리터러시연구 제12권 2호(통권 40호)
2021. 4. 30.
The Korean Journal of Literacy Research
DOI https://doi.org/10.37736/KJLR.2021.04.12.2.06

다국면 Rasch 모형을 활용한 국어교사의 쓰기평가 지식 수준에 따른 평가 수행 차이 분석

이은정[1)]

〈 목 차 〉

1. 서론
2. 이론적 배경
3. 연구 방법
4. 연구 결과 및 논의
5. 결론 및 제언

1. 서론

같은 학년 국어 수업을 담당하고 있는 A, B교사가 있다고 상정해 보자. 이 교사들이 학생 C의 글을 평가한다면, 이 학생의 쓰기 점수는 동일할까? 이 채점의 원점수가 상급 학교 진학의 성패(成敗)를 가름한다면, 관대한 A교사가 채점한 학생의 글은 성공을, 엄격한 B교사가 채점한 학생의 글은 패의 결과가 있을 가능성에 대해 국어교사들은 자유롭지 않다.

Linacre(1989)는 과제와 평가자로 인한 변량은 전체 평가 점수의 1/3~2/3

1) 한국교원대학교, 박사과정, alleyx@naver.com

를 차지할 만큼 중요한 비중이므로, 피험자 능력에 대한 안정되고 공정한 추정치를 얻기 위해서는 과제와 평가자 통제의 중요성을 강조하였다. 실제 우리나라 모의 논술 채점 상황을 통해 이현숙(2008)은 채점자 간 엄격성과 채점자 내 일관성의 차이가 존재하는 경우 수험자의 당락(當落)이 변화할 수 있음을 지적하고, 고부담(high-stakes) 검사에 점수 보정 방식이 필요함을 주장하였다. 쓰기평가는 입시와 직결되는 수행평가의 한 영역으로 활용되는데, 학생들이 유불리 없이 공정하게 평가받기 위해서는 이와 같은 채점 보정 방식이 필요할 수 있다. 그러나 이러한 논의는 다수 전문가들로부터의 이론적 타당성 확보, 학교 현장에 적용 가능한지 여부 등에 대해 평가 주체들 간의 충분한 협의가 이루어져야 한다. 현실 여건을 고려할 때, 학교 현장에서 우선적으로 할 수 있는 일은 국어교사의 평가 결과가 신뢰도와 타당도를 갖추었다고 인정받게 하는 것이다. 즉 국어교사는 학생의 쓰기 능력을 정확히 진단, 판별하고 그 결과를 활용하여 개별 학생에게 쓰기 학습에 대한 형성적 피드백을 제공해 줄 수 있는 평가 전문가가 되어야 한다.

그렇다면 국어교사가 쓰기평가를 위해 갖추어야 할 전문성은 무엇일까? 쓰기평가에 필요한 전문성은 한가지 안(案)으로 정리할 수 없는 총체적이고 복합적인 특성을 갖고 있다. 그러나 인간의 지적인 수행 능력을 분석하여 기술하는 일반적인 틀이 '지식, 수행, 태도'임을 고려할 때 쓰기평가 전문성 역시 수행에 필요한 지식, 실제 수행 능력, 지식과 수행에 대한 태도 요인으로 나눌 수 있다(박영민, 2012 ㄱ; 이성영, 2005). 학생들이 학습 전에 진단평가를 통해 자신의 학습 상태를 점검하는 것처럼 교사들도 쓰기평가 전문성 요인인 지식, 수행, 태도가 어느 수준이고, 어떤 부분이 부족한지에 대한 진단과 처방이 이루어져야 이에 대한 개선이 이루어질 수 있다. 이 중 태도는 비단 쓰기평가 단일 영역으로 국한하기 어려운 정의적 요인이므로 본 연구의 논의 대상에서 제외하고, 이 글에서는 국어교사의 쓰기평가에 대한 지식과 실제 평가 수행을 중심으로 논의를 이어가고자 한다.

쓰기 지식과 수행에 대해 Saddler & Graham(2007)은 쓰기 지식이 풍부할수록 능숙한 필자의 자질을 갖추고 있어 개인의 지식 차이는 쓰기 수행을 예견할 수 있다고 보았다. 이를 쓰기평가 상황에 적용해 보면, 쓰기평가에 대한 지식을 풍부하게 갖출수록 수행을 좀 더 능숙하고 전문적으로 할 수 있다고 가정할 수 있다. 이에 본 연구는 국어교사의 쓰기평가 지식 수준에 따라 실제 학생 글의 평가 수행에 어떤 차이가 있는지를 분석하여, 쓰기평가 지식 수준이 높을수록 실제 평가 수행에서 엄격성의 일관성을 유지하는지 등 국어교사의 쓰기평가 특성에 대해 탐색하고자 한다. 선행 연구는 주로 국어교사의 쓰기평가 지식이나 평가 수행 각각을 논의 대상으로 삼고 있어, 쓰기평가 지식과 수행을 함께 다룬 연구는 부족한 실정이다. 따라서 본 연구를 통해 쓰기평가 지식 수준에 따른 평가 수행이 어떻게 다른지 분석해 봄으로써 국어교사의 쓰기평가 특성에 대한 논의를 확장해 볼 수 있을 것이다. 이를 위해 쓰기평가 지식이 상위, 하위 수준에 해당하는 국어교사를 연구대상으로 선정하여, 피험자와 문항 이외에 다양한 평가자 특성을 국면(facets)으로 포함하여 평가자 특성 연구에 적절하다고 간주되는 다국면 Rasch 모형(지은림, 채선희 2000; 최연희, 2002)을 활용해 연구를 진행하였다.

이 연구는 일부 국어 교사를 선정하여 표집의 규모가 크지 않고 성별, 경력별 표본의 크기가 균일하지 않은 문제가 있다. 그러나 국어교사의 쓰기평가 전문성이 부족하다는 비판을 언제까지 묵과할 수 없으며, 채점 수행 중 성별, 경력별, 채점 분량 변인에 따라 엄격성이 부족하다는 연구(박영민, 2012ㄴ; 박영민, 최숙기, 2010ㄴ; 박종임, 박영민, 2011)에 이어 또 하나의 변인으로 쓰기평가 지식이 평가 수행에 영향을 미치는 요인일 수 있음을 탐색해 봄으로써 쓰기평가 전문성 신장 방안에 대한 논의를 확장하는데 의의가 있을 것이다.

2. 이론적 배경

1) 쓰기평가 지식과 전문성

Malone(2013)은 교사들이 언어 평가를 수행하지만, 평가에 관한 지식을 적용하는 것에서 전문성이 부족하여 실질적이고 근본적인 평가를 놓치는 경우가 많음을 지적하였다. Stiggins(2002) 역시 평가 전문성을 갖추지 못한 교사들로 인해 교실 수업이 위기에 처할 수도 있음을 지적하며,평가를 실시함에 있어 교사 스스로 학생 성취도를 정확하게 반영하는 절차, 채점을 잘 할 수 있을 것이라는 신념, 평가 결과에 대한 학생 피드백 제공 방법 등 평가에 대한 지식과 수행을 통해 전문성을 갖출 것을 당부하였다.

Crusan et al.(2016)은 쓰기 교사를 대상으로 한 설문에서 교사들이 쓰기평가 지식에 관련된 교육을 받은 경험이 적으며, 특히 채점 기준 등을 작성할 때 이와 관련된 지식 등의 부족으로 어려움을 겪고 있음을 보고하였다. 비단 이러한 문제는 장은섭(2015)의 국어 교사를 대상으로 한 연구에서도 유사하게 보고되고 있으므로 지식과 수행에 대한 쓰기 교사들의 평가 전문성 부족 문제는 국내외를 막론하고 중요한 화두(話頭)이다.

쓰기 교수 전문성 준거 요소에 대한 연구에서 김선정(2006)은 IRA(International Reading Association), NBPTS(National Board for Professional Teaching Standards) 등에서 제시하는 교사의 문식성 전문성 기준안을 참고하여 쓰기 교수 전문성은 여러 문식성 전략을 시연(demonstrating)할 수 있는 능력으로 정의하였다. 이를 통해 교사는 자신이 가지고 있는 쓰기 교수에 대한 방법적 지식과 선언적 지식을 활용해 평가 도구를 실제적으로 활용할 수 있는 능력을 갖추어야 함을 강조하였다. 학생들의 문식 환경을 마련하기 위한 교사의 전문적 역할을 이론적 설명가, 조력자로 설명하며 지식과 수행의 조화로운 역할을 강조한 것에 의의를 찾을 수 있다.

평가자의 인지 과정을 확인하여 쓰기 지식이 채점 수행에 필요한 요소임을 연구한 전형길, 이인혜(2017)는 학생 글을 채점하는 평가자의 사고구술 프로토콜을 분석하였다. 평가자의 사고 구술을 통해 쓰기평가 문식성이 어떻게 나타나는지를 지식과 신념으로 나누어 살펴본 결과, 평가자들은 지식을 활용하여 채점의 엄격성을 조절하였으며, 교육 경력 및 연수 경험에 따라 점수 표상(表象)에 차이가 있음을 확인하였다.

쓰기평가 전문성을 측정하기 위한 검사 도구를 개발하고, 예비 국어교사와 현직 국어교사의 쓰기평가 전문성을 비교한 연구로는 박영민(2012ㄱ, 2013)이 있다. 이 연구는 ATF(America Federation of teacher)의 교사 전문성 평가 기준을 바탕으로 쓰기평가 지식 측정을 위해 쓰기평가 방법, 쓰기평가 결과 처리 및 활용, 쓰기평가 윤리 세 가지 측정 요인으로 바꾸어 선다형과 서답형 문항 형태를 혼합한 검사 문항을 개발하였다. 예비 국어교사와 현직 국어교사를 대상으로 검사를 실시한 결과, 세 가지 요인 모두 척도 평균에 미치지 못해 국어교사의 쓰기평가 전문성이 부족함을 실제로 확인하였다.

이러한 선행 연구의 논의를 종합해 보면 국어교사 스스로가 실제 평가 과정에서 쓰기평가 지식이 중요하다고 인식하지만, 채점 기준안을 작성하고 실제 채점 척도를 해석해 점수를 부여하는 것과 같은 실질적인 쓰기평가 수행에 관한 쓰기평가 지식은 부족하다는 것이다. 이로 인해 국어교사의 전문성을 신뢰할 수 있는지에 대한 문제 제기와 이를 개선해야 한다는 논의가 이어지고 있다. 다만, 실제 쓰기평가 지식에 따라 교사들의 쓰기평가 특성이 어떻게 나타나는지에 대한 연구는 부족한 실정이므로 이 글에서 이러한 논의를 이어나가고자 한다.[2)]

---

2) 본고에서는 쓰기평가 지식을 평가자가 피험자의 쓰기 수행을 평가할 때 활용하는 개념적, 절차적 지식으로 정의하고자 한다. 평가 상황에 따라 평가자, 피험자의 구체적 대상은 변할 수 있으며, 가령 대학 입시 논술시험이라면 평가자는 논술시험 채점자, 피험자는 수험생이 될 것이다. 본고의 평가 상황은 학교 현장을 상정하고 있으므로 평가자는 국어교사, 피험자는 학생이 될 것이다. 본 연구에 활용된 쓰기평가

2) 다국면 Rasch 모형을 활용한 쓰기평가 수행

쓰기평가는 평가자 특성, 과제의 난도, 학생의 능력에 따라 다양한 결과가 도출될 수 있다. 특히 다국면 Rasch 모형을 활용하면 평가자들의 채점 경향 등을 통계적으로 조정하여 채점 오류를 줄일 수 있는 장점이 있다. 평가자 오류에 대해 Englehard(1994)는 다국면 Rasch 모형의 Facet 점수를 활용하여 평가자 엄격성, 후광효과(halo effect), 채점 척도 중앙집중화 경향을 논의하며 같은 능력을 가진 피험자 글에 대한 평가자 간 채점 수행에 많은 차이가 있음을 지적하였다. 이러한 맥락에서 설현수(2010)는 원점수와 표준점수, Facet 점수를 비교하며 평가자 간의 엄격성 차이 정도가 클수록 다국면 Rasch 모형의 Facet 점수가 개별 피험자의 능력을 정확하게 변별할 수 있다고 보았다.

다국면 Rasch 모형을 활용하여 국어교사의 쓰기 평가 특성에 대해 구체적으로 연구한 박영민, 최숙기(2010ㄴ)는 중학생 설명문을 채점한 국어교사들의 쓰기평가 특성을 분석하였는데, 성(性)과 경력, 평가 요인에 따라 채점의 엄격성과 일관성에 차이가 있는 것을 확인하였다. 평가 참여자의 47%는 과적합이나 부적합의 평가 경향을 보여 국어교사의 평가 전문성에 대해 비판적으로 고찰하였다.

이러한 엄격성의 차이가 어떤 요인에 의해 나타나는지에 대해 박종임, 박영민(2011)은 Rasch 모형을 활용하여 중학생 서사문 채점에 나타난 국어교사의 채점 일관성을 분석하였다. 연구 결과, 일관성 변화 원인으로 채점 분량 증가와 채점 기준 내면화 여부, 채점 경험 등의 요인 등을 지적하고 채점 일관성을 높일 수 있는 평가자 훈련을 제안하였다.

지식 검사 도구의 하위 변인으로는 쓰기평가 방법, 쓰기평가 결과처리 및 활용, 쓰기평가 윤리가 있다. 쓰기평가 방법 요인은 과정 평가, 결과 평가와 같은 구체적인 평가 방법에 관한 것이며, 쓰기평가 결과 처리 및 활용은 채점 척도 활용, 채점자 간 신뢰도 등 평가 활용에 관한 것이며, 쓰기평가 윤리는 평가 실시에 있어 지켜야 할 윤리적 사항에 관한 지식을 의미한다.

예비 국어교사를 대상으로 한 쓰기평가 특성 연구에서 박영민(2012ㄴ)은 학생 글 채점 수행에서 엄격성이 일관되게 유지되지 못하거나 지나치게 높으면 국어교사가 학생의 쓰기 능력을 적절하게 변별할 능력이 없다고 보았다. 따라서 쓰기평가 전문성을 위해 교사들의 채점 수행의 엄격성을 유지하기 위한 훈련과 평가 과정 점검 질문의 개발 및 적용 등 실제적인 전문성 신장 방안에 대해 논의를 이어나갔다.

평가 문항별로 평가자의 엄격성 차이가 있는지 분석한 안수현, 김정숙(2017)은 FACETS을 활용하여 한국어능력시험의 쓰기평가 문항 채점에서 점수 부여에 차이가 있는 문항을 대상으로 채점자에 따라 엄격성과 관대함의 차이가 있음을 확인하고 안정적인 채점 운영을 위해 평가자로서 전문성 확보가 필요함을 강조하였다.

의학 분야에 대한 지식이 풍부하더라도 임상적 수행이 적으면 환자에 대한 적확한 처치가 어려운 것처럼, 국어교사 역시 쓰기평가에 대한 지식이 풍부하더라도 그것을 적절하게 수행할 수 없으면 전문성을 인정받기 어렵다. 따라서 국어교사의 쓰기평가 지식과 수행에 대한 분석을 통해 쓰기평가 지식 수준에 따라 어떠한 평가 특성이 나타나는지를 탐색하고, 이를 바탕으로 국어교사의 전문성 향상 방안에 대한 구체적인 모색을 이어나가야 할 것이다.

3. 연구 방법

1) 연구 대상

이 연구는 국어교사의 쓰기평가 지식에 따른 평가 수행 특성을 분석하는데 목적이 있다. 이를 위하여 이은정(2020)의 현직 교사를 대상으로 쓰기평가 지식을 연구한 자료를 바탕으로, 쓰기평가 지식 수준이 상위와 하위로 분류된

국어교사 6명을 연구 대상으로 선정하였다.[3] 연구 대상의 수준을 상위와 하위로 나눈 기준은 전체 표집 인원의 원점수 기준 상위 30%를 상위 수준, 하위 30%를 하위 수준으로 분류하였다.[4] 검사 문항의 총점은 55점이었으며, 상위 수준의 M=47.37, SD=3.20, MAX=53, MIN=43점, 하위 수준의 M=31.16, SD=3.44, MAX=36, MIN=26점이었다. 이에 따라 이 연구에 참여한 국어교사들의 정보는 〈표 1〉과 같다.

〈표 1〉 연구 대상

평가자	쓰기평가 지식 수준(원점수)	성별	교육 경력
1	상위(53점)	여	6년
2	상위(50점)	여	14년
3	상위(45점)	남	13년
4	하위(34점)	여	21년
5	하위(31점)	여	18년
6	하위(26점)	남	17년

3) 해당 연구는 국어교사를 대상으로 쓰기평가 지식 검사를 실시하고 분석한 연구이다. 연구 결과 쓰기평가 지식의 하위 요인인 쓰기평가 방법, 쓰기평가 결과처리 및 활용, 쓰기평가 윤리 세 요인의 평균은 척도 평균에 미치지 못해 국어교사의 쓰기평가 전문성은 전반적으로 부족한 것으로 나타났다. 구체적으로는 국어교사의 성별에 따른 유의미한 차이는 없었으며, 중학교 교사들의 쓰기평가 윤리 평균이 고등학교 교사에 비해 높았다. 교직 경력별로는 쓰기평가 방법 요인에서 20년 이상의 고경력 교사들이 5년 미만의 저경력 교사들에 비해 평균이 낮았으며 이는 통계적으로 유의했다.

4) 쓰기평가 지식 수준을 상위, 하위 30%로 구분한 것은 본 연구의 현실적 여건을 반영한 조작적 정의임을 밝힌다. 쓰기평가 지식 검사를 실시했던 국어교사 65명중 가장 높은 수행을 보인 교사들과 가장 낮은 수행을 보인 교사를 연구 대상자로 섭외하였으나, 연구 진행에 동의하지 않는 교사들이 다수 존재하여 연구 대상자 범위를 상위, 하위 30%로 넓혔다. 특히 자신의 쓰기평가 지식이 낮다는 사실에 불쾌감을 표하는 교사들이 많아 연구 진행에 많은 어려움이 있었다. 다만 본 연구에 참여한 1번 평가자는 65명 중 가장 높은 점수를 받은 참여자였으며, 6번 평가자는 가장 낮은 점수를 받은 참여자로 평가 지식 차이를 극명하게 보여준다고 할 수 있으며, 선행연구(박영민,최숙기, 2010 ㄱ)에서 상위, 하위 수준을 30%로 구분하고 있어 이를 참고하여 상위, 하위를 30%로 정의하였다. 또한 교직 경력별로 표집이 균질하지 않은 것도 연구의 현실적 한계로 인한 것임을 밝힌다.

평가 대상 글이 고등학생이 작성한 것임을 고려하여 연구 참여자들은 고등학교 재직 경험이 있는 교사들로 한정하였으며, 연구 취지와 진행 과정에 대한 설명 후 참여자의 자발적 동의를 얻어 연구를 진행하였다. 평가자로 선정된 국어교사들에게 본인의 쓰기평가 지식 수준을 공개할 경우 과도한 자신감이나 부정적 효능감으로 평소와는 다른 쓰기평가 특성을 보일 것을 고려하여 연구 대상자들에게 쓰기평가 지식 수준을 사전에 공개하지 않았고, 채점 수행 자료 분석 이후 진행된 사후 면담에서 쓰기평가 지식 수준과 평가 특성에 대한 피드백을 제공하였다.

2) 검사 도구

이 연구에서는 '과학 연구를 위해 동물 실험을 해야 한다'라는 쓰기 과제에 따라 작성한 고등학생의 논설문 25편을 국어교사들이 평가하도록 하였다. 학생 글은 2020년 10월 26일부터 30일까지 충북 소재 A고등학교 2학년 국어 선택 교과 시간에 작성되었으며, 학생 글은 담당 국어 교사의 쓰기 첨삭을 통해 피드백이 이루어졌다. 채점 분량 20~25편을 기준으로 평가자의 적합도와 엄격성에 변화가 있었던 선행 연구(박종임, 박영민, 2011)를 참고하여, 교사들의 인지적 부담과 피로라는 외부효과를 차단하여 오차 요인을 줄이기 위해 교사들의 채점 수행 분량을 25편으로 한정하였다. 또한 본 연구에서는 어떤 평가 기준에서 엄격성의 차이를 보이는지 교사들의 쓰기평가 특성을 분석하고 진단하는 데 목적이 있으므로, 글의 전체적인 인상을 바탕으로 채점하는 총체적 채점 방법보다는 분석적 채점 방법이 적절하다고 판단하였다. 그리하여 평가자들이 채점 수행에 사용한 논설문 평가 기준은 백유진(2020)에 사용된 채점 기준을 사용하였다. 이 채점 기준을 사용한 이유는 해당 연구에서 사용된 논설문이라는 글의 유형과, '동물 실험'이라는 화제가 본 연구와 유사하

고, 분석적 채점 방법이기 때문이다.[5] 연구를 진행하며 평가자들이 평가 요인에 따라 6점부터 1점까지 본인의 주관대로 점수를 부여할 수 있게 하였다.

3) 연구 절차

최초 수집된 학생 글은 총 42편이었으나, 분량 미달과 활자 해독이 불가능하여 한글 워드프로세서 전사가 불가능한 4편을 제외하고 38편을 연구 자료로 활용하였다. 연구에서 사용된 채점 기준을 사용하여, 연구자와 A고등학교 교과 담당 교사가 학생 글을 채점한 뒤 상, 중, 하 수준으로 분류하였다. 이후 작문 교육을 전공하고 있는 박사과정 대학원생과 글의 수준 분류가 타당하고 적절한지 검토 및 조정 과정을 거친 후 연구 대상 글을 최종 25편으로 확정하였다. 손글씨로 쓴 학생 글은 맞춤법과 띄어쓰기 오류 등을 수정하지 않고 그대로 한글 워드프로세서로 옮겨 글씨 모양에 따른 평정의 오류를 줄이고자 하였다. 평가자들에게는 연구 진행에 대한 안내문, 학생들이 사용한 쓰기 과제, 채점 기준표, 학생 글, 사후 설문 자료 등을 엑셀(EXCEL) 파일로 정리하여 온라인 매체를 활용해 전달하였다. 평가자 훈련을 실시할 경우, 지나치게 엄격하게 채점하거나 관대하게 채점하는 등 평소 교사의 쓰기평가 특성이 나타나지 않을 것을 고려하여 별도의 훈련 과정은 거치지 않았다. 국어교사들은 2021년 1월 28일부터 2월 3일까지 제공된 평가 자료를 활용하여 개별적으로 채점을 수행하였으며, 모든 평가가가 모든 학생 글을 채점하는 완전교차설계방식을 적용하였다. 채점이 완료된 후에는 연구자가 채점 결과를 수합하여 FACETS 프로그램을 활용하여 개별 평가자의 쓰기평가 특성을 분석하였다.

---

5) 채점 방법에는 총체적 채점과 분석적 채점이 있다. 채점 목적에 따라 점수를 부여하여 서열을 매기는 것이라면 총체적 채점이, 피험자에 대한 이해와 진단을 평가의 목적으로 갖는다면 분석적 채점 방법이 적절하며 분석적 채점 방법이 총체적 방법보다 채점자 간 신뢰도가 높게 나타나는 경향이 있다(남명호, 2002:24).

4) 분석 방법

고등학생 논설문 채점 수행을 통해 국어교사의 쓰기평가 특성을 분석하기 위하여 FACETS Version 3.80 프로그램을 사용하였고, 피험자 쓰기 능력, 평가 기준의 난도(難度), 평가자의 엄격성, 쓰기평가 지식 수준에 따른 평가자의 엄격성이라는 4국면을 적용하여 분석하였다. 이를 통해 고등학생 논설문 쓰기평가에서 쓰기평가 지식 수준이 q인 국어교사가, 논설문 쓰기 능력이 n인 고등학생의 논설문 쓰기평가 기준 i에 대해, 평가 점수 k-1이 아닌 k를 부여할 확률과 그 확률을 log로 변환한 값을 얻을 수 있다 (Linacre, 1989). 이러한 분석 모형을 정리하면 〈표 2〉와 같다.

〈표 2〉 쓰기평가 특성 분석을 위한 Rasch 분석 모형

$$\ln\left(\frac{P_{ijqKn}}{P_{ijq(K-1)n}}\right) = B_n - D_i - C_j - E_q - F_k$$

P_{ijqKn} = 쓰기평가 지식 수준이 q인 국어교사 j가 평가 요인 i에 대해 점수 k를 줄 확률
$P_{ijq(K-1)n}$ = 쓰기평가 지식 수준이 q인 국어교사 j가 평가 요인 i에 대해 점수 k-1을 줄 확률
B_n = 고등학생 n의 논설문 쓰기 능력
D_i = 논설문 평가 요인 i의 난도(難度)
C_j = 국어교사 j의 엄격성
E_q = 쓰기평가지식 수준이 q인 국어교사 j의 엄격성
F_k = 평가 점수 k-1에 비해 평가 점수 k를 받기 어려운 정도

본 연구에서는 〈표 2〉의 다국면 Rasch 모형을 활용하여 원점수보다 객관적인 변환 점수 측정치 logit값으로 각 국면을 분석하였다.[6] 이를 통해 국어

6) Rasch 모형은 문항반응이론 모형 중 하나로 1-모수 로지시틱 문항반응모형으로 불린다. 문항 난이도, 문항 변별도, 피험자 세 개의 모수 중에서, 문항 난이도 하나의 모수만을 고려해 1-모수 모형이라 하며, 기본적으로 피험자의 능력을 문항 난이도와의 관계에 의해서만 설명하는 특징이 있다(지은림, 채선희, 2000:25). logit은 로지스틱 함수에서 정답을 할 확률을 의미하는 로그 승산 단위(log odds unit)로, 응답확률로 문항곤란도와 피험자의 능력을 나타낸다(McNamara, 1996).

교사의 쓰기평가에서 보이는 엄격성과, 쓰기평가 지식에 따라 고등학생의 논설문 쓰기 능력을 일관성을 유지하며 평가하고 있는지 분석을 진행하였다.

4. 연구 결과 및 논의

1) 채점 수행 자료의 모형 적합도 검증

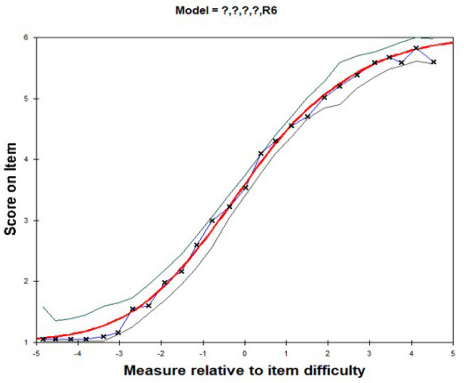

〈그림 1〉 채점 자료의 모형 적합도

분석 모형에 대한 채점 수행 자료가 적합한지 알아보기 위한 모형 적합도 분석 결과는 〈그림 1〉과 같다. 〈그림 1〉은 문항 반응 곡선과 실제 채점 자료에 나타난 반응 간의 관계를 나타낸 것이다. 가로축은 '학생 능력 – 과제 난이도' 추정치며, 세로축은 이에 대한 기대 점수를 나타낸다. 모형 적합도 분석은 95% 신뢰 구간을 설정하여, 관찰치 곡선이 문항 특성 곡선에 얼마나 부합하는지를 보여준다.

국어교사들의 채점 수행이 Rasch 모형에 적합한지 판단하기 위해서는 관찰 점수가 신뢰 구간 안에 적절히 위치해야 한다. 〈그림 1〉처럼 대부분의 관찰치가 신뢰 구간 안에 위치하고 있어, 국어교사 6명으로부터 얻은 채점 수행 자료는 Rasch 모형에 적합한 것으로 간주하고 분석을 진행하였다.

2) 측정단면분포도 분석

FACETS 프로그램 분석으로 채점 수행에 참여한 국어교사들의 쓰기평가 자료를 logit 값에 따라 분포를 제시하면 〈그림 2〉와 같다.

```
+-----------------------------------------------------------------------------+
|Measr|+examinee              |-rater   |-knowledge|-criteria       |Scale|
|-----+-----------------------+---------+----------+----------------+-----|
|   4 +                       +         +          +                + (6) |
|     |                       |         |          |                |     |
|   3 + 11                    +         +          +                + --- |
|     | 15 16                 |         |          |                |     |
|   2 +                       + 1       +          +                +  5  |
|     |                       |         |          |                |     |
|   1 + 14 23                 +         +          +                + --- |
|     | 7  8  18 24           |         |          | C3  O2         |  4  |
*   0 * 4  25                 *         * 1  2     * C2  E1  O1  O3 * --- *
|     | 2  3  5  13 17 19 21  | 2  3  5 |          | C1  E2         |  3  |
|  -1 + 10 12 20              + 4  6    +          +                + --- |
|     | 6  9                  |         |          |                |     |
|  -2 + 22                    +         +          +                +  2  |
|     | 1                     |         |          |                | --- |
|  -3 +                       +         +          +                + (1) |
|-----+-----------------------+---------+----------+----------------+-----|
|Measr|+examinee              |-rater   |-knowledge|-criteria       |Scale|
+-----------------------------------------------------------------------------+
```

〈그림 2〉 피험자 × 평가자 × 쓰기평가 지식 × 평가 요인 분포도

〈그림 2〉는 모든 국면(facet)의 정보를 logit 모수 추청치로 나타낸 것이다. 왼쪽 첫 번째 열의 지수(Measr)는 문항 반응 이론의 공통 척도인 logit 값을 의미하며, 채점을 수행하는 평가자들의 엄격성에 대한 정보, 피험자의 능력, 평가 요인이 어느 정도 분포를 보이는지에 대한 정보를 제공해 준다. 두 번째 열(+examinee)는 고등학생 논설문 25편의 logit 분포로 쓰기 능력이 높을수록 척도의 위쪽에, 쓰기 능력이 낮을수록 척도의 아래쪽에 위치한다. 평가자들에게 11번이 가장 높은 수준, 1번이 가장 낮은 수준의 글로 평가받았음을 알 수 있다. 세 번째 열(-rater)은 채점을 수행하는 국어교사 6명의 logit 분포로 0을 기준으로 척도 위쪽에 위치할수록 엄격한 평가자이고 아래쪽에 위치할수록 관대한 평가자이다. 1번 평가자가 가장 엄격하고 4번, 6번 평가자가 관대함을 알 수 있다. 네 번째 열(-knowledge)는 쓰기평가 지식 수준의 logit 분포로, 다른 분석에 영향을 미치지 않기 위해 로짓값을 0으로 고정시킨 모조

국면(dummy facets)이다 (Linacre, 2019). 채점 자료 코딩시 상위 수준은 1로, 하위 수준은 2로 설정하였다. 세 번째 열(-rater)에서 쓰기평가 지식 수준이 높은 평가자는 1,2,3번이고 쓰기평가 지식 수준이 낮은 평가자는 4,5,6이다. 다섯 번째 열(-criteria)은 평가 요인별 logit 분포로 평가 요인의 난도(難度)로 위쪽에 위치할수록 엄격하게, 아래쪽에 위치할수록 관대하게 평가한 것으로 볼 수 있다. 구체적으로 C3은 평가 요인 중 근거의 타당성에 대한 것으로 평가자들에게 가장 엄격하게, E2는 어법에 관련된 요인으로 평가자들에게 관대하게 평가되었음을 알 수 있다. 여섯 번째 열(Scale)은 평가 요인의 점수를 척도별 logit 분포로 도식화한 것으로, 이 연구에서 활용된 6점 척도의 활용 양상이 적절함을 보여준다.

3) 쓰기평가 지식 수준별 엄격성 분석

측정단면분포표를 통해 각 국면에 대한 개략적인 정보를 파악했다면, 구체적인 쓰기평가 지식 수준별 평가자의 엄격성 수준과 적합도에 대한 logit 값 정보는 〈표 3〉과 같다.

〈표 3〉 쓰기평가 지식 수준별 채점자 엄격성 및 적합도

평가자	쓰기평가 지식 수준	엄격성 (logit)	표준 오차	내적합 지수	외적합 지수
1	상위	2.07	0.01	1.08	0.89
2	상위	-0.48	0.08	1.03	0.99
3	상위	-0.49	0.08	0.68	0.73
4	하위	-1.16	0.08	0.71	0.76
5	하위	-0.55	0.08	1.52	1.47
6	하위	-0.91	0.08	0.92	1.00

〈표 3〉의 평가자 엄격성은 −1.16 logit(SE=0.08)부터 2.07 logit(SE=.01)까

지의 분포를 보이며 이는 평가자 간 엄격성에 차이가 있는 것으로 볼 수 있다. 이러한 차이는 X^2 = 802.2(p〈0.00), 분리신뢰도 R = 0.99로써 통계적으로 유의하였다. 주목해야 할 것은 쓰기평가 지식 수준이 가장 높은 1번 평가자가 학생 글을 가장 엄격하게, 쓰기평가 수준이 낮은 4번 평가자는 가장 관대하게 평가했으며 두 평가자 간 엄격성 logit 차이는 3.23이다. Eckes(2005)는 가장 엄격한 평가자와 가장 관대한 평가자의 엄격성 logit 차이가 4.26로짓일 때, 가장 관대한 평가자가 5점을 부여할 확률이 50%라고 가정하면, 가장 엄격한 평가자가 5점을 부여할 확률은 1.5%이라고 지적하였다. 이를 고려하면 4번 평가자가 5점을 줄 확률이 50%일 때 1번 평가자가 5점을 줄 확률은 13%밖에 안 되는 차이라 볼 수 있다.

이러한 평가의 엄격성이 일관성 있게 이루어졌는지 판단하기 위해서는 적합도 지수를 살펴보아야 한다. 외적합 지수(Outfit MnSq)는 모든 관찰값을 계산하여 예상치 못한 극단값에 민감하게 반응하므로(장소영·신동일, 2009:24) 좀 더 안정적인 내적합 지수(Infit MnSq)로 분석하였으며, 연구자마다 적합도 지수에 따른 이견이 있지만 본 연구에서는 McNamara(1996)에 따라 적합 지수 0.75 미만은 과적합, 1.3 초과는 부적합으로 분석하였다. 따라서 2, 6번 평가자는 적합(fit), 3, 4번 평가자는 과적합(overfit), 5번 평가자는 부적합(misfit)으로 분석할 수 있다. 적합(fit)은 평가자가 엄격성의 일관성을 유지하며 평가를 수행한 것이며, 과적합(overfit)은 비슷한 점수만 부여하여 학생의 논설문 쓰기 능력을 세부적으로 변별하지 못하는 것을 의미한다. 부적합(misfit)은 점수 부여에 일관성이 없어 높은 점수를 부여해야 할 글에 낮은 점수를 부여하거나 혹은 낮은 점수를 부여해야 할 글에 높은 점수를 부여하는 등 평가의 일관성이 없는 것을 의미한다. 부적합(misfit)과 과적합(overfit)은 평가의 신뢰성 문제를 야기할 수 있으므로 평가자가 어떠한 쓰기평가 특성을 보이는지 분석하여 이를 개선해야 한다.

우선, 부적합으로 분석된 5번 평가자의 결과를 〈표 4〉의 Rasch 모형에 의

한 기대 점수와 관찰 점수 간의 차이를 통해 확인할 수 있다.

〈표 4〉 평가 기댓값 이외의 반응 결과

평가자	피험자	평가 요인	관찰 점수	기대 점수	잔차	표준화 잔차
5	14	O2	2	4.7	-2.7	-3.3
5	14	O3	2	4.7	-2.7	-3.3
5	9	C2	6	2.9	3.1	3.2

〈표 4〉는 평가의 점수가 Rasch 모형을 바탕으로 할 때 예측 점수에 비해 실제 관찰 점수가 얼마나 벗어났는지를 보여줌으로써, 5번 국어교사와 평가 결과 요인 사이의 편향을 확인할 수 있다. 이를 좀 더 구체적으로 확인하기 위해 5번 평가자의 14번 글에 대한 평가 결과를 다른 평가 결과와 비교해 보았다. 학생 글은 8개의 평가 기준, 6점 척도로 채점되었고, 모든 평가 요인을 충족할 경우 최고점 48점, 그렇지 않을 경우 최하점 8점을 부여하는데, 5번 평가자는 검사 도구 14번 글은 24점, 7번 글은 34점을 부여하여 7번 학생 글을 더 우수하다고 평가하였다. 그러나 FACETS 프로그램 분석 결과 14번 글의 logit 값은 1.03(SE=0.18), 7번 글의 logit 값은 0.41(SE=0.18)로 14번 학생의 쓰기 능력이 우수한 것으로 분석되었다. 또한 21번 학생 글은 43점을 부여하여 앞에 논의한 두 개의 글보다 수준 높은 글로 평가하였지만, FACETS 프로그램 분석 결과 21번 글의 logit 값은 −0.28(SE=0.16) 음의 수치를 보여 난도가 높지 않은 글로 분석되었다. 이를 종합해 볼 때 쓰기평가 지식이 하위 수준이었던 5번 평가자는 고등학생의 논설문 쓰기 능력을 변별하지 못하며 고등학생의 논설문 쓰기 능력을 추정하는데 어려움을 겪는 것으로 분석할 수 있다. 이러한 평과 결과를 바탕으로 피드백을 제공하기 위해 심층 면담을 진행하였다. 다음은 5번 평가자와의 면담 내용 중 일부이다.

학생 글을 평가할 때 어떤 글이 잘 썼고, 못 썼는지 기준을 세우기가 어

려워요. 이번에도 사실 채점 기준이 있기는 했지만 채점 기준에서 말하고 있는 '통일성, 체계성, 응집성' 개념을 학생 글에 적용하여 1,2,3,4,5,6점으로 구별해 점수를 줘야하는데 명확하게 이러한 개념이 점수에 연결이 안 되다 보니 잘 쓰면 5점 못 쓰면 2점으로 점수를 줬어요. 채점을 한 다음에 전체적으로 살펴보지 않았더니 점수를 이리 줬는지 몰랐네요.

면담을 통해 5번 평가자가 학생 글의 쓰기 능력 변별을 어려워한다는 것, 그 이유로 제시한 것이 '통일성, 체계성, 응집성' 등 쓰기평가 기준에서 제시한 용어에 대한 지식을 실제로 적용하여 척도를 변별해 평가를 수행하는 것에 대한 어려움을 겪고 있음을 알 수 있다.

또한 쓰기평가 지식 수준이 하위로 분류된 4번 평가자는 과적합으로 분석되었다. 4번 평가자는 Rasch 모형을 바탕으로 한 예측 점수와 실제 점수의 편향은 나타나지 않았지만, FACETS 분석 결과 logit 값 2.53(SE=0.23), 2.58(SE=0.23)의 결과를 보인 쓰기 능력이 우수한 15번 16번 글에 4, 5점 척도만을 부여하고, logit 값 -1.35(SE=0.16), -1.42(SE=0.16)의 결과를 보인 쓰기 능력이 우수하지 못한 6번, 9번 글에는 2, 3점 척도만을 부여하여 세부 기준별로 점수를 부여하지 못하고 단일 척도에 편중된 결과를 보였다. 다음은 4번 평가자와 평가 결과에 대해 피드백을 진행하면서 이러한 이유에 대해 면담한 내용 중 일부이다.

학생 글 채점하면서 잘 썼다 못 썼다 구분하고 평가 기준 점수를 거기에 맞추는 편이에요. '매우 그러함' 6점, '그러함'을 5점으로 구분할 때 명시적으로 구분할 수 있는 근거를 판별하기 어렵고, 채점에 시간이 오래 걸린다, 애매하다 싶으면 최고점은 피하고 그 아래 점수 주고, 아예 글을 제출하지 않아 최하점을 주는 것이 아니라면 최하점은 안 주고 3,4,5점에서 점수를 고릅니다.

4번 평가자의 면담 속에서 확인할 수 있는 것은 최고점, 최하점을 피해 중앙집중적으로 점수를 부여한다는 점, 세부 기준을 어떻게 판별해야하는지에 대한 구체적인 정보나 지식이 없이 인상 평가에 의존한다는 점을 확인할 수 있다. 과적합으로 분류된 쓰기평가 지식 수준 상위인 3번 평가자 역시 2,3,4 채점 척도를 주로 사용해 세부 척도를 정확하게 변별하지 못하는 것으로 나타났다. 국어교사들의 평가 척도 중앙집중경향 문제는 지속적으로 지적되었으며(박영민, 2012ㄴ; 박종임, 2013; 백유진, 박영민, 2021) 쓰기평가 지식 상위, 하위 수준 교사들에게서 이러한 현상은 동일하게 나타났다. 이외 1,2,6번 평가자의 내적합 지수는 모두 적합의 범위에 있어 엄격성이 일관되게 유지되는 것을 알 수 있다.

쓰기평가 지식 수준이 상위인 1,2번 평가자가 엄격성의 일관성을 유지하는 적합 평가자로, 쓰기평가 지식 수준이 하위인 4,5번 평가자가 엄격성의 일관성을 유지하지 못하는 과적합, 부적합한 평가자로 분석된 결과를 볼 때 쓰기평가 지식이 높을수록 평가의 엄격성을 일관성 있게 유지하는 것으로 볼 수 있다. 즉 쓰기평가 지식 수준에 따라 평가의 엄격성에 차이가 있음을 알 수 있다.

4) 쓰기평가 지식 수준별 평가 요인에 대한 엄격성과 편향

쓰기평가 지식 수준별 집단 간의 엄격성이 평가 요인에 따라 어떻게 다른지 확인하기 위해 집단과 평가 요인 간의 편향(bias)을 분석하였다. 평가 요인의 엄격성은 일반적으로 난도(難度)로 설명하는데, 엄격하게 평가할수록 해당 요인에 맞게 글을 쓰는 것이 어려움을 의미한다. 쓰기평가 지식 수준별로 평가 요인에 대한 편향 분석을 〈표 5〉에 제시하였다.

〈표 5〉 쓰기평가 지식 수준별 – 평가 요인 엄격성 편향 분석

평가 요인[7]	상위 집단		하위 집단		t	p
	엄격함 (logit)	표준 오차	엄격함 (logit)	표준 오차		
E1	0.24	0.14	-0.28	0.19	2.66	0.01
C2	-0.06	0.14	-0.09	0.01	0.17	0.87
C1	-0.44	0.14	-0.43	0.00	-0.02	0.99
C3	0.49	0.14	0.50	0.00	-0.06	0.95
O1	-0.12	0.14	-0.06	-0.02	-0.32	0.75
E2	-0.42	0.14	-0.36	-0.02	-0.32	0.75
O3	0.14	0.14	0.31	-0.06	-0.88	0.38
O2	0.16	0.14	0.38	-0.06	-1.14	0.25

〈표 5〉에 따르면 평가 요인 E1이 쓰기평가 지식 수준별로 엄격성 차이가 유의하며($t = 2.66$, $p=0.01$), 나머지 평가 요인은 통계적으로 유의하지 않은 것으로 나타났다. E1은 명료한 문장을 사용하였는지에 대한 평가 요인으로 '명료함'이라는 기준을 수립함에 있어 쓰기평가 지식 상위 수준 교사들은 좀 더 세부 기준을 세워 엄격하게 평가하였으며, 쓰기평가 지식 하위 수준 교사들은 구체적 기준 없이 자의적인 판단으로 관대하게 평가한 것으로 보인다. 이를 구체적으로 확인해 보고자 E1 평가 요인에서 가장 큰 편향을 보인 6번 평가자와 개별 면담을 진행하였다. 면담의 일부 내용을 제시하면 다음과 같다.

> 내용이나 조직 점수 구분하는 것은 별 어려움이 없었는데, 평가 기준 8개 중에 문장의 명료성을 1점부터 6점까지 변별하는 것이 가장 애매했어요. 내가 읽기에 잘 읽히면 명료한 것인데, 명료하다는 게 개인마다 기

7) C1은 맥락에 맞는 내용 생성, C2는 주장의 명료성, C3은 근거의 타당성, O1은 글의 통일성, O2는 내용의 체계성, O3은 글의 응집성, E1은 명료한 문장의 사용, E2는 어문 규범 적절성이다.

준이 다르지 않나요? 이것 때문에 학교에서도 수행평가할 때 이 기준은 뺐던 것 같아요. 어차피 학생 글 수준이 엄청 두드러지게 뛰어난 글도 없고, 내용도 비슷하고 , 문장도 비슷하고. 명료한 정도를 무엇을 기준으로 해야할지 크게 고민 안 하고 아주 잘 읽히면 5점이나 6점, 읽다가 좀 막히면 2점 3점 이렇게 줬죠.

인터뷰를 통해 6번 평가자는 해당 평가 요인에 대해 명확한 기준을 수립하지 않고 '잘 읽힌다'는 주관적인 인상을 판단으로 척도를 구분하고 있어 점수 변별이 잘 이루어지고 있지 않다는 것을 알 수 있다. 실제로 6번 평가자는 글 수준이 가장 뛰어난 11번(logit=3.13)과 수준이 낮은 9번(logit=-1.35)의 E1에 대한 점수를 동일하게 부여했다. 종합해 볼 때 쓰기평가 지식이 하위 수준인 6번 평가자는 해당 평가 요인을 적용해 평가하는데 어려움을 겪어 정확한 점수 평정이 이루어지지 않는 것으로 보인다. 따라서 쓰기평가 지식 수준에 따라 해당 평가 요인에 대한 엄격성 정도가 달라 점수 부여에 차이가 있을 수 있으니 고등학생의 논설문 지도에 유의해야 할 것으로 보인다. 쓰기평가 지식 집단 간 편향 분석에 이어, 개별 평가자의 평가 요인에 대한 편향을 〈그림 3〉을 통해 확인할 수 있다.[8)]

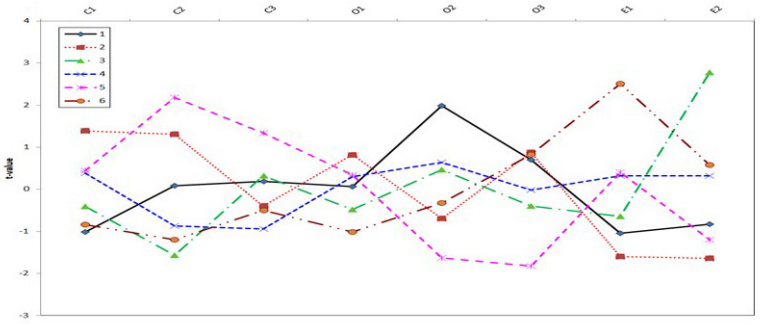

〈그림 3〉 평가자별 –평가 요인 엄격성 편향 그래프

8) 1~6은 평가자 번호를 의미하며 색깔과 선의 모양으로 구분하였다.

그래프는 평가자별 평가 요인에 대한 편향을 나타낸 것으로 가로축은 평가 요인, 세로축은 엄격성에 대한 t-value로 기대 점수와 관찰 점수 간의 차이를 보여주며 -2~+2 밖에 있는 경우 다시 평가해야 할 정도로 문제가 될 수 있음을 뜻한다(이인혜, 2014:253). 왼쪽부터 5번 평가자 C2, 1번 평가자 O2, 6번 평가자 E1, 3번 평가자 E2에서 평가 요인 사용에 문제가 있었음을 알 수 있다. 쓰기평가 지식 수준별로 E1 평가 요인에서 통계적으로 유의한 차이를 보인 것에 이어, 쓰기평가 지식 상·하위 모든 집단에서 국어교사들의 평가 요인에 대한 편향이 발견되었다. 이러한 결과는 채점 편향이 개별 채점자에 따라 매우 다르게 나타난 백유진(2020)에서도 확인할 수 있다. 이러한 평가가 실제 쓰기평가에 반영되어 학생의 성적으로 산출될 경우 평가의 신뢰도에 큰 영향을 미치므로 평가자 재교육 등의 전문적 평가 훈련 등을 통해 반드시 개선되어야 한다.

5) 쓰기평가 지식 수준별 채점 척도 활용 양상

쓰기평가 지식 수준별로 평가자들이 채점 척도 활용 양상을 분석함으로써 학생의 쓰기 능력을 적절하게 변별하고 있는지 분석할 수 있다. 〈표 6〉은 쓰기평가 지식 수준에 따른 채점 척도 활용과 적합도를 제시한 것이다.

〈표 6〉 쓰기평가 지식 수준별 척도 활용과 적합도

척도	상위 수준				하위 수준			
	사용 빈도 (비율)	누적 비율 (%)	Avge Meas	Outfit Mnsq	사용 빈도 (비율)	누적 비율 (%)	Avge Meas	Outfit Mnsq
1	94 (16%)	16%	-3.72	0.8	20 (3%)	3%	-1.83	0.6
2	118 (20%)	35%	-1.77	1.0	38 (6%)	10%	-0.64	1.0
3	136 (23%)	58%	-0.50	0.9	102 (17%)	27%	0.7	1.1
4	93 (16%)	74%	0.55	1.0	167 (28%)	55%	0.43	0.9
5	98 (16%)	90%	1.55	1.1	192 (32%)	87%	1.37	0.9
6	61 (10%)	100%	3.37	1.0	81 (14%)	100%	2.25	1.2

〈표 6〉의 사용 빈도(비율)은 해당 척도를 사용한 비율로 상위 집단은 3점을, 하위 집단은 5점을 가장 많이 사용한 것을 알 수 있다. 평균 측정치(Avge Meas)는 실제 관찰값에서 얻어진 평균값으로 척도 등급이 높아질수록 평균 측정치가 증가하면 척도가 적절하게 기능하는 것으로 볼 수 있는데 두 집단 모두 1점에서 6점 등급으로 높아질수록 점차 수치가 증가하여 척도가 적절하게 기능함을 알 수 있다. 외적합 평균 제곱값(Outfit Mnsq)는 1.0을 기준으로 채점 등급이 모델값을 기준으로 신뢰로운지 판단할 수 있는데(장소영·신동일, 2009:84), 상위 집단은 대체적으로 신뢰할 수준이지만 하위 집단의 경우 1점 척도 등급 부여에서 신뢰할 수 없는 수치값을 보인다. 상위 집단의 경우 1점 척도의 사용 비율이 16%인데 반해, 하위 집단의 경우 1점 등급의 사용 비율이 3%밖에 되지 않아 하위 집단의 경우 쓰기 능력이 낮은 글에 대한 변별이 잘 이루어지지 않아 최하점 부여를 피하는 것으로 분석할 수 있다. Eckes(2012)는 이렇게 극단 척도를 사용하지 않을 경우, 학생의 쓰기 능력을 적절히 변별하지 못해 평가의 신뢰성에 문제가 있을 수 있음을 지적한 바 있다. 집단별로 채점 구간 확률을 살펴봄으로써 채점 척도를 잘 변별하고 있는지 〈그림 4〉를 통해 확인할 수 있다.

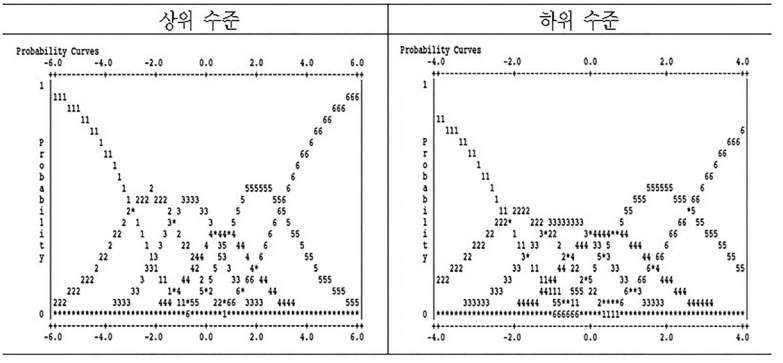

〈그림 4〉 쓰기평가 지식 수준별 채점 구간 확률 모형 그래프

〈그림 4〉의 x축은 피험자 능력에 대한 logit 값이며 y축은 특정 척도가 선택될 확률로, 1점에서 6점까지 평가 척도가 x축에서 한 번은 가장 높은 logit 값을 가지는 언덕 모양을 이룰 때 이상적인 모형으로 볼 수 있다. 쓰기평가 지식 상위집단의 경우 각 척도별로 이상적인 형태를 이루고 있지만, 하위집단의 경우 2,3점과 3,4점의 척도가 제대로 기능하지 못하고 있음을 알 수 있다. 즉, 쓰기평가 지식 수준이 하위인 국어교사들이 쓰기평가에서 낮은 수준과 중간 수준 척도 사용 변별에 대한 문제가 있어 실제 학생 글에 대한 평가가 올바르게 이루어지고 않다고 볼 수 있다.

물론 McNamara(1996)는 평가자에 따라 중앙 척도를 사용하기도 하고 모든 척도를 사용하기도 하며, 매우 다양한 수준의 학생 글을 특정 척도로 일관화해 점수를 부여하는 것이 어려운 일임을 지적하였다. 그러나 평가 척도 활용이 타당하게 이루어져야 학생의 쓰기 능력 변별이 정확하게 이루어지므로 이러한 문제는 반드시 개선되어야 한다. 앞에서 논의한 바와 같이, 쓰기평가 지식 수준에 따라 쓰기평가 척도 활용에 차이가 있으므로 교사의 현재 쓰기평가 지식 수준 정도를 점검, 진단하여 이러한 문제 해결에 실마리를 찾아야 할 것이다.

5. 결론 및 제언

현재 우리나라 학교에서 국어교사가 학생 글에 부여하는 쓰기평가 점수는 그냥 수(數)가 아니다. 단기적으로는 상급 학교 진학에 활용되는 기준이지만, 장기적으로는 쓰기 능력이 낮은 수준임에도 불구하고 중간이나 높은 수준으로 평가받은 학생이 자신의 쓰기 능력이 부족한지도 모른 채 학령기에 방치되어 성인기에 이르러 쓰기 문해력 저하를 겪을 가능성을 원천 배제할 수 없다. 실제 민병곤 외(2018)는 우리 국민의 국어 능력 실태조사에서 국민들의 평

균적인 쓰기 능력은 '2수준'이며, 평균 점수는 250점 만점에 121.61점(만점 대비 48.64%)으로 듣기, 말하기, 읽기, 디지털, 문법 영역의 평가 결과와 비교할 때 가장 낮았다. 또한 쓰기 능력의 신장이 요구되는 2수준과 1수준의 비율이 전체의 69.6%로 우리 국민의 전체적인 쓰기 능력 수준이 낮은 것으로 보고한 결과를 볼 때 이러한 문제 제기는 충분히 가능하다고 판단된다.

이에 본 연구는 국어교사가 평가 전문성을 갖추어 학생의 쓰기능력을 정확히 변별하는 것이 무엇보다 중요하다는 문제의식에 착안해 국어교사의 쓰기평가 전문성 요인인 지식과 수행에 대해 살펴보았다. 쓰기평가 지식 수준에 따라 평가 수행에 차이가 있는지를 분석, 확인한 결과 쓰기평가 지식이 하위 수준인 국어교사들은 상위 수준인 교사에 비해 높은 수준의 글을 낮은 수준으로 평가하거나 혹은 반대로 평가하는 부적합(misfit)이나, 단일한 척도만을 사용하여 쓰기 능력 변별이 잘 이루어지지 않는 과적합(overfit) 평가 경향을 보였다. 또한 평가 요인에 대한 편향 분석에서 상위 집단과 하위 집단이 표현 요인에서 엄격성 차이가 확인되어 조정이 필요했다. 평가 척도 활용에서는 상위 집단에 비해 하위 집단은 평가 척도를 모두 활용하지 못하고, 일부 척도만을 사용해 척도 변별에 어려움을 겪고 있는 것을 확인하였다. 이러한 분석을 종합해 볼 때 쓰기평가 지식은 쓰기평가 수행에 영향을 미치고 쓰기평가 지식 수준이 높을수록 쓰기평가의 정확성이 높아지므로, 쓰기평가 지식 수준이 부족한 교사들에 대한 재교육을 통해 쓰기평가 전문성을 높일 필요가 있다.

이러한 문제를 해결하기 위해서는 우선 국어교사들의 쓰기평가 전문성에 대한 정확한 진단이 선결되어야 한다. 쓰기평가 전문성을 이루는 요인은 다양하지만, 그 중 본 연구에서 변인으로 다룬 쓰기평가 지식과 같은 검사를 통해 국어교사의 전문성 정도를 진단하여 수준에 맞는 처방이 이어져야 한다. 전문적 검사 도구를 사용할 수 없을 경우 쓰기평가 수준 체크리스트를 통해 쓰기평가 전문성에 대한 정도를 확인할 수 있다. 임천택(2005)은 자기 평가를

통한 송환(feedback)은 쓰기 지식을 명료하게 해준다고 보았는데, 평가의 국면에 적용해 보면 국어 교사 역시 피드백 과정을 통해 쓰기평가 지식을 더욱 명료하고 평가 상황을 객관적으로 돌아보게 되어 평가를 점검하고 개선할 수 있다. 피드백의 방법에는 자기 평가 질문지, 체크리스트, 포트폴리오 등 여러 방법이 있지만 격무(激務)에 시달리는 교사들에게 효율적 방안은 체크리스트 방법이다. 체크리스트는 관찰하려는 피험자의 행동을 사전에 분류한 후, 피험자에게 실제로 그러한 행동이 나타났을 때 표시하거나 체크하는 방법이다(Linn & Gronlund, 1995). 체크리스트는 수행 결과에 대한 양적 분석이 용이해 피험자 스스로 자신의 수행 정도를 점검하기 편리하므로, 쓰기평가에 대한 신속하고 효율적인 피드백을 얻기 원하는 교사들을 위해 적절한 방법이라 할 수 있다.

이러한 평가 전문성 점검을 바탕으로 쓰기평가 전문성을 향상할 수 있는 구체적인 프로그램을 운영해야 한다. 프로그램의 운영 주체로 학교 내, 지역사회 대학을 제안하는 바이다. 학교 내에서는 국어교사 쓰기평가 동아리를 주기적으로 운영할 수 있다. 교사 동아리 활동의 장점은 학교 일과에 교사 협의회 시간을 포함하도록 권고하고 있기 때문에 시간 운용을 정례화할 수 있고, 같은 학생을 지도, 평가하는 교사들이 구성원이기에 이미 래포(rapport)가 형성되어 있어 심리적으로 안정적인 상황에서 활동이 이어질 수 있다. 쓰기평가 동아리에서 개인, 조별로 교사들이 평가 도구를 제작, 수정, 평가하고 실제 학생 글 채점 과정을 공유하면서 국어교사 스스로 평가 특성을 탐색하는 과정을 거침으로써 전문성 함양에 대한 기본을 다질 수 있다.

이후 좀 더 전문적인 연수를 위해 지역사회 대학과의 연계 방법이 있다. 국어교사 개인의 노력으로 전문적 교육 프로그램을 찾아 연수를 받는 것에 한계가 있으므로, 교육청별로 지역사회 거점 대학을 정해 쓰기평가 관련 프로그램을 운영하게 하는 것이다. 쓰기평가에 대한 이론적 강의는 원격수업이나 실시간 온라인 강의를 통해 접근성을 높이고, 주말이나 방학 기간 등을 활용

해 평가에 관한 워크숍을 진행하며 지식과 수행이 조화를 이룰 수 있게 하는 것이다. 이 과정에서 예비 국어교사들과의 연계 프로그램을 별도로 운영해 예비 국어교사들은 현직 국어교사들에게 평가에 관한 실제 경험을 배우는 경험을 마련함으로써 교원 양성 과정에서부터 평가에 대한 소양을 갖추게 하는 것도 장기적인 방안이 될 수 있을 것이다.

이 연구는 쓰기평가 지식 집단을 상위, 하위로만 나누었고 표집의 규모가 크지 않아 일반화에는 한계가 있지만, 쓰기평가 지식을 평가 수행과 연결한 실증적인 연구가 부족한 상황에서 쓰기평가 지식 수준에 따라 평가 수행을 분석한 것에 의의가 있다. 후속 연구에서 전문적인 검사 도구 개발을 통해 국어교사의 쓰기평가 전문성을 좀 더 체계적으로 진단하고, 추가 변인을 설정하여 국어교사의 쓰기평가 특성을 살펴볼 것을 제안하는 바이다.

쓰기평가가 인지적 부담이 큰 활동인 것은 분명하지만, 학교 현장에서 국어교사만이 할 수 있는 전문적 영역이기에 평가의 신뢰성을 확보하기 위한 다양한 논의는 계속되어야 한다.

참고문헌

김선정(2006), 국어교사의 쓰기 교수 전문성 준거 설정 기초 연구, 작문연구 3, 작문학회, 139-168.

남명호(2002), 수행평가 :기술적 측면, 교육과학사.

민병곤 외(2018), 2018년 국민의 국어 능력 실태조사, 연구보고서, 국립국어원.

박영민(2012ㄱ), 쓰기 평가 지식 측정을 위한 검사 도구 개발 연구, 청람어문교육 46, 청람어문학회, 29-46.

_____(2012ㄴ), 예비국어교사의 중학생 논설문 평가에서 발견되는 엄격성 및 일관성의 특성, 국어교육학연구 43, 국어교육학회, 253-283.

_____(2013), 현직 국어교사와 예비 국어교사의 쓰기평가 지식의 차이 분석, 작문연구 19, 작문학회, 331-352.

박영민, 최숙기(2010ㄱ), 중학생 논설문 평가의 모평균 추정과 평가 예시문 선정, 국어교육 131, 한국어교육학회, 437-461.

_____(2010ㄴ), Rasch 모형을 활용한 국어교사의 쓰기평가 특성 분석 -중학생 설명문 쓰기평가를 중심으로-, 국어교육학연구 37, 국어교육학회, 367-391.

박종임(2013), 국어교사의 쓰기평가 특성 연구, 한국교원대학교 대학원 박사학위논문.

박종임, 박영민(2011), Rasch 모형을 활용한 국어교사의 채점 일관성 변화 양상 및 원인 분석 -중학생 서사문 채점을 중심으로-, 우리어문연구 39, 우리어문학회, 301-335.

백유진(2020), 논설문 채점에 나타난 국어 교사의 채점 편향의 특성 분석 - 텍스트 특징에 따른 채점 편향, 청람어문교육 76, 청람어문학회, 67-101.

백유진, 박영민(2021), 중학생 논설문 평가에 나타난 예비국어교사의 평가 특성 분석, 학습자중심교과교육연구 21(1), 학습자중심교과교육학회, 1119-1146.

설현수(2010), 평정자간의 엄격성 차이정도가 피험자 총점산출 방법에 미치는 영향: 원점수, 표준점수, Facet 점수 비교, 교육평가연구 23(1), 한국교육평가학회, 125-147.

안수현, 김정숙(2017), 한국어능력시험(Topik) 쓰기 평가의 채점 특성 연구, 한국어교육 28(1), 국제한국어교육학회, 173-196.

이성영(2005), 국어과 교사의 쓰기 영역 평가 전문성 기준과 모형, 국어교육 117, 한국어교육학회, 353-376.
이은정(2020), 국어교사의 쓰기평가 지식 차이 분석 -성별,학교급,경력을 중심으로, 작문연구 47, 작문학회, 7-41.
이인혜(2014), 한국어 교사의 쓰기평가 효능감과 평가 특성 연구, 이중언어학 56, 이중언어학회, 231-266.
이현숙(2008), 다국면 라쉬모형을 적용한 논술 채점 상황에서 채점 설계 및 채점자 특성이 채점의 정확성에 미치는 효과, 교육평가연구 21(4), 한국교육평가학회, 129-152.
임천택(2005), 국어교육 쓰기 지식 생성을 위한 자기 평가의 교육적 함의, 새국어교육 71, 한국국어교육학회, 285-310.
장소영, 신동일(2009), 언어교육평가 연구를 위한 FACETS 프로그램, 글로벌콘텐츠.
장은섭(2015), 쓰기평가에 대한 국어교사의 인식 및 실태 조사 연구, 국어교육 150, 한국어교육학회, 329-358.
전형길, 이인혜(2017), 한국어 교사의 쓰기평가 문식성 연구, 이중언어학 69, 이중언어학회, 213-248.
지은림, 채선희(2000), Rasch 모형의 이론과 실제, 교육과학사.
최연희(2002), 채점자 훈련이 영어 작문 채점에 미치는 효과에 대한 연구 FACETS 분석을 통한 신뢰도 변화 분석, 응용언어학 18(1), 이중언어학회, 257-292.
Crusan, D., Plakans, L., Gebril, A.(2016), Writing assessment literacy: Surveying second language teachers' knowledge, beliefs, and practices, Assessing Writing 28, 43-56.
Eckes, T.(2012), Operational rater types in writing assessment: a classification approach to rater variability, Language Testing 25, 155-185.
Engelhard, G.(1994), Examining Rater Errors in the Assessment of Written Composition with a Many-Faceted Rasch Model, Journal of Education Measurement 31(2), 93-112.
Linacre, J. M.(1989), Many-facet rasch measurement. Chigo: MESA Press.
Linacre, J. M.(2019), A User's Guide to FACETS: Rasch-Model Computer Program, IL: Winsteps.com.
Linn, R. L. & Gronlund, N. E.(1995), Measurement and assessment in teaching(7th

ed), Prentice-Hall, Inc.

Malone, M. E.(2013), The essentials of assessment literacy : Contrasts between teachers and users, Language Testing 30(3), 329-344.

McNamara, T. F.(1996), Measuring second language performance. New York ; Addison Wesley Longman Ltd.

Saddler, B. & Graham, S.(2007), The relationship between writing knowledge and writing performance among more and less skilled writers, Reading & Writing Quarterly 23, 231-247.

Stiggins, R. J.(2002), Assessment crisis: The absence of Assessment for Learning, The Phi Delta Kappan 83(10), 758-765.

Weigle, S. C.(2007), Teaching writing teachers about assessment, Journal of Second Language Writing 16(3), 194-209.

Wright, B. D., & Stone, M. A.(1979), Best Test Design. Chigo: MESA Press.

국문초록

다국면 Rasch 모형을 활용한 국어교사의 쓰기평가 지식 수준에 따른 평가 수행 차이 분석

이은정(한국교원대학교)

이 연구의 목적은 국어교사의 쓰기평가 지식 수준에 따른 평가 수행 차이를 분석하여, 국어교사의 전문성 향상 방안을 모색하는데 목적이 있다. 연구 결과는 다음과 같다.

첫째, 쓰기평가 지식 상위 집단일수록 평가 수행에서 엄격성의 일관성을 유지하며, 쓰기평가 지식 하위 집단은 부적합이나 과적합의 평가 경향을 보였다.

둘째, 평가 요인 중 문장의 명료성 요인을 평가할 때 쓰기평가 지식 상위 집단과 하위 집단의 엄격성의 차이가 발견되어 조정이 필요했다.

셋째, 평가 척도 활용에서 쓰기평가 지식 하위 집단은 상위 집단에 비해 평가 척도 변별을 적절하게 하지 못하고 일부 척도만을 사용하였다.

이를 종합하면 쓰기평가 지식 수준이 높을수록 채점 수행에서 엄격성을 일관되게 유지하고 평가 요인과 평가 척도 활용을 적절하게 사용하므로, 쓰기평가 지식 수준이 부족한 교사들에 대한 재교육이 필요하다.

쓰기평가 전문성 향상 방안으로는 정확한 쓰기평가 지식 검사 도구로 국어교사들의 쓰기평가 전문성을 진단하고, 국어교사 쓰기평가 동아리 운영, 지역사회 대학을 활용한 쓰기평가 프로그램 운영을 제안하였다.

주제어 : 다국면 Rasch 모형, 쓰기평가 지식, 평가 수행, 쓰기평가 전문성

Abstract

An Analysis of Differences in the Assessment Performance Considering the Knowledge Level of Korean Language Teachers' Writing Assessment Using the Many-Facets Rasch Model

Lee Eunjeong(Korea National University of Education)

This study analyzed differences in the assessment performance considering the knowledge level of Korean language teachers' writing assessment. The following results were found.

First, the higher the writing assessment knowledge group, severity, and consistence were maintained in the assessment performance, whereas, the lower group showed a tendency of assessment of misfit or overfit.

Second, in the assessment factor performance analysis, there was a difference in the severity of the writing assessment knowledge found between the groups for the clarity of sentences.

Third, as for the use of the assessment scale, the lower group did not discriminate properly the assessment scale compared to the higher group.

In conclusion, it was suggested to diagnose accurate writing assessment expertise, operate a writing assessment club, and use a writing assessment program at a community college.

Keywords : Many–Facets Rasch Model, writing assessment knowledge, assessment performance, writing assessment expertise

이 논문은 2021년 3월 27일에 투고 완료되어 2021년 3월 29일 편집위원회에서 심사위원을 선정한 뒤 2021년 4월 10일까지 심사를 완료하여 2021년 4월 23일 편집위원회에서 게재가 결정된 논문임.