creative commons

COMMONS DEED

저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:

저작자표시. 귀하는 원저작자를 표시하여야 합니다.

비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.

변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

석사학위논문

평가자 변인에 따른 채점-재채점 신뢰도 분석

한국교원대학교 대학원

국 어 교 육 전 공

최 미 영

2022년 2월

평가자 변인에 따른 채점-재채점 신뢰도 분석

지도교수 박 영 민

이 논문을 교육학 석사학위 논문으로 제출함

한국교원대학교 대학원

국 어 교 육 전 공

최 미 영

2022년 2월

최미영의

교육학 석사학위 논문을 인준함

심사위원장 박 형 우 인

심 사 위 원 최 숙 기 인

심 사 위 원 박 영 민 인

한국교원대학교 대학원

2022년 2월

차 례

논문 요약 ····· v

Ⅰ. 서론 ····· 1

1. 연구의 필요성 및 목적 ····· 1
2. 선행 연구 검토 ····· 3
3. 연구 문제 및 제한점 ····· 8

Ⅱ. 이론적 배경 ····· 10

1. 쓰기평가의 특성 ····· 10
2. 쓰기평가 신뢰도 ····· 12
3. 쓰기 평가자의 평가 특성 ····· 14

Ⅲ. 연구 방법 ····· 19

1. 연구 대상 ····· 19
2. 검사도구 ····· 20
3. 연구 절차 ····· 25
4. 분석도구 ····· 30

Ⅳ. 연구 결과 및 논의 ····· 31

1. 전체 채점 결과 ····· 31
2. 채점, 재채점 기술통계 ····· 35
3. 평가자별 채점-재채점 신뢰도 ····· 38
4. 일관성 유형에 따른 채점-재채점 신뢰도의 차이 ····· 40
5. 쓰기평가 효능감에 따른 채점-재채점 신뢰도의 차이 ····· 61
6. 경력 및 성별에 따른 채점-재채점 신뢰도의 차이 ····· 65

Ⅴ. 결론 ····· 68

참 고 문 헌 ····· 73
ABSTRACT ····· 80
부록 차례 ····· 86

표 차 례

<표 Ⅲ-1> 연구 대상 분포 ····· 19
<표 Ⅲ-2> 학생 쓰기 과제 ····· 20
<표 Ⅲ-3> 채점 기준표 ····· 23
<표 Ⅳ-1> 1차 채점 기술통계 ····· 31
<표 Ⅳ-2> 2차 채점 기술통계 ····· 33
<표 Ⅳ-3> 학생 글 채점, 재채점 결과 ····· 35
<표 Ⅳ-4> 평가자별 채점, 재채점 결과 ····· 36
<표 Ⅳ-5> 평가자별 채점-재채점 상관계수 ····· 38
<표 Ⅳ-6> 채점-재채점에서의 평가자 엄격성 및 일관성 비교 ····· 47
<표 Ⅳ-7> 채점-재채점 일관성에 따른 평가자 유형 분류 ····· 52
<표 Ⅳ-8> 일관성 유형에 따른 채점-재채점 기술통계와 상관계수 ····· 53
<표 Ⅳ-9> 평가자 일관성 유형에 따른 채점-재채점 신뢰도 ····· 55
<표 Ⅳ-10> 평가자별 쓰기평가 효능감 검사 문항의 기술통계 ····· 62
<표 Ⅳ-11> 쓰기평가 효능감 수준에 따른 채점-재채점 신뢰도 ····· 63
<표 Ⅳ-12> 경력에 따른 채점-재채점 신뢰도 ····· 65
<표 Ⅳ-13> 성별에 따른 채점-재채점 신뢰도 ····· 67

그 림 차 례

<그림 Ⅲ-1> 연구 과정 ····· 25
<그림 Ⅳ-1> 1차 채점 결과의 모형 적합도 검사 결과 ····· 41
<그림 Ⅳ-2> 2차 채점 결과의 모형 적합도 검사 결과 ····· 42
<그림 Ⅳ-3> 1차 채점 결과의 측정단면분포도 ····· 43
<그림 Ⅳ-4> 2차 채점 결과의 측정단면분포도 ····· 45

논 문 요 약

평가자 변인에 따른 채점-재채점 신뢰도 분석

최 미 영

한국교원대학교 대학원 국어교육 전공
(지도교수 박 영 민)

국어교육에서 쓰기 직접 평가는 학생들의 쓰기 능력 진단과 발달을 위해 중요한 의미를 갖는다. 따라서 국어교사에게는 쓰기 직접 평가를 위해 쓰기평가에 관한 지식과 효능감을 고루 갖추고 타당하고 신뢰할 수 있는 쓰기평가를 하는 전문성이 요구된다. 하지만 쓰기 채점 시 채점자가 주관성 개입 문제를 극복하고 글에 점수를 부여하는 경향을 지속적으로 일정하게 유지하는 채점 일관성을 갖는 데에는, 집중도 하락이나 피로도 증가, 채점 척도와 기준 활용의 차이 등으로 인해 어려움이 따른다. 따라서 채점 일관성 정도를 판단하고 이를 향상시킬 수 있는 방안을 모색하는 일은 중요하다.

이러한 문제의식에 기초하여, 이 연구에서는 쓰기평가에서의 채점자 내 일관성을 채점-재채점 신뢰도 분석을 통해 실증적으로 확인하고자 한다. 평가자 일관성 유형과 쓰기평가 효능감 수준 그리고 배경요인에 해당하는 경력과 성별 등을 변인으로 하여 채점-재채점 신뢰도를 분석, 쓰기평가자의 평가 특성을 통해 채점 일관성 신장 방안을 모색하였다.

이 연구에서는 30명의 평가자를 대상으로 하여 총 2회에 걸쳐 쓰기 채점을 시행하였다. 성별을 기준으로 하면 남교사 12명(40.00%), 여교사 18명(60.00%), 경력을 기준으로 하면 5년 미만 4명(13.33%), 5년 이상~10년 미만 14명(46.67%), 10년 이상~15년 미만 9명(30.00%), 15년 이상 3명(10.00%)으로 총 30명의 국어

교사를 대상으로 하였다. 평가자들은 7개 평가 요소로 이루어진 6점 척도의 채점 기준표에 따라, 논설문 쓰기 과제를 수행한 고등학교 2학년 학생의 글을 채점하였다. 1, 2차 채점 시기에 각각 35편의 학생 글을 채점하였고, 그 중 20편에 해당하는 학생 글은 1, 2차 채점 시기에 동일하게 주어져 차후 채점-재채점 신뢰도 분석의 대상으로 삼았다. 또 평가자 요인 검사지, 쓰기평가 효능감 검사지가 투입되었고, 일부 평가자를 대상으로 심층 면담이 실시되었다.

기술통계 분석을 통해 1, 2차 채점 결과를 정리하고, 그 중 채점-재채점 신뢰도 분석의 대상이 되는 학생 글 20편에 대한 기술통계를 따로 분석하였다. 평가자 일관성 유형에 따른 채점-재채점 신뢰도 분석을 위해, 채점 결과에 대한 모형 적합도 검사 후 다국면 Rasch 모형을 통해 분석한 채점 일관성과 엄격성의 특성을 서술하였다. 채점 일관성 유형에 따라 집단을 1~6으로 분류하고, 그 중 특징적인 일관성 유형을 보여주는 집단인 1, 4, 6에 해당하는 평가자의 채점-재채점 신뢰도를 분석하였다. 또 쓰기평가 효능감 수준에 대해 서술한 후 효능감 수준에 따른 채점-재채점 신뢰도 차이를 분석하고, 경력과 성별에 따른 차이도 분석하였다. 서술과정에서 평가자와의 심층 면담 내용을 인용하고, 평가자 요인 검사지에 나타난 쓰기평가 연수 경험과 쓰기 직접 평가 경험에 관한 내용을 활용하여 채점 일관성 향상을 위한 방안을 모색하였다. 이러한 과정을 통해 얻은 결론은 다음과 같다.

첫째, 평가자별로 채점 일관성을 분석한 결과, 채점-재채점 신뢰도가 대체로 확보된 것으로 나타났다. 상관분석을 통해 얻은 상관계수가 폭넓게 분포하여 평가자마다 정도의 차이는 있으나, 중간 정도의 상관관계를 보인 평가자가 9명, 높은 상관관계를 보인 평가자가 18명으로 이는 적절한 수준의 채점 일관성을 유지하는 평가자가 다수 있음을 의미한다.

둘째, 평가자 엄격성과 일관성을 분석한 결과, 평가자 개인마다 엄격성 수준에 편차가 있음이 나타났다. 전반적으로 엄격한 평가자보다 관대한 평가자가 많았고, 채점과 재채점에서 서로 다른 엄격성 수준을 보이는 평가자도 있었다. 이러

한 엄격성의 차이는 쓰기평가의 신뢰도에 문제를 가져올 수 있음을 의미한다.

셋째, 일관성 유형에 따라 평가자를 분류한 결과, 전체 평가자 중 1/3의 비율에 해당하는 평가자가 채점과 재채점에서 모두 채점 일관성을 적절히 유지하는 편이었으나, 마찬가지로 1/3에 해당하는 평가자들은 채점과 재채점에서 모두 과적합하거나 또는 부적합한 양상을 보이기도 했다. 이는 쓰기평가에서 평가자의 채점 일관성 신장이 필요하다는 것을 시사한다.

넷째, 평가자의 일관성 유형에 따른 채점-재채점 신뢰도를 분석한 결과, 채점과 재채점에서 모두 적합한 일관성을 보인 집단의 경우 대부분 높은 상관관계 또는 중간 정도의 상관관계를 보였다. 하지만 일관성 유형에 따라 채점-재채점 신뢰도가 일관된 경향을 보인다고 볼 수는 없었고, 쓰기평가의 경험이나 연수 등에 따라 달라지는 측면이 있음을 심층 면담을 통해 알 수 있었다. 이는 쓰기평가에 관한 채점자 훈련이 요구됨을 의미한다.

다섯째, 평가자의 쓰기평가 효능감에 따른 채점-재채점 신뢰도를 분석한 결과, 효능감 수준에 따른 일관된 경향은 뚜렷하지 않았으나 대체로 효능감 수준이 높은 평가자가 채점-재채점 신뢰도의 수준도 높은 경우가 많았다.

여섯째, 평가자의 경력과 성별에 따라 채점-재채점 신뢰도를 분석한 결과, 일반화할 수 있는 경향은 발견하지 못했으나 주로 5년 이상~10년 미만의 경력에 속하는 평가자가 높은 정도의 상관관계를 보이는 비율이 높았다. 또 남교사의 경우에 낮은 정도의 상관관계를 보이는 정도가 높은 편이었다.

일곱째, 쓰기 평가자의 채점 일관성을 신장시키기 위해서는 쓰기평가 지식 습득과 실제 채점이 이루어지는 채점자 훈련, 피드백을 통한 자기 성찰 기회 부여 등이 필요함을 알 수 있었다.

이 연구는 국어교사를 대상으로 두 차례의 쓰기 직접 평가를 실시하여 채점-재채점 신뢰도를 분석하였고 이를 통해 채점 일관성을 실증적으로 확인하였다는 점, 채점 결과를 바탕으로 평가자의 채점 일관성 유형, 쓰기평가 효능감, 경력과 성별에 따른 채점-재채점 신뢰도 차이를 확인하여 평가자 특성을 분석, 평가자

요인을 고려하고 심층 면담을 통해 채점 일관성 신장 방안을 모색했다는 점, 이를 통해 쓰기평가에서의 채점 일관성 연구에 실증적 자료를 제공한다는 점에서 의의가 있다.

주요어 : 쓰기평가, 채점-재채점 신뢰도, 평가자 일관성, 쓰기평가 효능감, 다국면 Rasch 모형

※ 이 논문은 2022년 2월 한국교원대학교 대학원위원회에 제출된 교육학 석사학위 논문임.

Ⅰ. 서론

이 장에서는 평가자 변인에 따른 채점-재채점 신뢰도를 분석하는 연구의 필요성과 목적에 대해 논의하고자 한다. 쓰기평가 신뢰도와 쓰기 평가자의 특성에 관한 선행 연구를 검토하고, 논의할 연구 문제와 제한점, 의의에 대해 살펴보고자 한다.

1. 연구의 필요성 및 목적

쓰기평가는 학생의 쓰기 능력 진단과 함께 쓰기 능력 발달을 목적으로 한다는 점에서 국어교육에서 중요한 위치를 차지한다. 유창하게 글을 쓰기 위한 사고 과정, 쓰기 관습에 대한 이해, 아이디어의 생성이나 계획, 수정과 같은 쓰기 기능과 전략들을 제대로 측정하고 그것이 가능하게 된 요인을 분석하고 해석하여 피드백을 하는 일은 고도의 전문성을 요한다. 특히 쓰기 직접 평가의 경우 학생들이 실제로 글을 생산해 내는 과정에서 쓰기 능력의 다양한 측면을 활용하게 한다는 점에서 타당성을 갖는 방식이다. 그렇기 때문에 학생의 쓰기 능력을 직접 평가하는 능력은 국어교사에게 요구되는 필수적 소양 중 하나라 할 수 있다.

국어교사에게 쓰기평가는 가장 주된 교육 활동 중 하나이지만 분량, 인지 부담 등으로 인한 어려움을 겪을 수밖에 없다. 채점자가 채점 기준과 채점 척도를 해석하고 학생 글 채점에 이를 적용하는 과정에서 개입되는 채점자의 주관성은 쓰기평가의 신뢰도 문제를 가져온다. 자동 채점의 가능성이 연구되고 있으나 여전히 인간 채점자의 역할과 가치는 중요하며, 평가의 신뢰도를 확보하기 위해 인간 채점자가 가진 주관성 문제를 극복하는 것은 쓰기평가의 주요 사안이다.

채점자 일관성은 평가자가 글에 점수를 부여하는 경향이 지속적으로 일정하게 유지되는 것을 의미한다. 이러한 경향은 평가자가 글을 채점할 때 항상 동일한

수준의 엄격성을 가지는 것을 기본으로 한다(박종임·박영민 2012). 평가자가 가진 주관성과 더불어 채점 분량 증가(Lunz & Stahl 1990, 박종임·박영민 2011, 장미 2020, 조윤정·양명희 2018, 정분의 2019 등)로 인한 집중도 하락이나 피로도 증가의 영향, 채점 척도나 채점 기준 활용의 차이 또는 채점자 개인적 특성과 채점 절차 특성(McNamara 2000) 등의 영향으로 항상 동일한 수준의 엄격성을 가지는 것은 어려운 일이다. 하지만 채점 일관성이 확보되지 않으면 평가 신뢰도에 문제가 발생한다. 따라서 동일 수준의 엄격성을 갖고, 정해진 채점 기준과 척도를 지속적으로 일정하게 적용하는 것은 국어교사에게 요구되는 필수적이고 전문적인 소양이라 할 수 있다.

따라서 채점자 일관성 정도를 판단하고 이를 높이는 방향을 모색하는 일은 중요하다. 채점자 내 신뢰도는 한 명의 채점자가 시간차를 두고 한 편의 글을 반복적으로 채점했을 때, 이 두 번의 채점 결과가 얼마나 일치하는가를 의미한다(박영민 외 2016). 쓰기평가에서의 검사-재검사 신뢰도인 채점-재채점 신뢰도는 동일한 채점자가 다른 조사 시점에서 채점한 결과가 일치하는 정도를 말해준다. Rasch모형 분석을 통해 얻어지는 채점자의 일관성은 채점자가 여러 학생 글을 채점할 때 동일한 엄격성을 유지하는지를 말해준다. 하지만 앞서 말한 채점자 내 신뢰도를 확인하기 위해서는, 개발된 측정도구를 조사 대상이 되는 집단에서 일부를 표본으로 뽑아서 일정한 시간을 두고 채점을 실시한 후 두 채점 결과 간의 일치도(상관관계)를 확인해야 한다.

하지만 채점-재채점 신뢰도를 분석하여 채점 일관성을 실증적으로 논의한 연구는 쓰기평가에서 매우 부족하다. 여기에는 두 채점 사이에 일어날 수 있는 여러 예상치 못한 변인들에 대한 통제의 어려움, 채점의 기간과 채점의 분량으로 인한 채점자의 부담 등의 요인이 영향을 미쳤을 것으로 보인다. 쓰기 채점에서 채점자 신뢰도를 신장시키기 위한 실효성 있는 채점자 교육 방법이 제안되기 위해서는 먼저 채점자 내 신뢰도를 실증적으로 확인하여 그 수준과 특성을 분석할 필요가 있다. 따라서 평가자의 일관성 유형, 쓰기평가 효능감, 쓰기 평가자가 갖

고 있는 배경요인 등에 따른 차이를 분석함으로써 쓰기평가에서의 채점자 내 신뢰도에 관한 정보를 제시하고자 한다. 쓰기평가에서의 이러한 연구 결과들이 축적되어야 쓰기평가에서 채점자인 국어교사의 채점 일관성을 진단하고, 그에 맞는 채점자 교육이 가능해진다. 또한 채점 일관성 수준에 대한 피드백을 통한 성찰 및 적정 채점자 변별에 도움을 줄 수 있다. 평가자 변인에 따른 채점-재채점 신뢰도 분석을 통해 국어교사의 쓰기평가 신뢰도를 높이기 위한 방안 마련에 기여할 수 있기를 기대한다.

2. 선행 연구 검토

그동안 쓰기평가에서 채점자의 신뢰도를 고려할 때, 주로 채점자 간 일치도를 높이는 방향에 대해 고민해 왔다. 하지만 채점자 간 일치도를 확인하기에 앞서 채점 일관성이 확보되지 않은 평가자를 제외하는 것이 우선되어야 하기 때문에 채점자 각각의 채점 일관성을 확보하는 것도 중요하다. 채점자의 채점 일관성 확보에 관한 실증적 연구는 부족한 편이지만, 쓰기평가에서의 평가자 변인에 따른 채점-재채점 신뢰도를 분석하기 위해서 본 연구와 관련된 몇몇 연구들에 대해 살펴보면 다음과 같다.

먼저 이혜원·이경원(2014)의 어음청각검사 어표의 검사-재검사 신뢰도 분석, 나은진·송창순(2018)의 신체인식척도 검사-재검사 신뢰도 분석, 허소희·진인기(2019)의 한국어 이명주요기능 설문지의 검사-재검사 신뢰도 분석, 이재창 외(2017)의 주의력 네트워크 검사에 대한 검사-재검사 분석 연구 등은 의학 분야에서 이루어진 검사-재검사 신뢰도 연구이다. 이러한 연구들은 주로 검사 도구의 안정성을 확인하기 위한 목적에서 이루어졌다. 신문자·이희란(2017), 정수정·최나야(2018)는 검사 도구의 표준화를 위해 안정성을 확인하는 피험자 대상의 검사-재검사를 실시하기도 했다.

지은림(2008)은 채점자 특성을 확인하기 위한 검사-재검사 신뢰도 연구로, 논

술고사의 신뢰성에 영향을 미치는 채점자 특성을 알기 위해 2회 실시된 동형의 논술고사에 대해 채점자 집단이 보인 신뢰도를 분석했다. 전문가 집단의 경우 엄격성과 적합성에서 비전문가보다 안정성이 있게 나타났다. 1차와 2차 평가에서의 엄격성, 적합성 측정치를 상관분석(Pearson r과 Spearman rho)한 결과 전문가 집단의 엄격성 상관계수 r은 .246, rho는 .400이었으나 비전문가 집단은 각각 -.194, -.152였고, 전문가 집단의 적합도 상관계수 r은 .425, rho는 .341이었으나 비전문가 집단은 각각 -.381, -.551이었다. 전문가 집단의 일관성이 비전문가 집단보다 더 높았고, 비전문가 집단은 오히려 부적상관을 보인 것이다. 이는 논술 채점에서 신뢰도를 유지하기 위해서는 전문성을 갖춘 채점자를 확보하는 것이 중요하고 이를 위한 채점자 훈련이 필요함을 의미한다.

조윤정·양명희(2018)는 한국어 말하기 평가에 대한 검사-재검사 신뢰도 분석 연구에서 3개의 말하기 과제에 대해 동일한 채점자가 2회의 채점을 시간 간격(1주일)을 두고 실시했다. 전체적으로 1차 채점보다 2차 채점에서 엄격성의 차이가 줄어 신뢰도가 향상되었으나 일관성 면에서는 다양한 양상을 보여 채점자 내 신뢰도가 확보되지 않았음을 보였다. 또 채점자의 한국어 교육 경력과 관계없이 채점 일관성 양상이 다르게 나타났다는 점에서, 평가자 개인의 특성에 맞는 채점자 훈련이 요구됨을 시사했다. 채점자의 주관이 반영될 가능성이 높은 말하기 평가임에도 개별화된 채점 훈련이 지속적으로 이루어지지 못하는 측면에 대안이 필요함을 의미한다.

윤금준(2021)은 국어교사의 쓰기평가 일관성 유형에 따른 채점-재채점 신뢰도 분석을 실시했다. 이는 쓰기평가에서 최근 이루어진 채점-재채점 신뢰도 연구로, 고등학교 국어교사를 대상으로 학생 글에 대해 채점-재채점을 실시한 결과 채점-재채점 모두 평가자 내 신뢰도를 유지한 경우는 25.00%, 두 번의 채점 중 한 번만 적합한 경우는 52.78%로 나타났다. 또 평가자의 일관성이 적합한 집단의 경우 채점-재채점 신뢰도가 높았으나, 과적합 양상을 보인 집단의 경우엔 채점-재채점 신뢰도가 높더라도 채점과 재채점에서의 엄격성이 상이했다. 이는 평가

자의 신뢰도 분석을 위해서는 채점-재채점 신뢰도와 평가자의 엄격성을 함께 고려해야 함을 의미한다.

Congdon & McQueen(2000)은 평가자의 엄격성 변화를 분석하기 위해 검사-재검사를 실시하였다. 초등학생 쓰기 평가에서 16명의 평가자들이 보인 8일 간의 엄격성 변화와, 동일 검사지를 8일 후 재채점 했을 때의 엄격성 변화를 통해 평가자들이 보이는 채점 엄격성 차이를 밝혔다. 16명의 평가자 중 10명의 평가자의 경우, 마지막 날의 엄격성 정도가 첫날의 엄격성과 크게 다르게 나타났다. 이는 평가자의 엄격성이 일관되게 유지되지 않을 수 있다는 결과를 보여주었다.

다음으로 평가자 특성에 영향을 미칠 수 있는 쓰기평가 효능감이나 경력, 성별과 같은 배경요인, 그 외 쓰기평가 요인에 관한 선행 연구들을 살펴보고자 한다.

박영민·최숙기(2010, 2011)는 국어교사의 쓰기평가 특성을 분석하기 위해 각각 중학생 설명문과 논설문에 대해 평가자의 성별에 따른 평가의 일관성과 엄격성을 분석하였다. 두 연구에서 모두 평가자의 일관성에는 성별에 따른 차이가 없었으나 엄격성에 있어 여교사가 남교사보다 엄격한 경향을 보였다. 이는 현직 국어교사와 예비 국어교사의 쓰기평가를 비교한 박영민·최숙기(2009)에서도 유사하게 나타났다.

장은주(2015)는 고등학교 논설문 평가에 관한 연구에서 성별과 같은 배경요인이 평가자 유형별 특징에서 뚜렷한 대비를 보인다고 보지 않았고, 정미경(2011)는 중학생 설명문 평가에서 남교사가 여교사에 비해 더 엄격하게 평가하는 경향이 있다고 보았다. 하지만 성별에 따른 모형적합도 분석에서 외적합 지수가 0.93~1.07에 분포하여 남교사와 여교사 모두 내적 일관성은 안정적으로 유지되는 것을 확인했다.

경력에 따른 평가자의 특성 차이를 논의한 연구들 중 박영민·최숙기(2010, 2011)에서는 각각 중학생 설명문과 논설문에 대한 평가에서 경력에 따른 엄격성 차이를 설명했다. 먼저 박영민·최숙기(2010)는 1~5년 경력의 국어교사가 엄격성이 가장 높고, 20년 초과의 경력을 지닌 경우 가장 관대하게 평가하는 것을 밝

혔다. 박영민·최숙기(2011)에서도 1~5년의 경력 집단의 엄격성이 0.08로 다른 경력 집단에 비해 통계적으로 유의한 차이를 보였고, 경력이 증가할수록 학생 글을 관대하게 평가하는 경향을 확인했다.

장은주(2015)는 경력이 평가자 유형별 특징에 뚜렷한 대비를 보이지는 않았으나 5년 미만인 국어교사가 부적합 평가자 비율이 가장 높고, 5~15년 경력의 경우 적합한 평가자 비율이 가장 높았기에, 신규 교사의 채점 일관성 유지를 위한 쓰기평가 교육 기회가 필요함을 밝혔다.

이러한 선행 연구들로 미루어볼 때 평가자의 성별이나 경력 요인은 평가의 일관성과 엄격성에 어느 정도 영향을 미치고 있음을 알 수 있다. 성별의 경우 통계적으로 유의한 차이를 뚜렷하게 보이거나 일관된 경향성을 갖는다고 일반화할 수는 없지만, 성별이나 경력 등 평가자 변인에 따른 평가 특성을 분석하여 평가 신뢰도를 확보하기 위한 방안을 모색하는 일은 중요한 것으로 보인다.

교사의 자기 효능감은 교육 활동의 여러 측면에서 직·간접적인 영향을 미친다. 쓰기평가 맥락에서 교사의 쓰기평가 효능감 역시 쓰기평가 활동을 긍정적으로 이끄는 역할을 할 것이라 보고 이에 관한 연구들이 있어왔다. 그 중 쓰기평가 효능감에 따른 평가자의 평가 특성에 대해 다룬 연구들이 있다.

이인혜(2014)는 한국어교사의 쓰기평가 효능감과 평가 특성에 대해 분석하였다. 쓰기평가 효능감이 높은 집단과 낮은 집단의 엄격성 편향의 정도는 '내용 및 과제 수행', '전개 구조' 범주에서는 통계적으로 유의한 차이를 보이지 않았고, '언어 사용' 범주에서 통계적으로 유의한 차이를 보였다. 또 일관성이 적합한 집단이 그렇지 못한 집단보다 쓰기평가 효능감 평균이 높았고 통계적으로 유의한 차이를 보였다. 쓰기평가 효능감이 채점 엄격성 측면에는 전반적으로 영향을 미친다고 볼 수는 없으나, 쓰기평가 효능감과 쓰기평가 능력 사이에 어느 정도의 유의미한 상호작용은 이루어진다는 점을 알 수 있다.

장은주(2015)도 쓰기평가 효능감의 차이와 채점 일관성 유지 여부와 통계적으로 유의한 관계를 보이지는 않음을 밝혔다. 하지만 자아효능감이 개인의 행동에

긍정적 영향을 미치듯 쓰기평가 효능감과 같은 정의적인 요인이 국어교사의 평가 행위에 영향을 미치기 때문에 이에 대한 고려가 필요하다고 하였다.

백유진(2018)는 평가자 간 쓰기평가 효능감 수준의 차이를 분석하였다. 쓰기평가 효능감 수준이 가장 높은 집단의 경우 엄격하게 채점하는 경향이 발견되었으나 이를 일반화할 일정한 경향이나 유의한 관련성은 없었다. 하지만 쓰기평가 효능감이 평가에 대한 평가자의 태도에 영향을 미치는 것으로 보여 다른 변인들과의 영향 관계를 지속적으로 탐구할 필요를 논했다.

이외 쓰기평가나 쓰기평가 연수 경험, 쓰기평가 기준에 대한 인식을 평가자 요인으로 두고 분석한 연구도 있다. Huot(1993)는 쓰기평가 경험이 많고 쓰기 채점자 훈련도 받은 유능한 채점자 집단과 그렇지 못한 미숙한 채점자 집단이 글을 채점하는 동안 수행한 사고구술 프로토콜을 분석한 결과, 채점 전략과 채점 기준에 대한 내면화에 차이를 밝혔다. 두 집단 모두 글의 내용과 조직을 가장 중요하게 여겼으나 유능한 채점자 집단의 경우 학생 글에 대한 다양한 논평을 보였고, 좋은 글의 특성을 분명히 인식하고 유창한 읽기를 보였다.

장은주(2015)는 평가자 유형별 쓰기평가 경험을 살펴본 결과 적합한 평가자보다 과적합, 부적합 평가자 집단에서 쓰기평가 경험이 많다는 반응이 더 높다는 것을 밝혔다. 이는 쓰기평가 경험에 대한 판단이 주관적이기 때문에 그 빈도나 정도에 대한 해석이 달라서일 수도 있으나, 과적합 평가자 집단의 평균 교육 경력이 실제로 2년 정도 높았기에 실제로 쓰기평가 경험이 많다고 해도 채점 일관성을 적절히 유지하지 못할 수 있다고 보인다. 한편 적합한 평가자 집단의 경우 교사로 근무하면서 국어과 평가 연수를 이수한 비율이 가장 높았다. 따라서 쓰기 평가자로서 국어교사는 실제 쓰기 직접 평가를 지속적이고 반복적으로 수행하며 채점 일관성을 유지할 수 있도록 전문성을 발전시키기 위한 노력이 요구된다는 것을 알 수 있다.

Eckes(2008)는 쓰기평가에서 평가자의 평가 기준의 중요성 인식에 따라 평가자 유형을 분류하였다. 평가자 기준 9가지를 제시한 후, 중요하게 여기는 평가

기준이 무엇인지에 따라 6가지의 평가자 유형을 분류했다. 이후 Eckes(2012)는 평가 기준에 대한 평가자의 인식 뿐 아니라 쓰기평가에서 보이는 엄격성 정도를 함께 분석하여 평가자 유형을 분류하였고, 중요하다고 여기는 평가 기준을 더 엄격하게 평가하는 경향을 밝혔다.

3. 연구 문제 및 제한점

이 연구는 국어교사를 대상으로 채점-재채점을 실시하여 쓰기평가에서 평가자가 동일 대상에 대해 내적 일관성을 얼마나 확보하고 있는지 그 실제를 확인하고, 그 결과를 바탕으로 평가자의 여러 변인별 특성을 분석하는데 있다. 이는 그동안 미흡했던 평가자 내 신뢰도에 대한 실증적 연구 자료가 되어 쓰기평가 전문성 함양을 위한 유의미한 정보를 제공할 것이라 기대된다. 따라서 이 연구에서 설정한 연구 문제는 다음과 같다.

첫째, 채점-재채점 신뢰도를 분석했을 때 쓰기평가에서 국어교사의 내적 일관성은 어느 정도일까?

둘째, 평가자의 여러 변인에 따른 채점-재채점 신뢰도의 차이는 어떠할까?

이를 위해 국어교사를 대상으로 채점-재채점을 실시하여 평가 결과에 대한 기술통계, 상관계수 분석을 통해 평가자의 내적 일관성을 분석하려 한다. 또 평가자의 여러 변인에 따른 채점-재채점 신뢰도의 차이를 분석하기 위해 다국면 Rasch 모형을 활용하여 평가자의 일관성 유형을 살펴보고 평가자 요인 설문지와 심층 면담을 통해 양적 연구를 보완함으로써 쓰기평가의 일관성 측면에 유의미한 정보를 도출하고자 한다.

이 연구는 몇 가지 제한점을 갖고 있다. 첫째, 표집 규모가 충분히 크지 않아 근무지나 경력을 골고루 반영한 결과라 볼 수 없기에 국어교사의 쓰기평가 특성

으로 일반화하기에 무리가 있다는 점이다. 특히 경력에 따른 평가 특성을 비교하기에 하위 집단별 참여자가 부족했다. 하지만 쓰기평가의 경험이 적지 않은 경력 집단이 다수 참여하였고, 평가자 수가 이 연구에서 사용한 연구 방법을 사용하여 결과를 도출하기에는 무리가 없다고 판단된다.

둘째, 평가의 환경이 평가자마다 다르기 때문에 채점-재채점을 실시함에 있어 동일한 조건을 위한 엄격한 통제가 이루어지지 못했다는 점이다. 다만 기억의 영향을 줄이기 위해 채점 시기에 두 달 이상의 시간 간격을 두었고, 각 평가자가 동일한 플랫폼을 통해 제한된 기간 동안 채점할 수 있도록 하였다.

셋째, 쓰기 과제를 논설문으로 한정하였기에 모든 문종의 채점 특성으로 일반화할 수 없다는 점이다. 국어교사의 평가 경험과 채점 기준에 대한 익숙함 등을 고려하여 논설문으로 선정하였으나, 후속 연구를 통해 다양한 문종의 채점 특성을 살펴볼 수 있기를 기대한다.

위와 같은 제한점에도 불구하고 이 연구는 다음과 같은 점에서 의의가 있다.

첫째, 쓰기평가에서 평가자 내 신뢰도가 얼마나 확보되어 있을지에 대한 실증적 분석이 가능할 것이다. 선행 연구 검토를 통해 알아보았듯이 쓰기평가에서 채점-재채점 신뢰도 분석을 통해 평가자의 내적 일관성을 확인한 연구는 거의 이루어지지 않았다. 국어교사를 대상으로 채점-재채점을 실시하여 얻은 결과를 분석하여 평가자 내 신뢰도 확보를 위한 후속 연구에 실증적 정보를 제공해 줄 것이다.

둘째, 평가자의 채점 일관성, 쓰기평가 효능감과 경력, 성별에 따라 평가자가 쓰기 채점의 내적 일관성에 있어 어떤 특성을 보이는지 살펴봄으로써 쓰기평가 전문성 함양을 위한 유의미한 정보를 제공에 기여할 수 있을 것이다.

Ⅱ. 이론적 배경

이 장에서는 쓰기평가의 특성과 쓰기평가 신뢰도, 쓰기 평가자의 평가 특성, 다국면 Rasch 모형에 대한 이론적 측면을 논의할 것이다. 쓰기평가가 가진 특성을 이해하고, 이 연구에서 알아보고자 하는 채점-재채점 신뢰도를 중심으로 쓰기평가 신뢰도에 대해 알아보고자 한다. 또 쓰기 평가자가 쓰기평가에서 보이는 특성, 특히 채점 엄격성과 일관성에 대해 살펴보고, 평가자 변인에 따른 특성에 대한 연구를 논의할 것이다. 따라서 쓰기 평가자 변인별 특성을 분석하기 위한 다국면 Rasch 모형에 대해서도 살펴보고자 한다.

1. 쓰기평가의 특성

쓰기평가는 글을 쓰는 데에 필요한 능력을 다양한 측면에서 측정하고, 이들 결과에 근거하여 학생의 쓰기 능력을 교육적으로 해석·판단하여 학생들에게 적절한 피드백을 제공하는 행위로 정리할 수 있다(박영민 외 2016). 쓰기 능력은 '목표 지향 사고 과정'(Flower&Hayes 1981), '자기 점검 전략의 효과적인 사용'(Gersten&Baker 2001), '언어 기능'(Mellon 1969) 등을 통해 설명되었다(Gary A. Troia 저 2009, 박영민 역 2012). 이러한 쓰기 능력은 복잡성을 띄기에 이런 요소를 측정하는 것에는 어려움이 따른다. 쓰기 능력을 평가하는 방법에는 간접평가 방법, 직접 평가 방법이 있다. 간접평가 방법은 일반적으로 복합적인 선택형 문항을 통해 이루어지거나, 다른 사람이 쓴 글에서 오류를 찾고 그 오류를 교정하도록 하거나, 혹은 그 교정의 정확성에 대한 판단을 하는 방식으로 이루어진다(Gary A. Troia 저 2009, 박영민 역 2012). 직접 평가 방법은 쓰기 과제 지시문에 따라 글을 써 실제적으로 글을 산출하게 하는 것으로, 학생들이 실제

로 쓰기 과정에 참여할 수 있고 그 과정을 반영한 산출물을 만들 수 있다는 장점이 있다(Gary A. Troia 저 2009, 박영민 역 2012). 여기서는 직접 평가 방법을 통한 쓰기평가를 중심으로 그 특성을 살펴보고자 한다.

첫째, 쓰기평가는 주관적인 행위를 객관적으로 평가하는 고도의 전문성을 요하는 일이다(이성영 2005). 학생들이 쓰기 과제에 대한 자신의 생각을 직접 표출하기 때문에 개인의 주관적 생각이 반영된다. 학생 글을 평가하는 국어교사 역시 주관성을 가진 인간 평가자이기에 쓰기 평가자가 학생 글을 어떻게 인식하고 수용하느냐에 따라 평가 점수가 달라질 수 있다. 학생 글의 인상적 이미지에 따라 평가자의 반응이 달라질 수 있기에 쓰기 평가자로서 학생 글을 평가하는 일은 매우 중요한 의미를 지닌다(Brooks 2007). 작문 평가자의 학생 글 읽기 과정을 연구한 오세영(2017)에 따르면 쓰기 평가자는 학생 글을 읽는 독자이면서 동시에 평가자이기 때문에 개인 평가자의 고립성에서 벗어나 그룹 인지에 기반 하여 상이한 정보를 나눌 수 있는 방안을 제시하기도 했다.

둘째, 쓰기평가는 수행의 상황과 조건을 고려해야 하는 일이다. 쓰기는 매우 수행성이 강한 활동에 속한다. 수행 능력을 평가하는 일은 지식을 평가하는 일에 비해 상대적으로 더 어렵다(이성영 2005). 채점 대상이 되는 글의 유형에 따라 쓰기 평가자가 고려해야 할 조건도 달라진다. 박영민·최숙기(2010)에서 설명문 채점 결과를 분석했을 때 단어 선택에 가장 높은 점수를, 조직에 가장 낮은 점수를 부여했고, 박종임·박영민(2011)에서 서사문 채점 결과를 분석했을 때 내용 요인에 비해 조직이나 표현 요인 평가에 어려움을 겪는 것으로 나타났다. 또 최숙기·박영민(2011)에서 논설문 채점 결과를 분석했을 때에는 내용 요인을 가장 엄격하게 평가하는 것으로 나타났고, 박종임(2013)에서 동일한 평가자가 서사문과 논설문을 모두 채점했을 때 서사문보다 논설문을 더 엄격하게 평가하였다. 이런 특성을 고려할 때 최영미 외(2019)에서 개발한 Python 기반의 쓰기평가연습 프로그램을 통해 글의 유형, 평가 분량, 평가 대상의 학년 수준을 선택하고 표준화된 쓰기 과제와 채점 기준을 통해 채점을 수행하고 피드백을 받을 수 있

는 채점자 훈련 시스템은 쓰기 평가자의 전문성 향상에 도움이 될 것이다.

셋째, 쓰기평가와 쓰기 활동은 연속선상에 있다. 글을 쓰는 과정에서 자기 점검을 되풀이하고 반복적으로 수정하는 것, 쓰기 지도 과정과 결과를 점검하여 피드백을 제공하는 것은 모두 평가를 내포하는 수행 활동이다(이성영 2005). 쓰기를 수행하는 학생들이 텍스트, 과제, 상황, 목적 등에 영향을 받기 때문에 하나의 단일한 평가 활동에 의존하기보다는 쓰기 지도 과정에서 실제적으로 이루어지는 쓰기 수행에 가치를 부여해야 하며, 쓰기평가 결과를 해석할 때 평가 과제와 텍스트, 수업 상황에 대한 정보가 포함되어야 한다(박영목 2008). 쓰기의 수행 활동과 평가 활동을 엄격히 분리하는 것이 아니라 밀접한 관련성을 이해하고 쓰기평가를 해석함으로써 학생의 쓰기 능력을 왜곡 없이 공정하고 타당하게 분석할 수 있어야 한다. 그래서 쓰기평가가 학생의 쓰기 능력 향상으로 이어질 수 있다. 쓰기평가는 효과적인 피드백을 통해 학생들의 쓰기 학습에 직접적인 영향을 주는 활동을 해 나가야 하기 때문이다(박영목 2008).

2. 쓰기평가 신뢰도

신뢰도란 '한 검사가 측정하고자 하는 것을 일관성 있게 측정하거나 오차 없이 정확하게 측정하는 정도'를 의미한다(강승호 외 2004). 평가자의 직접 평가로 이루어지는 쓰기평가의 목적을 달성하기 위해서는 쓰기평가의 신뢰도가 확보되는 일이 중요하다. 쓰기평가를 수행하는 평가자를 중심으로 그 신뢰도를 측정하는 방법은 평가자 간 신뢰도와 평가자 내 신뢰도로 구분하여 이해할 수 있다. 평가자 간 신뢰도와 평가자 내 신뢰도의 개념에 대해 말하고 각 신뢰도를 추정하는 방법에 대해 설명하고자 한다.

평가자 간 신뢰도란 하나의 검사결과를 두 사람 이상의 채점자가 독립적으로 채점했을 때 채점결과가 어느 정도 일치하는지를 알아보는 것을 말한다(강승호

외 2004). 수행평가나 논술평가 등에서 한 검사를 여러 학생들에게 실시했을 때 누가 채점하느냐에 따라 검사점수가 변동될 수 있다는 점 때문에 평가자 간 신뢰도를 확보하는 일은 중요하다. 평가자 내 신뢰도란 한 채점자가 하나의 검사 결과를 반복 채점했을 때 채점결과가 어느 정도 일치하는지를 알아보는 것을 말한다(강승호 외 2004). 평가자 내 신뢰도가 확보되지 않는다면 평가자 개인의 채점에 대한 일관성이 없다는 것이기 때문에 평가자 간 신뢰도 역시 떨어진다. 평가자 내 신뢰도는 평가자 간 신뢰도를 추정하기 위해 전제가 되어야 할 조건이라 볼 수 있다.

먼저 평가자 간 신뢰도를 추정하는 방법에는 Pearson(1896)의 단순적률상관계수, 일치도 통계와 Cohen(1960)의 Kappa계수, 그리고 일반화 가능도 이론 등이 있다(성태제 1994). 검사가 불연속 변수로서 합격-불합격 또는 A-B-C 등급처럼 질적 유목으로 분류되는 경우 Hambleton과 Novick의 P_0계수와 이 계수를 보완한 Cohen의 Kappa(또는 K)계수를 사용할 수 있다(강승호 외 2004). P_0계수는 앞서 말한 일치도 통계, 합치도 계수라고 하는데 다수의 피험자들을 대상으로 채점자들이 분류한 유목이 얼마나 일치하는가를 알아보는 것인데 이때 채점자 간에 우연히 일치하는 부분이 포함되어 평가자 간 신뢰도를 실제보다 과대 추정하는 문제가 있다.

이를 보완하기 위해 채점자 간에 우연히 일치하는 확률을 제거하고 평정자간의 일치도를 추정하는 방법이 Kappa계수로, 순수한 합치도 계수라고 부른다. 검사점수가 연속 변수 또는 양적 변수인 경우에는 상관계수법, 일반화가능도 이론, 다국면 Rasch 모형 등을 사용한다(강승호 외 2004). 이 경우 상관계수법은 주로 채점자가 2명인 경우 유용하고 채점자가 3명 이상인 경우에는 일반화가능도 이론이나 다국면 Rasch 모형을 적용하는 것이 효과적이다(남명호 외 2000). Pearson 상관계수 r은 2명의 채점자가 채점을 얼마나 일관성 있게 했는지를 나타내 주는 것으로 1에 가까운 값이 나올수록 평가자 간 신뢰도가 높다 할 수 있다. 일반화가능도 이론이나 다국면 Rasch 모형을 사용하면 평가자 간 신뢰도뿐

만 아니라 각종 오차요인과 오차요인의 영향력을 동시에 분석할 수 있다는 장점이 있다.

다음으로 평가자 내 신뢰도를 추정하는 방법으로는 Cronbach α가 대표적이다. Cronbach(1951)은 한 검사의 단일 시행에서 얻은 동질성이나 내적 일관성을 측정하기 위해 α계수를 개발하였다(강승호 외 2004). 검사문항들이 정답은 1점, 오답은 0점을 주는 이분형으로 채점되는 검사의 경우와 1, 2, 3, 4, 5점과 같이 부분점수가 가능한 연속형 문항으로서 논문형 검사 문항에 모두 사용할 수 있다. 한 검사가 두 개 이상의 하위검사로 구성되어 있을 때 각 하위검사마다 α계수를 산출해야 한다. α계수 한 검사를 구성하고 있는 모든 문항들 간의 상호 상관의 평균으로 해석할 수 있어 흔히 '급내 상관'이라 부른다.

검사-재검사 신뢰도는 동일한 검사를 동일한 사람들에게 일정한 시간간격을 두고 두 번 실시하여 신뢰도를 추정하는 방법이다(강승호 외 2004). 이 동일한 두 번의 검사결과 간의 상관계수가 검사-재검사 신뢰도 계수이다. 통제할 수 없는 검사환경의 조건 차이나 돌발적인 여러 방해요인에 의한 오차가 있을 수 있으나, 일반적으로 검사-재검사 신뢰도는 한 검사의 결과를 다른 시기에도 일반화할 수 있는 정도를 설명한다. 쓰기평가에서는 채점을 수행하는 평가자가 얼마나 일관되게 안정성 있는 결과를 보이는가를 의미한다. 동일한 두 검사 간의 상관계수를 구하는 방법이기 때문에 계산이 비교적 간편하고 동형검사를 제작하는데 따르는 어려움을 방지할 수 있다. 하지만 두 검사 간의 시간간격에 따라 기억 효과나 연습 효과로 인해 신뢰도에 영향을 미칠 수 있다. 또 동일검사를 동일집단에게 두 번 실시할 때 흥미도가 떨어지거나 동일한 검사환경을 유지하기 어렵다는 점에서 실질적인 어려움이 따른다.

3. 쓰기 평가자의 평가 특성

쓰기평가의 평가자인 국어교사가 지닌 각각의 특성은 평가 결과에 직·간접적

인 영향을 미친다. 국어교사의 성별, 경력과 같은 배경요인 외에도 쓰기평가에 대한 지식, 태도 등에 따라서도 그 결과가 달라질 수 있다. Linacre(1989)는 평정자의 전반적인 엄격성과 평정자, 문항, 채점척도간의 상호작용을 통틀어 '엄격성(severity)'이라는 용어를 사용하였고, McNamare & Adamxs(1991, 1994)는 평정자 엄격성과 상호작용 효과를 '평정자 특성(rater characteristics)'이라는 용어로 사용할 것을 제안했다(McNamara 저 1996, 채선희 외 역 2003).

채점 엄격성이란 학생 글을 채점하여 점수를 부여할 때 엄격하게 부여하는 정도를 의미한다. 엄격한 평가자의 경우 점수를 지속적으로 낮게 주는 경향을 보이고, 관대한 평가자의 경우 점수를 지속적으로 높게 주는 경향을 보인다. 엄격성과 관대함(leniency)은 서로 대립되는 개념이기에 주로 엄격성이 높고 낮다는 것으로 정도를 표현한다. 동일한 학생 글을 평가하는데 평가자마다 서로 다른 엄격성으로 인해 평가 결과에 차이가 있다면 학생의 쓰기 능력이 타당하고 신뢰할 만한 방법으로 평가되었다고 보기 어렵다. 채점 일관성(consistency)이란 여러 학생의 글을 채점하여 점수를 부여할 때 동일한 엄격성 수준을 유지하는 정도를 의미한다. 일관성의 정도로 평가자 유형을 분류할 때 그 기준이 되는 내적합(infit) 지수는 연구자들마다 어느 정도 차이가 있으나 적합, 과적합(overfit), 부적합(misfit)으로 구분한다. 내적합 제곱평균값(infit MnSq)을 기준으로 할 때 McNamara(1996), 박종임(2013)에서는 '0.75~1.3', Bond & Fox(2001), 박영민·최숙기(2010)에서는 '0.7~1.3', Lunz et al.(1990)에서는 '0.6 ~ 1.5', 장소영·신동일(2009)에서는 '0.5~1.5'를 적합한 일관성 수준으로 판단하는 범위로 삼았다. 적합한 일관성 수준을 보인다는 것은 채점 회기 동안 엄격성을 일관적으로 유지한다는 의미이고, 과적합한 일관성 수준을 보인다는 것은 비슷한 점수만 부여해 세부적인 변별을 하지 못하고 있다는 것을 의미한다. 부적합한 일관성 수준을 보인다는 것은 예측할 수 없는 점수를 부여하여 점수에 일관성이 없다는 의미이기에 Myford & Wolfe(2003)에 따르면 과적합한 일관성 수준을 보이는 것보다 부적합한 일관성 수준을 보이는 경우가 신뢰도가 더 떨어진다고 볼 수 있다.

평가자 간의 엄격성 차이는 다국면 Rasch 모형을 통해 예측 가능하고 평가자의 엄격성에 따라 조정된 기댓값을 반영하거나 오류가 있을 경우 평가 결과에 반영할 항목을 조정하는 등 조정 가능한 오차로 모형화 할 수 있다. 하지만 이러한 오차를 조정하고 그 후 남는 것은 Linacre(1989)에 의해 '평정에 있어서 체계적인 방식으로는 설명될 수 없는 부분'으로 정의 내려진 무선오차이다(McNamara 저 1996, 채선희 외 역 2003). 이는 평자가의 채점 일관성에 관한 것으로, 일관성 부족은 어떤 기법으로도 조정이 불가능하며 채점에 대해 재교육을 시키거나 채점과정에서 제외시키는 길밖에 없다(McNamara 저 1996, 채선희 외 역 2003). 이 때문에 채점자의 채점 일관성을 높이기 위한 채점자 훈련과 같은 방안 마련에 대한 연구(박종임 2013, 박종임·박영민 2011, 장은주 2015)들이 이루어지고 있다.

평가자가 특정 문항에 대해서는 관대하면서 다른 문항에 대해 일관되게 엄격해질 수도 있고, 특정 피험자나 피험자 집단에 대해 과대 혹은 과소평가하는 경향을 보일 수 있다. 이렇게 평가자가 평가 상황에서 특정 피험자, 특정 요소 등에 대해 더 엄격하거나 더 관대하게 평가하는 특성을 평가자 편향(bias)이라 한다(최숙기·박영민 2011). 평가자 편향은 다국면 Rasch 분석의 상호작용 분석을 통해 확인할 수 있다. 특정 평가자와 피험자 간, 혹은 특정 평가자와 문항간의 체계적인 상호작용과 같은 상호작용 효과라 부르기도 한다(McNamara 저 1996, 채선희 외 역 2003).

문항반응이론(Item Response Theory: IRT)에 근거한 Rasch 모형은 1960년대 덴마크의 수학자 George Rash에 의해 발표되었고, 이후 미국 시카고 대학 교육학과의 Benjamin D. Wright(1968)에 의해 소개되고 실용화되었다. 다국면 Rasch 모형(many facet Rasch model: FACETS 모형)은 Linacre(1989)에 의해 1모수-로지스틱 문항반응모형인 Rasch 모형을 확대하여 개발된 것이다(지은림 외 2000). 이는 평정자 요인을 더하거나 과제곤란도를 더하는 등 Rasch 모형에 추가로 더하는 가법모형(additive)으로의 확장을 가능하게 했다. 이러한 평정상황

의 각 측면-문항, 능력, 과제, 평정자 등-을 국면(facet)이라 부른다(McNamara 저 1996, 채선희 외 2003).

쓰기평가를 선다형 문제 형식의 간접 평가로 실시할 수도 있겠지만 학생들의 쓰기 능력을 제대로 진단하고 향상시키기 위해서는 직접 평가가 중요하다. 직접 평가에서 채점자들의 주관이 채점과정에 반영되는 경우 모든 채점자가 같은 정도의 엄격성과 일관성으로 채점하기를 기대하는 것은 불가능에 가깝다. FACETS 모형은 이러한 점을 고려하여 채점자들의 채점 경향을 통계적으로 조정함으로써 채점 오류를 찾아내 채점자 내 내부 일관성을 높이도록 하거나, 각 채점자들의 엄격함이나 관대함의 정도 그리고 특정 문항이나 평가 영역에서의 편향적 채점 경향을 확률적으로 추적하여 채점자 훈련에 도움을 제공할 수 있다(신동일 2001). 다국면 Rasch 모형의 공식은 다음과 같다(McNamara, 1996).

$$\log(P_{njk}/P_{njk-1}) = B_n - D_i - C_j - F_k$$

위의 공식에서 제공하는 값은 n이라는 수험자가 문항 i에 대해서 채점자 j에게 하나의 등급 점수(Pnjk-1)에서 보다 높은 등급 점수 Pnjk 값을 얻을 확률을 log의 값으로 변환한 것이다. 실제 채점 과정에서 받은 점수, 즉 원점수가 아닌 보다 객관적인 변환 점수를 구하기 위해 측정치 값을 log 지수로 표기하고 수험자 n의 능력(Bn)에서부터 문항 i의 난이도(Di)와 채점자 j의 엄격성(Cj), 그리고 어떤 등급 점수 (k-1)에서 그 다음 높은 점수 k로 향상시키는데 걸리는 어려움(Fk)를 모두 고려한 값이다(장소영·신동일 2009).

FACETS 프로그램을 통해 수행된 다국면 Rasch 분석은 원점수를 통계적으로 재조정하여 보다 공정한 채점결과를 제공하고, 각 변인의 타당도와 신뢰도를 구체적으로 검토할 수 있게 한다. 각 변인에 대한 적합도와 표준오차를 제시하여 모형의 내적 타당도와 신뢰도를 검토할 수 있다. 채점자 변인에 대한 적합도의 경우 채점자간 일관성을 검토할 수 있어, 적합도가 지나치게 낮거나 높은 경우

채점자간의 분산을 조정하고 그 원인을 규명해볼 수 있다. 표준오차는 변인별 추정 값이 얼마나 정확한가에 대한 정보를 주기 때문에 많은 문항을 채점할수록, 여러 채점자가 공통적으로 채점한 문항이 많을수록 분석에 필요한 정보가 풍부해 보다 정확한 추정 값을 얻게 된다(김성숙 2001).

또 각 요인-피험자 능력, 문항 곤란도, 평정자 엄격성-에 대한 분리된 상세한 표를 제공해준다. 피험자 능력은 문항 곤란도와 평정자 엄격성을 고려한 상황에서 주어진 수준의 문항에 대해 성공할 확률로 정의되며, 문항 곤란도 역시 주어진 능력의 피험자가 그 문항에 대해 주어진 평정자의 엄격성을 고려한 상태에서 주어진 점수 이상을 얻을 수 있는 확률에 따라 표현이 가능하다. 또 평정자 엄격성은 평정자가 주어진 능력의 피험자에게 주어진 문항에 대해 주어진 점수 이상을 부여할 수 있는 확률로 표현된다. 이러한 확률은 logit 단위로 나타낸다(신동일 2001).

채점자의 엄격성이나 일관성 양상을 살펴보거나 편향 분석을 통해 채점자 교육과 관리에 효과적 정보를 제공할 수 있다. 특정 문항이 지나치게 어렵거나 경력이 부족한 채점자가 특정 과제에 지나치게 관대하게 채점했다거나 하는 평가 단면 정보를 적절히 고려해야 신뢰성을 가질 수 있기에, 편향 분석은 이러한 채점 경향을 분석하는 과정에서 채점자가 어떤 편향을 어떤 단면에 얼마나 치우치게 채점 하고 있는지에 대한 정보를 제공한다(신동일 2001). 다국면 측정의 편파성 분석을 통해 원 점수에 체계적인 영향을 미치는 평가 상황의 서로 다른 국면 간의 상호작용 유형도 파악할 수 있다(채선희 외 2003).

이러한 다국면 Rasch 분석에 근거한 연구는 국내외에서 다양하게 이루어졌다(신동일 2001, 채선희 1996, 박종임·박영민 2011, 박종임 2013, 이현숙 2008, Lumley & McNamara 1995, McNamare 1996, Weigle 1998). 쓰기 수행평가나 논술시험 등에서 각 변인의 영향을 고려하여 학생의 쓰기 능력을 측정할 수 있는데 도움이 된다는 점에서 그 활용도가 높다.

Ⅲ. 연구 방법

이 장에서는 평가자 변인에 따른 채점-재채점 신뢰도를 분석하기 위해 사용한 연구 방법에 대해 구체적으로 제시하고자 한다. 이 연구에 참여한 연구 대상을 밝히고, 쓰기 과제와 채점 기준 및 척도를 비롯한 검사 도구, 연구자가 학생 글을 수집하고 분석 대상 글을 분류한 과정 등을 연구 절차에 따라 밝히려 한다. 그리고 결과를 해석하기 위한 자료 분석 및 심층 면담의 내용과 이에 사용한 분석 도구를 제시하고자 한다.

1. 연구 대상

이 연구에서는 현직 국어교사 30명을 연구 대상으로 선정하여 쓰기평가 채점-재채점을 실시하였다. 연구에 참여한 국어교사를 교직 경력과 성별에 따라 분류하여 정리하면 <표 Ⅲ-1>과 같다.

<표 Ⅲ-1> 연구 대상 분포

경력 \ 성별	남	여	계(%)
5년 미만	3	1	4(13.33)
5년 이상~10년 미만	5	9	14(46.67)
10년 이상~15년 미만	4	5	9(30.00)
15년 이상	·	3	3(10.00)
계(%)	12(40.00)	18(60.00)	30(100.00)

이 연구에 참여한 총 30명의 현직 국어교사의 구성은 성별에 따라 분류하면 남교사 12명(40.00%), 여교사 18명(60.00%)이며, 교직 경력에 따라 분류하면 5년 미만 4명(13.33%), 5년 이상~10년 미만 14명(46.67%), 10년 이상~15년 미만 9

명(30.00%), 15년 이상 3명(10.00%)이다. 국어교사의 성별 분포 상 여교사가 남교사에 비해 많기 때문에 표집 시 여교사와 남교사가 동일한 비율로 표집 되지는 않았다. 평소 학교 현장에서 학생 글을 직접 평가할 때와 유사하게 평가할 수 있도록, 평가자에 대한 사전 교육을 제공하거나 평가 과정에서 협의하도록 하지 않았다.

2. 검사도구

가. 쓰기평가 자료

(1) 쓰기평가 과제

이 연구는 강원도 소재 일반계 고등학교 2학년 학생들을 대상으로 80편의 논설문을 수집하여 그 중 50편을 선정하였다. 이를 위해 제시한 쓰기평가 과제는 <표 Ⅲ-2>와 같다.

<표 Ⅲ-2> 학생 쓰기 과제

【쓰기 과제】 다음 <자료>를 읽고 '과학 연구를 위해 동물 실험을 해야 한다'에 대한 자신의 의견을 써 봅시다. 【읽기 자료】 국내 연구진이 포유동물 실험을 하지 않고 예쁜 꼬마선충을 대상으로 항암제 독성을 실험하는 기술을 개발했다는 뉴스다. 아직 사용할 수 없는 분야가 더 많겠지만 적어도 항암제 독성 실험에 사용됐던 포유동물의 수를 줄일 수 있을 것으로 기대된다. 지난 2015년 한 해 동안 실험에 사용된 동물은 2013년에 비해 37% 증가한 250만 마리에 달했다. 동물실험은 국내뿐만 아니라 세계적으로 증가하는 추세다. 동물실험의 횟수가 늘수록 동물애호가를 포함한 많은 사람들이 더 격렬하게 실험에

반대하고 있다. 실제로 동물실험에 대한 찬반 토론은 국내의 많은 학교들이 토론대회 문제로 선호하는 항목 가운데 하나다. 이번에는 동물실험에 대해 알아보도록 하자.

동물실험의 역사는 고대 그리스 시대까지 거슬러 올라간다. 히포크라테스는 동물 해부를 통해 생식과 유전을 설명했고, 아리스토텔레스는 해부학과 발생학을 발전시켰다. 16세기에는 베살리우스가 인체 해부학을 발전시켰는데 그 이전까지 동물 해부는 의학 분야에서 가장 중요한 과목으로 자리 잡았다. 19세기 이후 동물실험은 독성학과 생리학에서 사용되기 시작했다. 우리가 알고 있는 파스퇴르나 파블로프의 실험으로 의학과 생물학은 진일보한다. 이와 함께 반대하는 사람들도 늘기 시작했다.

동물실험을 반대하는 입장에서는 늘 효율에 대한 주장을 펼친다. 독일의 입덧 방지약에 들어있던 탈리도마이드라는 물질은 쥐나 개, 고양이에 대한 동물실험에서 아무런 부작용을 일으키지 않았지만 정작 원숭이와 사람에게는 팔이나 다리뼈가 발달하지 않거나 극단적으로 짧은 기형아를 발생시켰다. 백혈병 치료제였던 글리백은 쥐에서는 독성을 보였지만 원숭이와 사람에게는 효과가 있는 걸로 나타났다. 실제로 아스피린과 페니실린 등 많은 의약품이 동물과 인간에게 나타나는 효과가 다르다. 동물실험을 통해 모든 부작용을 정확하게 예측할 수 없기에 실험이 과연 의미가 있는지에 대한 의심이 제기되는 것이다. 여기에 동물과 사람이 공유하는 병이 약 1% 정도로 극히 드물다는 것도 동물실험을 반대하는 중요한 근거다.

동물실험을 찬성하는 측은 완벽하게 대체가 불가능한 기술이라는 점을 꼽는다. 인간이 사용할 약을 실험하려면 인간에게 투약하는 것이 가장 정확하고 명확한 결과를 얻을 수 있지만 그럴 수 없다는 것이다. 물론 목적으로 인간을 대하는 것 자체가 올바른 행위는 아니겠지만 만약 사용하더라도 실험 결과를 얻기까지 너무 많은 시간이 걸리는 것도 동물실험이 불가피하다는 논거가 된다. 컴퓨터를 활용해 시뮬레이션을 해도 수많은 변수를 전부 데이터화할 수 없고, 이로 인해 부작용을 정확하게 예측하기 어렵다. 동물을 사용함으로써 빠른 결과를 얻고, 부작용을 살펴볼 수 있기에 대체 기술이 발명되기 전에는 어쩔 수 없는 실험이라는 주장이다.

이처럼 과학의 발전은 때로는 사회적인 혼란을 불러온다. 올바른 답이 있는 경우

도 있지만 대부분은 그렇지 않은 경우가 많다. 어디에 방점을 찍느냐는 언제나 우리의 선택이다. 동물실험에 대해 다시 생각해보고, 과학과 윤리와의 관계를 생각해 보는 시간을 갖도록 하자.

(출처 : 대전일보, 2017-06-19기사 편집 2017-06-19 19:36:25)
http://www.daejonilbo.com/news/newsitem.asp?pk_no=1268776

이 쓰기 과제는 2021년 6월 4일 해당 학교의 세 학급에서 각각 국어교사 1인의 감독 하에 50분간 작성하도록 하여 수행되었으며, 이후 수집된 학생 글은 워드프로세서로 옮겨 적었다. 이 과정에서 손 글씨의 영향으로 인해 엄격한 평가가 어려운 띄어쓰기는 수정하여 반영했으나 평가의 요소인 국어 규범의 오류는 수정하지 않았다.

문종은 국어교사의 평가 경험을 고려할 때 주장에 대한 근거를 타당하게 들고 논리적으로 전개해야 하는 논설문에 대한 평가 경험이 비교적 많고, 글의 특성에 대한 이해가 능숙하다는 선행 연구들을 고려하여 논설문으로 선정하였고, 학생들이 쉽게 접했을 만한 '동물 실험'에 관한 주제를 다루었다.

(2) 채점 기준 및 채점 척도

이 연구에서는 박영민(2012)과 권태현(2014), 장은주(2015)의 논설문 쓰기평가 기준을 참고하고 일부 내용을 수정하여 내용·조직·표현으로 평가 요인을 범주화하였다. 이후 국어교육 박사 과정 중인 국어교사 1명과, 석사 과정 중인 국어교사 1명의 자문을 받아 설정한 채점 기준 및 채점 척도는 <표 Ⅲ-3>과 같다.

<표 Ⅲ-3> 채점 기준표

평가 요소	평가 기준	평가 척도
내용	1. 주장이 명료한가?	1 ~ 6
	2. 근거가 주장을 뒷받침하기에 타당한가?	1 ~ 6
	3. 근거가 주장을 뒷받침하기에 구체적이고 풍부한가?	1 ~ 6
조직	1. 서론-본론-결론의 체계적인 구조를 갖추었는가?	1 ~ 6
	2. 문장 또는 문단이 유기적으로 연결되었는가?	1 ~ 6
표현	1. 단어 사용이 적절하고 문장을 명료하게 진술하였는가?	1 ~ 6
	2. 어문규범(맞춤법, 문장 부호 등)에 맞게 표현되었는가? * 띄어쓰기는 평가하지 않습니다.	1 ~ 6

내용 요소에서는 주장의 명확성과 근거의 타당성, 근거의 풍부성을 평가 기준으로 설정하였다. 평가자의 평가 요인 해석과 적용을 용이하게 하기 위해 근거의 타당성과 풍부성을 각각 하위 채점 요소로 분리하였다. 조직 요소에서는 논설문의 일반 원리에 따른 '서론-본론-결론'의 체계적 구조, 문장 또는 문단의 유기성을 평가 기준으로 설정하였다. 선행 연구들이 조직 요인에서 논리적, 유기적, 체계적인 내용 배치를 평가 요소로 삼고 있는 것을 참고하였고, 논설문에서 갖추어야 할 체계적 구조에 대해 평가자 간 해석의 차이를 줄이기 위해 보다 구체적으로 제시하였다. 표현 요소는 '단어 사용의 적절성'과 '명료한 문장 진술', '어문규범의 준수' 정도로 간략하게 설정하였다. 다만 학생 글을 워드 프로세서로 전사하는 과정에서 손 글씨의 영향으로 띄어쓰기가 수정된 점으로 인해, 띄어쓰기는 평가에서 제외하였다.

채점 척도는 Likert식 6점 척도를 사용하였다. 평가자들이 척도에서 가능한 점수범위를 사용함에 있어 극단점수의 사용을 피하거나 중앙 집중의 경향을 보일 수 있다. 채점-재채점에서 동일한 평가자의 채점 일관성에 중심화 경향으로 인한 영향을 줄이기 위해 1점에서 6점까지 점수를 부여할 수 있도록 하였다.

나. 평가자 요인 검사지

(1) 인적사항, 쓰기평가 및 연수 경험

평가자 요인에 따른 쓰기평가의 특징과 채점의 일관성 양상을 분석하기 위해 몇 가지 요소를 수집하였다. 배경요인으로는 성별, 교직 경력을 조사하였고, 쓰기평가에서의 평가자별 특성을 분석할 때 참고하기 위해 쓰기평가 및 연수 경험에 대한 추가 설문을 포함하였다. 쓰기 직접 평가를 실시한 경험이 어느 정도인지에 대해 '매우 적음(주로 하지 않음), 적음(일 년에 1회), 보통(학기 당 1회), 많음(학기 당 2회), 매우 많음(수시로 실시)'로 나누어 응답하도록 하였고, 주로 경험한 쓰기평가의 방식에 대해 서술식 응답을 얻었다. 또 쓰기평가에 관한 연수 경험이 있는지 '없음, 1~2회, 3~4회, 5회 이상'으로 구분하여 응답하도록 하였고, 쓰기평가 연수 경험이 있다면 자격 연수, 직무 연수, 집합 연수, 원격 연수 등 어떤 형태의 연수인지에 대해 물음으로써 평가자별 특성에 대한 정보를 보완하였다. 평가자 요인 검사지는 <부록 1>에서 확인할 수 있다.

(2) 쓰기평가 효능감 검사지

평가자의 쓰기평가 효능감에 따른 쓰기평가 특성 차이를 분석하기 위해 평가자들이 본 채점에 들어가기에 앞서 쓰기평가 효능감 검사를 실시하였다. 쓰기평가 효능감 검사지는 박영민(2010)에서 개발된 것을 사용하였다.

이 검사 도구는 예비국어교사의 쓰기평가 효능감 측정을 위해 개발된 것으로 총 18개의 문항으로 구성되었다. 예비국어교사 321명을 대상으로 양호도 분석 및 요인분석을 실시한 결과 두 가지 요인으로 분류하여 13개의 문항이 해당하는 요인 1은 '실행적 평가 효능감', 5개의 문항이 해당하는 요인 2는 '일반적 평가 효능감'으로 명명되었다. 실행적 평가 효능감은 평균은 3.922, 표준편차는 .9024였

고, Cronbach α로 추정한 신뢰도는 .941이었다. 일반적 평가 효능감은 평균 4.049, 표준편차 .7657, Cronbach α로 추정한 신뢰도는 .858이었다. 또 두 요인의 상관도는 .410, 유의확률 0.000으로 통계적으로 유의하였다. 이후 박영민(2011)에서 해당 검사 도구로 국어교사 133명을 표집하여 쓰기평가 효능감을 측정하였다. 실행적 평가 효능감의 평균은 4.410, 표준편차는 .521로, 일반적 평가 효능감의 평균은 4.318, 표준편차는 .649였고, 유의확률 0.000으로 통계적으로 유의했다. 장은주(2015)에서는 실행적 평가 효능감은 평균 4.71, 표준편차는 .50, 일반적 평가 효능감은 평균 4.49, 표준편차는 .61로 나타났다. 유의확률은 .000으로 통계적으로 유의했고, Cronbach α로 추정한 신뢰도는 .910으로 높은 수준을 보였다.

따라서 이 검사 도구의 타당성이 확인되었다고 보고 예비 검사는 시행하지 않았고 수정 없이 그대로 사용하였으며, 척도는 '전혀 그렇지 않다', '그렇지 않다', '별로 그렇지 않다', '조금 그렇다', '그렇다', '매우 그렇다'로 Likert 척도로 구성하였다. 각 문항은 <부록 1>에서 확인할 수 있다.

3. 연구 절차

가. 연구 과정

쓰기평가에서의 평가자 변인에 따른 채점-재채점 신뢰도 분석을 위한 연구의 과정을 정리하면 <그림 Ⅲ-1>과 같다.

<그림 Ⅲ-1> 연구 과정

검사 도구 제작	· 평가 기준, 평가 척도 마련 · 평가자 요인 중 설문 문항 선정 · 검사지 제작

학생 글 수집 및 채점-재채점 글 선정	· 쓰기 과제 선정 · 학생 글 80편 수집 · 수집된 글 자료 수준별 분류 · 분석 대상 글 20편 선정 · 1차, 2차 채점 글 각 35편 선정
예비 검사	· 채점 기준 및 척도 수정 · 검사 도구 수정
1차 채점	· 학생 글 35편 채점 및 평가자 요인 검사지 작성
2차 채점	· 학생 글 35편 채점
자료 분석 및 심층 면담	· 급내 상관계수, Pearsoon 상관분석 · 다국면 Rasch 모형 적합도 및 채점 특성 분석 · 평가자 변인에 따른 채점-재채점 신뢰도 분석 · 평가자 심층 면담

사전에 평가 기준 및 척도를 마련하고 검사 도구를 제작한 후 학생 글 80편을 수집하였다. 수집된 글 자료를 채점하여 수준별로 분류하고 분석 대상이 될 글 20편을 포함하여, 1차 채점 글 35편과 2차 채점 글 35편을 각각 선정하였다. 예비 검사를 통해 채점 기준과 척도, 검사 도구의 형식 등을 수정하였고, 두 달 가량의 기간을 사이에 두고 1차 채점과 2차 채점을 각각 실시하였다. 이후 자료를 분석하고 평가에 참여한 국어교사를 대상으로 심층 면담을 실시하였다.

나. 검사 도구 제작

논설문 평가 기준 및 척도를 제시하고 있는 선행 연구를 참고하여 내용, 조직, 표현의 평가 요인을 범주화하고 Likert식 6점 척도를 사용했다. 평가자 요인의 하위 요소로 성별과 교직 경력과 같은 평가자의 인적 사항, 쓰기평가 및 연수 경험을 선정하여 설문 문항을 구성하였다. 쓰기평가 효능감 검사 도구로는 박영민(2010)에서 개발되고 그 타당성이 확보되었다고 판단된 것을 수정 없이 사용하였고, 채점을 위한 플랫폼은 google 설문지를 사용하였다. 평가자 변인별 특성에 관해 분석할 때 양적 연구만으로 해석하기 어려운 측면을 보완하기 위해 쓰기 과제와 채점 과정에 대한 평가자의 주관적 인식, 채점 일관성 신장에 대한 의견 등은 심층 면담 질문지를 마련하여 사용하였다.

다. 학생 글 수집 및 채점 글 선정

쓰기평가의 채점-재채점 신뢰도를 분석하기 위한 학생 글을 수집하기에 앞서 학생들에게 제시할 쓰기 과제를 선정하였다. '동물 실험'에 관한 논설문 쓰기 과제를 선정하고, 강원도 소재 일반계 고등학교 2학년 학생으로부터 80편의 글을 수집하였다. 학생 글 자료 수집을 위해 해당 학교 논술반 담당 국어교사 3인에게 사전에 감독 시 유의점을 안내하였고, 2021년 6월 4일 동일한 시간대에 세 학급으로 나누어 50분간 실시되었다. 수집된 80편의 글은 평가자에게 긍정적, 부정적으로 미칠 수 있는 필체의 영향을 통제하기 위해 워드 프로세서로 입력하였다. 이 중 채점에 어려움을 줄 만한 분량이거나, 쓰기 과제의 요건을 현저히 따르지 않은 글 등을 배제하고 50편을 선정하였다.

총체적 채점에 따라 연구자가 수집된 글을 '상' 수준 15편, '중' 수준 20편, '하' 수준 15편으로 글의 수준을 나누고, 경력 10년 이상의 국어교사 2명의 검토를 거쳐 글 50편의 수준을 최종 분류하였다. 이후 글의 수준을 균형 있게 고려하여

이 연구에서의 분석 대상이 되는 글 20편을 선정하였다. 채점-재채점 신뢰도를 보다 정확하게 측정하기 위해서 분석 대상이 되는 동일한 학생 글에 대한 기억의 영향을 줄일 수 있도록, 각 채점 시기에 분석 대상 글과 함께 제공할 서로 다른 15편의 글을 선정하였다. 글 제시 순서도 채점자가 앞선 채점의 경험으로 인한 기억 등의 영향을 받지 않도록 1차 채점과 2차 채점 시기에 서로 다르게 배치하였다.

라. 예비 검사

검사 도구의 타당성을 확보하여 연구의 목적에 적합한 결과를 얻기 위해 본 검사에 앞서 예비 검사를 실시하였다. 국어교육 박사과정에 재학 중인 국어교사 1명과 석사 과정에 재학 중인 국어교사 1명을 통해 검사 도구 형식, 평가자 요인 설문 문항, 평가 기준 및 척도에 관한 자문을 얻었다. 평가 기준의 경우 평가자마다 다르게 해석할 수 있는 단어나 문장에 대한 수정이 이루어졌다. 가령 '글의 구조가 논설문의 일반 원리를 따르는가?'와 같이 그 의미 해석이 모호한 경우 '서론-본론-결론의 체계적인 구조를 갖추었는가?'와 같이 수정하여 해소하였다. 이외 평가자의 채점 피로나 오류를 줄일 수 있는 방향으로 형식을 일부 수정하였다.

마. 1차 채점

학생 글은 'google 설문지' 플랫폼에서 통제된 입력 기간 안에 평가자가 직접 채점을 수행할 수 있도록 작성되어 2021년 6월 27일 링크로 전달되었다. 쓰기 과제와 분석적 채점 기준표, 채점의 방식에 관한 안내는 1차 채점이 이루어지기 일주일 전에 미리 공지하였다. 채점은 2021년 6월 28일부터 7월 5일까지 제한된 기간에만 가능하도록 설계되었다. 채점은 채점-재채점 신뢰도 분석의 대상이 되

는 학생 글 20편과 그 외 15편의 글이 함께 제공되었다. 채점 과정에서 일어날 수 있는 여러 변수를 최소화하기 위해 되도록 한 번에 35편의 학생 글을 이어 평가하기를 권장하였다. 다만 연속적인 채점 과정에서 평가자가 느낄 피로도의 영향을 줄이기 위해, 채점 중 휴지기가 필요할 경우 중간 저장 후 기간 안에 응답 수정이 가능하도록 하였다. 채점 결과는 연구자의 google drive에 자동으로 저장되어 google spread sheet로 수합되었다.

바. 2차 채점

채점과 동일한 플랫폼과 방식을 통해 2차 채점이 이루어졌다. 1차 채점과 2차 채점이 이루어지는 시기의 간격이 너무 길면 평가자의 쓰기평가 경험을 비롯한 여러 변인의 변화나 채점 환경의 변화가 클 수 있고, 간격이 너무 짧으면 평가자의 기억에 영향을 받을 수 있다. 따라서 여러 변수와 기억의 영향을 최소화하기 위해 채점 시기와 재채점 시기 사이에 두 달 이상의 간격을 두었다. 또 분석 대상이 되는 20편의 글 외에 1차 채점 시기와 다른 글 15편을 추가하고 순서를 재배치하였다. 2차 채점은 2021년 09월 10일에서 9월 18일까지 통제된 기간 동안 채점이 수행 되었다. 쓰기 과제와 채점 기준표, 채점의 방식에 관한 유의사항은 앞선 채점 때와 마찬가지로 사전에 안내하였다.

사. 자료 분석 및 심층 면담

국어교사 30명으로 구성된 각 평가자가 채점한 결과 70건은 google spread sheet로 수합되었고, 그 중 채점-재채점 신뢰도 분석의 대상이 되는 학생 글 20편에 대한 40건의 채점 결과는 EXCEL 2013로 정리하였다. 이를 FACETS 프로그램을 통해 평가 자료가 다국면 Rasch 모형으로 분석하기에 적합한지 모형 적합도를 확인하였고, 이후 FACETS 프로그램으로 평가자의 채점 엄격성과 일관

성을 분석하였다. 채점 일관성 유형에 따라 평가자 집단을 나누어 비교하고 SPSS ver 28.0를 사용하여 두 채점 결과의 급내 상관계수(ICC)를 산출하고, 채점-재채점 신뢰도를 분석하기 위해 Pearson 상관분석을 실시하였다. 또 성별, 경력과 같은 평가자 배경요인과 쓰기평가 효능감에 따른 채점-재채점 신뢰도 분석을 실시하였다. 평가자 유형을 잘 보여주는 집단을 중심으로 심층 면담을 통해 채점 일관성에 대한 의견을 수집하고 일관성 신장 방안에 대해 논의하였다.

4. 분석도구

이 연구에서는 google 설문지 플랫폼으로 쓰기평가 자료와 쓰기평가 효능감 검사지를 제공하고, 배경요인 및 쓰기평가와 연수 경험에 대한 자료를 수합하였다. 채점 결과와 쓰기평가 효능감에 대한 기술 통계, 채점 결과에 대한 모형적합도 검사, 평가자의 채점 엄격성과 일관성 유형 분석, 급내 상관계수(ICC) 산출 및 Pearson 상관분석을 통해 채점-재채점 신뢰도를 구하였다. 기술 통계를 위해 EXCEL 2013을 사용하였고, 평가자 유형과 변인별 특성 등을 분석하기 위해 다국면 Rasch 모형을 적용한 FACETS ver. 3.80을 사용하였다. 또 급내 상관계수(ICC) 산출 및 Pearson 상관분석을 위해 SPSS ver 28.0을 사용하여 채점-재채점 신뢰도를 구하였다.

Ⅳ. 연구 결과 및 논의

이 장에서는 채점 결과의 급내 상관계수(ICC) 산출, Pearson 상관분석을 실시하여 채점-재채점 신뢰도를 분석하고자 한다. 채점 결과를 분석한 후 일관성 유형, 쓰기평가 효능감, 경력과 성별에 따른 채점-재채점 신뢰도 분석을 통해 쓰기 평가자의 변인별 특성을 살펴볼 것이다. 이를 위해 다국면 Rasch 모형을 통해 평가 대상인 학생 글, 평가자인 국어교사, 논설문의 평가 기준의 세 국면을 분석하여 평가자들의 채점 일관성 유형을 분류하고자 한다. 이러한 양적 연구 결과를 보완하기 위해 평가자들과의 심층 면담을 진행하여 국어교사의 채점 일관성 신장 방안에 대해서도 논하고자 한다.

1. 전체 채점 결과

이 연구에서는 다양한 경력으로 구성된 30명의 국어교사 평가자가 1차, 2차 채점 시기에 각각 35편의 학생 글에 대해 채점하였다. 채점-재채점 신뢰도 분석의 대상이 되는 학생 글 20편을 포함하여 1차 채점 대상 글에 대한 기술통계를 정리하면 <표 Ⅳ-1>과 같다.

<표 Ⅳ-1> 1차 채점 기술통계

제시순서	최솟값	최댓값	평균	표준편차	비고
1	7	41	22.96	6.30	·
2	9	39	24.53	7.31	3번 글
3	14	40	28.26	7.05	4번 글
4	9	41	28.00	6.96	·
5	12	42	32.00	6.76	·

6	10	42	29.60	7.70	1번 글
7	9	40	28.23	7.90	2번 글
8	13	42	31.30	6.27	5번 글
9	10	35	24.26	6.13	·
10	9	33	18.90	5.91	6번 글
11	13	42	25.03	6.13	·
12	9	39	25.63	6.12	7번 글
13	12	40	26.33	6.90	8번 글
14	14	42	35.70	6.92	11번 글
15	9	37	19.93	6.41	10번 글
16	14	35	26.96	5.88	9번 글
17	12	37	29.06	6.15	·
18	26	42	39.76	4.02	12번 글
19	12	40	22.86	7.74	13번 글
20	7	35	18.66	7.35	14번 글
21	7	41	26.03	7.48	·
22	12	42	29.13	7.52	·
23	12	41	27.10	6.21	15번 글
24	11	41	26.20	7.63	·
25	9	34	24.20	6.76	16번 글
26	12	39	26.60	6.59	17번 글
27	8	35	18.93	6.40	·
28	11	42	31.83	7.59	·
29	13	42	33.63	7.53	19번 글
30	12	37	29.40	5.94	·
31	11	35	23.43	6.82	18번 글

32	10	36	22.03	7.49	·
33	14	41	30.06	7.28	·
34	14	42	25.40	6.49	·
35	14	40	29.40	6.80	20번 글

35편의 채점 글 중 채점-재채점 신뢰도 분석의 대상이 되는 학생 글의 경우 비고에 해당 글이 무엇인지 학생 글 1번부터 20번까지 밝혀 적고, 해당 칸을 음영 처리 하였다. <표 Ⅳ-1>을 살펴보면 가장 낮은 점수인 7점에 해당하는 채점 결과를 받은 글이 3편, 가장 높은 점수인 42점에 해당하는 채점 결과를 받은 글이 10편이었다. 또 30명의 평가자가 부여한 점수의 평균은 18.66점에서 39.76으로 그 편차가 큰 편이었고, 표준편차도 4.02에서 7.90으로 차이가 났다.

다음으로 위 표와 같은 방식으로 정리한 2차 채점 대상 글에 대한 기술통계는 <표 Ⅳ-2>와 같다.

<표 Ⅳ-2> 2차 채점 기술통계

제시순서	최솟값	최댓값	평균	표준편차	비고
1	20	42	31.70	7.39	·
2	17	38	28.10	5.22	·
3	7	35	19.03	6.74	6번 글
4	12	38	23.33	7.46	·
5	13	39	25.96	6.33	16번 글
6	20	41	32.06	5.48	2번 글
7	7	34	19.60	6.61	·
8	7	40	22.10	8.20	14번 글
9	7	40	21.67	8.12	·
10	7	42	31.86	6.81	5번 글

11	7	38	27.57	7.22	·
12	11	37	20.76	6.98	10번 글
13	16	41	32.00	7.25	·
14	13	40	30.06	7.23	20번 글
15	13	38	25.56	7.19	3번 글
16	14	38	26.33	6.29	·
17	14	42	27.96	6.76	4번 글
18	12	41	30.56	7.66	·
19	14	40	28.13	6.17	15번 글
20	14	38	27.03	6.05	8번 글
21	12	41	28.53	6.96	·
22	14	40	26.20	7.47	13번 글
23	19	42	36.03	5.59	19번 글
24	14	40	24.83	6.99	·
25	11	36	23.96	5.97	18번 글
26	14	34	26.30	5.55	·
27	14	41	27.00	6.49	7번 글
28	11	40	27.90	6.04	9번 글
29	9	34	22.13	6.52	·
30	14	40	28.03	7.09	17번 글
31	13	42	34.15	6.84	·
32	20	42	36.50	5.67	11번 글
33	15	40	30.56	6.88	·
34	9	41	31.00	8.37	1번 글
35	27	42	40.03	3.71	12번 글

<표 Ⅳ-2>를 살펴보면 가장 낮은 점수인 7점에 해당하는 채점 결과를 받은 글이 6편, 가장 높은 점수인 42점에 해당하는 채점 결과를 받은 글이 7편이 나왔다. 또 30명의 평가자가 부여한 점수의 평균은 19.03점에서 40.03으로 그 편차가 큰 편이었고, 표준편차도 3.71에서 8.37로 1차 채점보다 더 큰 차이를 보였다.

2. 채점, 재채점 기술통계

1차, 2차 채점 시기에 평가자들에게 제시된 학생 글 중 동일한 학생의 글 20편에 대해서는 채점과 재채점이 이루어졌다. 동일한 학생 글에 대해 평가자들이 채점과 재채점을 한 결과의 평균을 정리한 기술통계는 <표 Ⅳ-3>과 같다.

<표 Ⅳ-3> 학생 글 채점, 재채점 결과

학생 글	1차 채점	2차 채점	계	학생 글	1차 채점	2차 채점	계
1	29.60	31.00	30.30	11	35.70	36.50	36.10
2	28.23	32.06	30.15	12	39.76	40.03	39.90
3	24.53	25.56	25.05	13	22.86	26.20	24.53
4	28.26	27.96	28.11	14	18.66	22.10	20.38
5	31.30	31.86	31.58	15	27.10	28.13	27.61
6	18.90	19.03	18.97	16	24.20	25.96	25.08
7	25.63	27.00	26.31	17	26.60	28.03	27.32
8	26.33	27.03	26.68	18	23.43	23.96	23.70
9	26.96	27.90	27.43	19	33.63	36.03	34.83
10	19.93	20.76	20.34	20	29.40	30.06	29.73

30명의 평가자로부터 부여 받은 채점 결과의 평균이 가장 높은 학생 글은 1차 채점과 2차 채점에서 동일하게 12번 학생 글이다. 1차 채점에서는 39.76, 2차 채

점에서는 40.03으로 가장 높은 평균 점수를 받아, 가장 낮은 평균 점수를 받은 학생 글과 비교할 때 1차 채점에서는 21.10, 2차 채점에서는 21.00으로 그 차이가 컸다. 1차 채점과 2차 채점에서 부여 받은 평균 점수의 차이를 살펴보면 6번 학생 글은 평균 점수 차이가 0.13으로 가장 작았고, 2번 학생 글은 3.83으로 그 차이가 가장 컸다. 개별 평가자가 부여한 점수의 차이는 있으나 모든 평가자가 부여한 점수의 평균 점수로 볼 때는 동일 학생 글에 대한 1차 채점과 2차 채점의 점수 차이가 크지 않은 것으로 보인다.

다음으로 30명의 평가자가 전체 학생 글 20편에 부여한 평가자별 채점 결과의 기술통계를 제시하면 <표 Ⅳ-4>와 같다.

<표 Ⅳ-4> 평가자별 채점, 재채점 결과

평가자	1차 채점				2차 채점			
	최솟값	최댓값	평균	표준편차	최솟값	최댓값	평균	표준편차
1	16	38	28.30	7.21	25	42	34.25	4.79
2	33	42	37.90	2.86	32	42	37.05	3.17
3	18	34	26.20	5.74	23	42	29.50	5.45
4	11	42	26.15	9.62	10	42	30.20	9.11
5	19	42	27.20	6.05	21	42	30.15	6.24
6	11	42	25.40	9.38	10	42	22.75	7.77
7	28	41	32.70	3.79	28	41	33.00	2.97
8	12	41	25.25	7.48	15	40	25.15	7.37
9	20	42	31.55	6.62	13	42	29.05	7.33
10	17	42	25.65	6.96	16	42	28.10	6.85
11	10	41	18.55	8.87	9	40	22.35	10.00

12	7	26	12.85	4.76	7	28	16.70	6.39
13	23	42	34.40	4.92	28	42	34.55	4.70
14	19	42	28.65	6.05	15	41	27.30	7.41
15	20	42	33.75	6.06	20	41	32.30	5.99
16	11	41	24.25	6.88	18	41	25.50	7.80
17	15	42	28.10	6.09	12	42	28.45	8.12
18	16	40	29.85	7.93	15	42	32.05	7.04
19	17	36	25.95	5.98	15	38	25.40	6.35
20	13	42	30.80	8.06	18	42	30.95	7.90
21	15	41	27.00	7.16	15	42	26.85	7.32
22	9	41	22.15	9.26	13	41	26.45	7.49
23	22	42	28.70	6.22	17	35	24.45	5.33
24	13	38	20.80	6.81	18	42	29.35	6.31
25	32	41	35.20	3.05	34	42	38.15	2.30
26	18	42	27.85	7.90	18	42	33.40	7.65
27	10	42	25.35	8.89	12	42	23.40	7.54
28	13	36	19.50	6.74	11	39	17.65	7.07
29	15	41	25.20	7.09	14	37	26.65	6.69
30	17	41	26.50	6.49	19	40	29.75	6.81
계	16.66	40.16	27.05	6.69	17.36	40.53	28.36	6.57

학생 글 20편에 대해 총점이 42점인 채점에서 국어교사 30명은 1차 채점에서는 평균적으로 27.05점을 부여했고, 2차 채점에서는 평균적으로 28.36점을 부여

하여 2차 채점에서 더 관대하게 채점했다고 볼 수 있으나 그 차이는 1.31점으로 매우 작았다. 1차 채점, 2차 채점에서의 최솟값과 최댓값을 비교하면, 최솟값은 각각 16.66점과 17.36점, 최댓값은 각각 40.16점, 40.53점으로 모두 2차 채점에서 더 높았다. 이를 통해 2차 채점에서 더 관대하게 채점했다고 볼 수 있으나 그 차이는 각각 0.7점, 0.37점으로 매우 작았다. 표준편차의 경우 1차 채점에서는 6.69, 2차 채점에서는 6.57로 근소한 차이로 1차 채점에서 평가자들의 점수 분포가 더 넓게 나타났다.

3. 평가자별 채점-재채점 신뢰도

채점-재채점에 신뢰도 분석을 위해 평가자 30명의 채점-재채점 급내 상관계수(ICC)와 Pearson 상관계수(r)를 산출하였다. 평가자별 채점-재채점 상관계수는 <표 Ⅳ-5>와 같다.

<표 Ⅳ-5> 평가자별 채점-재채점 상관계수

평가자	ICC	p	r	p
1	.221	.221	.192	.417
2	.732	.002	.592	.006
3	.787	< .001	.754	< .001
4	.875	< .001	.846	< .001
5	.776	< .001	.698	< .001
6	.836	< .001	.757	< .001
7	.862	< .001	.773	< .001
8	.918	< .001	.841	< .001

9	.873	< .001	.821	< .001
10	.871	< .001	.812	< .001
11	.777	< .001	.682	< .001
12	.563	.015	.493	.027
13	.652	.016	.471	.036
14	.851	< .001	.761	< .001
15	.901	< .001	.837	< .001
16	.798	< .001	.668	.001
17	.862	< .001	.780	< .001
18	.883	< .001	.823	< .001
19	.693	.008	.521	.019
20	.788	< .001	.639	.002
21	.904	< .001	.817	< .001
22	.789	< .001	.744	< .001
23	.732	< .001	.733	< .001
24	.597	< .001	.783	< .001
25	.566	.001	.647	.002
26	.770	< .001	.779	< .001
27	.886	< .001	.820	< .001
28	.851	< .001	.759	< .001
29	.808	< .001	.683	< .001
30	.741	< .001	.649	.002

<표 Ⅳ-5>를 살펴보면 채점에 참여한 평가자 30명 중 채점-재채점 신뢰도 분석의 대상인 20편의 학생 글 평가에서 통계적으로 유의한 상관관계를 보이지 못한 평가자는 1명(3.33%)이었다. 통계적으로 유의한 상관관계를 보인 29명(96.66%)의 평가자들의 경우 12번 평가자의 상관계수 0.563부터 8번 평가자의 상관계수 0.918까지 다양하게 나타났다.

급내 상관계수(ICC)는 두 가지 이상의 검사나 둘 이상의 평가자의 평가 결과에 대한 일치도를 분석하는 방법으로 0부터 1까지의 수로 표기한다. 1은 완벽한 일치도를, 0은 일치도가 전혀 없는 것으로 판단하며, 일반적으로 0.75 이상이면 높은 일치도를 보이는 것으로 본다. Pearson 상관계수(r)는 두 변수간의 관련성을 보여주는 것으로 Mukaka(2012)의 경우 $r < 0.3$일 때는 상관관계가 없는 것으로, $0.3 \leq r < 0.5$일 때 낮은 상관관계, $0.5 \leq r < 0.7$일 때는 중간 정도의 상관관계, $0.7 \leq r < 0.9$일 때는 높은 상관관계, $0.9 \leq r$일 때는 매우 높은 상관관계라 보았다. 이 연구에서는 Mukaka(2012)의 기준에 따라 상관계수를 분석하였다.

통계적으로 유의한 상관관계를 보인 29명의 평가자 중, 낮은 상관관계를 보인 평가자는 2명, 중간 정도의 상관관계를 보인 평가자는 9명, 높은 상관관계를 보인 평가자는 18명이었다. 매우 높은 상관관계를 보인 평가자는 없었으나, 중간 정도의 상관관계를 보인 평가자 중 5명(5번, 11번, 16번, 20번, 29번)은 Pearson 상관계수(r)가 높은 정도에 해당하는 0.7에 가까웠고, 급내 상관계수(ICC)도 '높은 일치도'를 보이는 수준으로 나타났다. 본 연구의 평가자들의 채점-재채점 신뢰도가 대체로 확보된 것을 알 수 있다.

4. 일관성 유형에 따른 채점-재채점 신뢰도의 차이

가. 모형 적합도 검사

채점 일관성 유형에 따라 채점-재채점 신뢰도를 산출하고 유형별로 평가자의 특성을 살펴보기에 앞서, 수집된 채점 결과가 다국면 Rasch 모형으로 분석하기에 적합한지 알아보기 위해 모형적합도 검사를 실시했다. 이 연구에서 국어교사 30명이 학생 글 20편에 대해 수행한 두 차례의 채점 결과에 대한 모형 적합도 검사 결과는 각각 <그림 Ⅳ-1>, <그림 Ⅳ-2>와 같다.

<그림 Ⅳ-1> 1차 채점 결과의 모형 적합도 검사 결과

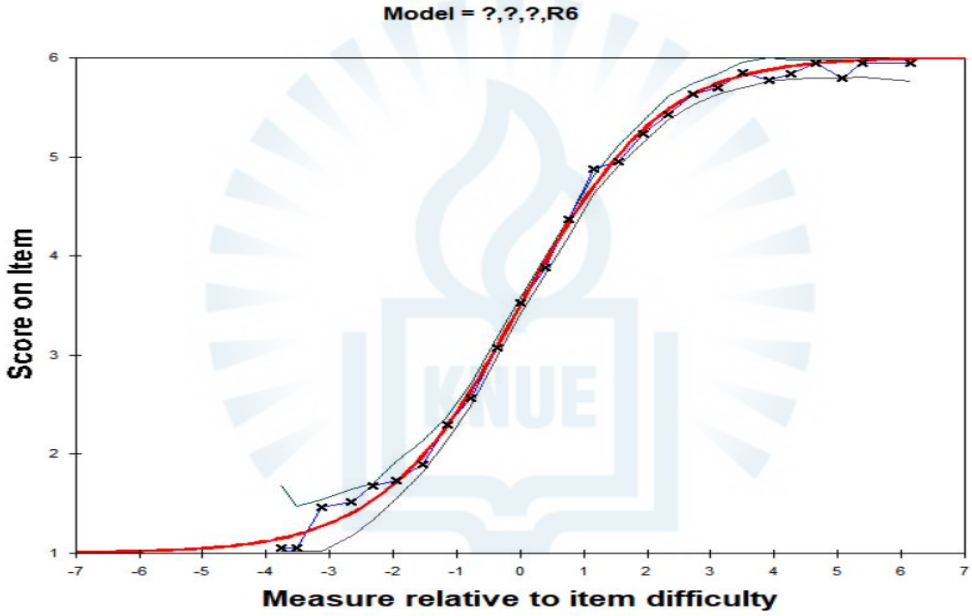

<그림 Ⅳ-2> 2차 채점 결과의 모형 적합도 검사 결과

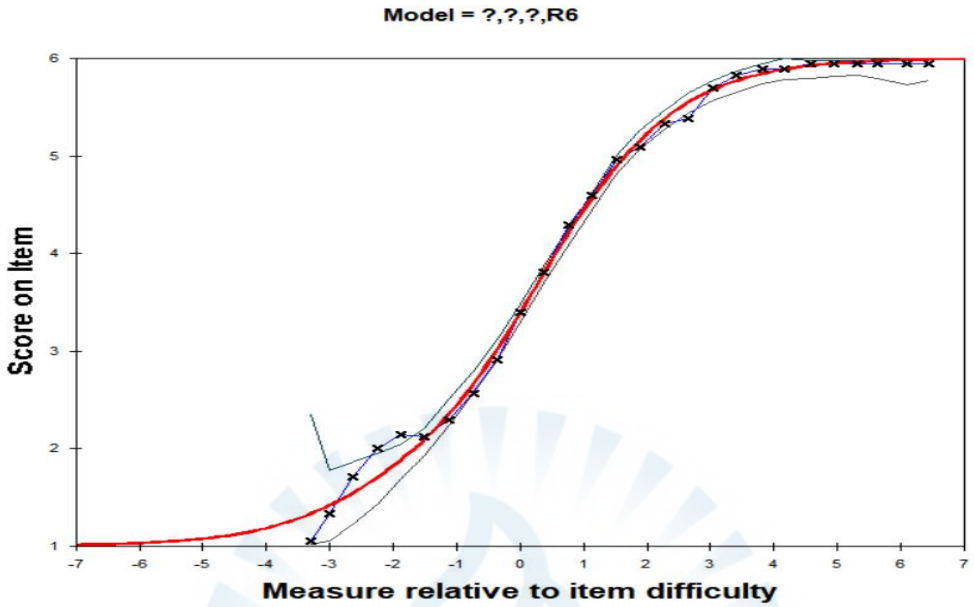

다국면 Rasch 모형으로 분석하려면 하나의 검사가 단일능력이나 특성을 측정하는 동질적인 문항으로 구성되어 있다는 일차원성의 가정을 만족해야 하고, 모든 채점자가 일정 분량의 공통 답안에 의해 연결되는 채점을 해야 한다. <그림 Ⅳ-1>와 <그림 Ⅳ-2>에 제시된 그래프를 통해 이론적인 문항 반응 곡선과 실제 채점 결과에서 나타난 반응 빈도 간의 관계를 알 수 있다. 그래프의 가로축은 '학생 능력 및 과제 난도 추정치'를 나타내고, 세로축은 그에 대한 기대 점수를 나타낸다. 그래프 상의 'x'는 관찰된 평가 점수로 평가자들이 부여한 것이고, 문항 특성 곡선인 붉은 곡선을 중심으로 양쪽에 95% 신뢰구간을 의미하는 얇은 선이 있다. 관찰 점수 'x'가 이 양쪽 얇은 두 선 안에 위치하면 평가 결과를 다국면 Rasch 모형으로 분석하기에 적합하다는 것을 의미한다.

<그림 Ⅳ-1>와 <그림 Ⅳ-2>의 그래프에서 볼 수 있듯 1차 채점, 2차 채점의 결과 모두 관찰된 평가 점수인 'x'가 대부분 두 실선 사이에 위치하여 95%의 신뢰구간 내에 있기 때문에 다국면 Rasch 모형에 적합한 자료임을 알 수 있다. 따라서 평가자인 국어교사 30명의 채점 결과 자료를 사용하여 이후 다국면

Rasch 분석을 진행하였다.

나. 평가자 일관성

이 연구에서는 FACETS 프로그램으로 다국면 Rasch 분석을 실시하여 학생 글, 평가자, 평가 기준이라는 세 국면에 대한 측정단면분포도 결과를 얻었다. 이는 세 가지 국면에 대한 총체적 분석 결과가 여러 개의 칸(column)으로 나타난다. <그림 Ⅳ-3>은 1차 채점 결과의 측정단면분포도이다.

<그림 Ⅳ-3> 1차 채점 결과의 측정단면분포도

```
Vertical = (1N,2A,3A,S) Yardstick (columns lines low high extreme)= 0,4,-3,3,End
+-----------------------------------------------------------------------------+
|Measr|+examinee    |-rater                                |-criteria |Scale|
|-----+-------------+--------------------------------------+----------+-----|
|   3 +             +                                      +          + (6) |
|     | 12          |                                      |          |     |
|     |             |                                      |          | --- |
|     |             |                                      |          |     |
|   2 +             + 12                                   +          +     |
|     |             |                                      |          |     |
|     | 11          |                                      |          |  5  |
|     |             |                                      |          |     |
|   1 + 19          +                                      +          + --- |
|     |             | 11  28                               |          |     |
|     | 5           | 24                                   | C-3      |  4  |
|     | 1  20       | 22                                   | C-2  O-1 |     |
*   0 * 2  4  9  15 * 16                                   * E-1  O-2 * --- *
|     | 7  8  17    | 10  19  27  29  3   30  4   6   8    | C-1      |     |
|     | 3  16 18    | 1   17  21  26  5                    |          |  3  |
|     | 13          | 14  18  23                           |          |     |
|  -1 + 10          + 20  9                                + E-2      + --- |
|     | 6  14       | 7                                    |          |     |
|     |             | 15                                   |          |  2  |
|     |             | 13  25                               |          |     |
|  -2 +             +                                      +          +     |
|     |             |                                      |          |     |
|     |             | 2                                    |          | --- |
|     |             |                                      |          |     |
|  -3 +             +                                      +          + (1) |
|-----+-------------+--------------------------------------+----------+-----|
|Measr|+examinee    |-rater                                |-criteria |Scale|
+-----------------------------------------------------------------------------+
```

<그림 Ⅳ-3>에서 첫째 칸(Measr)은 학생 글, 평가자, 평가 기준에 대한 측정 척도를 보여준다. 단위는 logit을 사용하고 기준점은 0으로 고정되어 있다.

둘째 칸(+examinee)은 채점 대상이 된 학생 글 20편의 분포를 보여주는데 해당 칸을 분석하면 해당 글의 수준을 파악할 수 있다. 이는 학생들이 쓰기 과제를 통해 보여준 쓰기 능력이라 할 수 있으며 상위에 위치할수록 높은 수준을, 하위에 위치할수록 낮은 수준을 의미한다. 여기서 examinee 앞에 붙은 '+' 부호는 이처럼 글의 수준이 높을 때 상위에 위치하게 한다는 것을 의미한다. 이에 따라 분석해 볼 때 학생 글 12는 가장 높은 수준, 학생 글 6과 14는 가장 낮은 수준의 글임을 의미한다. 다시 말해 글 12를 쓴 학생의 쓰기 능력이 가장 우수하고 글 6과 14를 쓴 학생의 쓰기 능력이 가장 낮은 것으로 볼 수 있다.

셋째 칸(-rater)은 채점에 참여한 평가자 30명의 엄격성을 보여주는데 해당 칸을 통해 각 평가자들의 채점 엄격성 정도를 비교할 수 있다. 상위에 위치할수록 엄격하고 하위에 위치할수록 관대하게 평가한다고 볼 수 있다. 여기서 rater 앞에 붙은 '-' 부호는 엄격할수록 상위에 위치하게 한다는 것을 의미한다. 이에 따라 분석해 볼 때 30명의 평가자 중 12번 평가자가 가장 엄격하게 평가하고 2번 평가자가 가장 관대하게 평가한 것을 알 수 있다. 또 logit 값 0에 위치한 16번 평가자의 경우 평균적인 채점 엄격성을 가졌다고 볼 수 있다. logit 값 0을 기준으로 살펴보았을 때 엄격한 평가자보다 관대한 평가자가 더 많은 편이며 평가자 개인마다 엄격성 차이가 존재하다는 것을 알 수 있다. 가장 엄격한 평가자인 12번과 가장 관대한 평가자인 2번을 비교할 때 그 차이가 4 logit 단위 이상이기 때문에 같은 쓰기평가에서도 평가자의 엄격성에 따라 다른 채점 결과를 얻을 수 있다는 점에서 쓰기평가의 신뢰도 문제가 있을 수 있다고 보인다.

넷째 칸(-criteria)은 평가 기준의 요소별 난도를 보여주는데 이를 통해 여러 평가 요소 중 어떤 요소가 가장 엄격한지 즉 점수를 받기 어려운 요소인지를 파악할 수 있다. 상위에 위치할수록 난도가 높은 평가 요소임을 의미한다. 여기서 C1, C2, C3은 각각 내용 범주의 평가 기준인 '주장이 명료한가?', '근거가 주장을

뒷받침하기에 타당한가?', '근거가 주장을 뒷받침하기에 구체적이고 풍부한가?'를 의미하고, O1, O2는 각각 조직 범주의 평가 기준인 '서론-본론-결론의 체계적인 구조를 갖추었는가?', '문장 또는 문단이 유기적으로 연결되었는가?'를 의미한다. E1과 E2는 각각 표현 범주의 평가 기준인 '단어 사용이 적절하고 문장을 명료하게 진술하였는가?', '어문규범에 맞게 표현되었는가?'를 의미한다. 이에 따라 분석해 볼 때 7개의 평가 요소 중 내용 범주의 세 번째 평가 요소인 '근거가 주장을 뒷받침하기에 구체적이고 풍부한가?'가 가장 난도가 높은, 엄격하게 평가된 요소이고, 표현 범주의 두 번째 요소인 '어문규범에 맞게 표현되었는가?'가 가장 난도가 낮은, 관대하게 평가된 요소임을 알 수 있다.

다섯 째 칸(Scale)은 채점 척도의 사용 양상에 대해 보여주는데 이 연구에서 사용한 6점 척도의 logit 값이 내림차순으로 배열되어 있다.

다음으로 <그림 Ⅳ-4>는 2차 채점 결과의 측정단면분포도이다.

<그림 Ⅳ-4> 2차 채점 결과의 측정단면분포도

```
Vertical = (1N,2A,3A,S) Yardstick (columns lines low high extreme)= 0,4,-3,3,End
+-------------------------------------------------------------------+
|Measr|+examinee        |-rater              |-criteria      |Scale|
|-----+-----------------+--------------------+---------------+-----|
|   3 +                 +                    +               + (6) |
|     | 12              |                    |               |     |
|     |                 |                    |               | --- |
|     |                 |                    |               |     |
|   2 +                 +                    +               +     |
|     |                 |                    |               |  5  |
|     | 11              |                    |               |     |
|     | 19              | 12                 |               |     |
|   1 +                 + 28                 +               + --- |
|     |                 |                    |               |     |
|     | 2  5            |                    | C-3           |  4  |
|     | 1  20           | 11  6              | C-2  O-1  O-2 |     |
*   0 * 15              * 23  27             *               * --- *
|     | 4  7  8  9  17  | 16  19  8          | C-1  E-1      |  3  |
|     | 3  13 16        | 14  21  22  29     |               |     |
|     | 18              | 10  17  9          |               |     |
|  -1 + 14              + 24  3   30  4   5  + E-2           + --- |
|     | 10              | 18  20             |               |     |
|     | 6               | 15  26  7          |               |     |
|     |                 | 1   13             |               |  2  |
|  -2 +                 +                    +               +     |
|     |                 |                    |               |     |
|     |                 | 2                  |               |     |
|     |                 | 25                 |               | --- |
|  -3 +                 +                    +               + (1) |
|-----+-----------------+--------------------+---------------+-----|
|Measr|+examinee        |-rater              |-criteria      |Scale|
+-------------------------------------------------------------------+
```

<그림 Ⅳ-4>에 따르면 1차 채점 결과에서와 마찬가지로 학생 글 12는 가장 높은 수준, 학생 글 6은 가장 낮은 수준의 글임을 알 수 있다. 다시 말해 글 12를 쓴 학생의 쓰기 능력이 가장 우수하고 글 6을 쓴 학생의 쓰기 능력이 가장 낮은 것으로 평가되었다. 하지만 학생 글 14의 경우 채점 결과에서 학생 글 6과 마찬가지로 가장 낮은 수준의 글로 평가되었으나, 2차 채점 결과에서는 근소한 차이로 높게 평가되었다. 하지만 채점, 재채점 결과 모두 학생 글 6, 10, 14가 가장 하위에 위치한 것으로 보아 주목할 만한 차이는 아니다. 이로 살펴볼 때 1차 채점, 2차 채점에서 평가자들이 가장 우수한 글과 가장 그렇지 못한 글을 판단하는 데에 일관된 평가를 했다고 볼 수 있다.

평가자의 엄격성을 비교할 때 1차 채점 결과에서와 마찬가지로 2차 채점에서도 30명의 평가자 중 12번 평가자가 가장 엄격하게 평가하였고 2번 평가자는 관대한 평가를 보였다. logit 값 0에 위치한 23번, 27번 평가자의 경우 2차 채점에서 평균적인 채점 엄격성을 보였다고 볼 수 있다. logit 값 0을 기준으로 살펴보았을 때 2차 채점에서도 엄격한 평가자보다 관대한 평가자가 더 많은 편이며 평가자 개인마다 엄격성 차이가 존재한다는 것을 알 수 있다. 25번 평가자의 경우 1차 채점 시기에 비해 2차 채점에서 다소 관대한 엄격성을 보여, 1차 채점 결과에서 가장 관대한 평가자였던 2번 평가자보다 더 하위에 위치했다.

평가 기준의 요소별 난도의 경우 7개의 평가 요소 중 1차 채점 결과에서와 마찬가지로 내용 범주의 세 번째 평가 요소인 '근거가 주장을 뒷받침하기에 구체적이고 풍부한가?'가 가장 난도가 높은, 엄격하게 평가된 요소로 나타났고, 표현 범주의 두 번째 요소인 '어문규범에 맞게 표현되었는가?'가 가장 난도가 낮은, 관대하게 평가된 요소로 나타났다. 이를 통해 평가자들이 1차 채점, 2차 채점에서 여러 평가 요소 중 일관되게 근거의 풍부성을 가장 엄격하게, 어문규범 준수를 가장 관대하게 평가하는 경향이 있음을 알 수 있다. 윤금준(2021)에서도 평가의 요인은 본 연구와 차이가 있으나 채점과 재채점 결과 가장 엄격하거나 가장 관대하게 평가한 요인이 동일했다.

다음 <표 Ⅳ-6>는 평가자 30명의 채점-재채점 결과에 대한 단면 출력 정보를 통해 평가자의 엄격성과 일관성을 비교한 것이다.

<표 Ⅳ-6> 채점-재채점에서의 평가자 엄격성 및 일관성 비교

평가자	1차 채점				2차 채점			
	Measure	SE	InfitMS	InfitZ	Measure	SE	InfitMS	InfitZ
1	-0.61	0.09	1.12	1.03	-1.76	0.10	0.98	-0.10
2	-2.49	0.12	0.82	-1.31	-2.41	0.12	0.63	-3.06
3	-0.30	0.09	0.71	-2.87	-0.91	0.09	0.68	-3.14
4	-0.29	0.09	1.40	3.20	-1.02	0.09	1.29	2.35
5	-0.44	0.09	0.66	-3.40	-1.01	0.09	1.09	0.80
6	-0.18	0.09	0.98	-0.11	0.16	0.09	0.85	-1.37
7	-1.32	0.09	0.66	-3.14	-1.51	0.10	0.72	-2.57
8	-0.16	0.09	0.91	-0.79	-0.22	0.09	0.84	-1.44
9	-1.12	0.09	0.77	-2.09	-0.84	0.09	0.73	-2.60
10	-0.22	0.09	0.82	-1.70	-0.68	0.09	0.62	-3.82
11	0.86	0.09	1.55	4.02	0.23	0.09	1.49	3.73
12	2.02	0.12	0.84	-1.17	1.27	0.10	1.10	0.78
13	-1.64	0.10	0.75	-2.16	-1.82	0.10	1.00	0.02
14	-0.66	0.09	0.50	-5.26	-0.56	0.09	0.52	-5.10
15	-1.51	0.10	1.32	2.36	-1.38	0.09	1.31	2.43
16	-0.01	0.09	0.91	-0.81	-0.28	0.09	0.96	-0.36
17	-0.58	0.09	0.57	-4.42	-0.74	0.09	0.71	-2.85

18	-0.84	0.09	1.35	2.73	-1.34	0.09	1.23	1.83
19	-0.26	0.09	1.19	1.64	-0.26	0.09	1.43	3.38
20	-1.00	0.09	1.36	2.76	-1.15	0.09	1.64	4.65
21	-0.41	0.09	0.89	-0.93	-0.49	0.09	1.28	2.31
22	0.29	0.09	1.44	3.45	-0.43	0.09	0.84	-1.44
23	-0.67	0.09	0.56	-4.48	-0.11	0.09	0.68	-3.09
24	0.50	0.09	1.02	0.17	-0.88	0.09	0.42	-6.56
25	-1.80	0.10	0.72	-2.39	-2.75	0.13	0.65	-2.68
26	-0.54	0.09	1.38	2.98	-1.59	0.10	2.03	6.59
27	-0.17	0.09	0.93	-0.61	0.05	0.09	1.21	1.74
28	0.70	0.09	1.05	0.45	1.07	0.10	0.89	-0.84
29	-0.15	0.09	1.23	1.97	-0.46	0.09	0.80	-1.89
30	-0.34	0.09	0.99	-0.06	-0.95	0.09	0.97	-0.21

· 1차 채점 통계치 해석

Model, Populn: RMSE .09 Adj (True) S.D. .84 Separation 9.26 Strata 12.68 Reliability (not inter-rater) .99

Model, Sample: RMSE .09 Adj (True) S.D. .86 Separation 9.42 Strata 12.89 Reliability (not inter-rater) .99

Model, Fixed (all same) chi-square: 2016.5 d.f.: 29 significance (probability): .00

Model, Random (normal) chi-square: 28.6 d.f.: 28 significance (probability): .43

Inter-Rater agreement opportunities: 60900 Exact agreements: 15986 = 26.2% Expected: 15218.7 = 25.0%

· 2차 채점 통계치 해석

Model, Populn: RMSE .09 Adj (True) S.D. .86 Separation 9.11 Strata 12.47 Reliability (not inter-rater) .99

Model, Sample: RMSE .09 Adj (True) S.D. .88 Separation 9.26 Strata 12.68 Reliability (not inter-rater) .99

Model, Fixed (all same) chi-square: 2095.1 d.f.: 29 significance (probability): .00

Model, Random (normal) chi-square: 28.6 d.f.: 28 significance (probability): .43

Inter-Rater agreement opportunities: 60900 Exact agreements: 16848 = 27.7% Expected: 16004.9 = 26.3%

<표 Ⅳ-6>에서 평가자 30명의 1차 채점과 2차 채점 결과의 측정 값(Measure), 표준오차(SE), 내적합 지수(Infit MnSq), 내적합 표준화 값(Infit

Zstd)을 제시하고 각 결과의 통계치 해석 수치를 덧붙였다. 채점자의 엄격성을 알아볼 수 있는 'Measure' 값은 채점 일관성에 미치는 영향을 조정한 logit 값으로, 관찰 원점수(Observed Score)를 Rasch 측정이론의 적용으로 변형한 측정치이다. logit 값 0을 기준으로 이보다 작으면 관대한 평가자, 높으면 엄격한 평가자로 해석할 수 있다. 'SE' 값은 정확성에 대한 정보를 제공하는 표준오차로 0에 가까울수록 정확도가 높다고 볼 수 있다. 내적합 지수와 내적합 표준화 값을 통해서는 채점자의 일관성을 알아볼 수 있다. 외적합 지수(Outfit MnSq)는 모든 관찰 점수를 포함하여 산출된 적합도 값이기 때문에 예상치 못한 극단적 관찰 값이 전체 적합도에 적절하지 못한 영향력을 제공할 수 있으나, 내적합 지수는 극단적 관찰 값을 배제하여 산출한 적합도 값이기에 보다 적절한 정보를 제공할 수 있다고 여겨진다(신동일 2001).

먼저 1차 채점 결과를 통해 평가자의 엄격성을 살펴보면 평가자의 엄격성 분포 범위는 4.51 logit으로, 2.02 logit(SE=0.12)을 보인 가장 엄격한 12번 평가자에서부터 -2.49 logit(SE=0.12)을 보인 가장 관대한 2번 평가자까지 다양했다. 통계치 해석에서 분리도(Separation)는 채점 엄격성 수준의 상대적인 분포를 보여주는 것으로, 분리될 수 있는 채점자 엄격성 단면의 수를 나타낸다. 여기서 분리도는 9.26으로 채점 엄격성이 9개 수준으로 나뉜다는 것을 의미한다. 분리신뢰도(Reliability)는 채점자의 엄격성 차이를 보여주는 지수로, 낮은 값일수록 서로 다른 채점자들이 비슷한 엄격성을 가진다고 해석할 수 있다. 여기서는 .99로 나타나 채점자들 간의 엄격성 수준의 편차가 크다 볼 수 있다. 또 카이스퀘어(chi-square) 검증으로 채점자 집단의 엄격성에 대한 신뢰성을 확인해볼 수 있다. 모든 채점자의 엄격성이 같다는 영가설(null hypothesis)을 검증한 결과 카이스퀘어 값은 2016.5이며 p값은 .00이기에 영가설을 기각하고, 채점자 집단의 엄격성 차이는 크다는 것을 알 수 있다.

채점자 간 일치도는 '실제일치도(Exact agreements)-기대일치도(Expected)/100-기대일치도'로 산출되는데, 이 값이 '-' 값을 보이면 예측된 채점

자 간 일치도에 비해 실제 채점자 간의 채점 불일치가 크다는 것을 의미하고, '+' 값을 보이면 채점자 간의 편차가 충분하지 않아 기대 이상의 과적합 양상을 보인다고 할 수 있다. 여기서는 실제일치도가 26.2%, 기대일치도가 25.0%로 채점자 간 일치도가 0.016 logit 값으로 나온다. 과적합 양상을 약간 보이지만 모형을 통해 예측된 채점자 간 일치도와 실제 채점자 간의 일치도가 유사한 것으로 볼 수 있다.

내적합 지수와 내적합 표준화 값을 통해 평가자의 일관성을 살펴볼 때, 연구자에 따라 적합한 일관성 수준을 어떻게 판단하느냐에 차이가 있지만 이 연구에서는 McNamare(1996)에 따라 0.75~1.3 범위에 있으면 적합한 일관성을 보이는 것으로, 0.75 미만의 값을 보이면 과적합 일관성으로, 1.3을 초과한 값을 보이면 부적합 일관성으로 분류하였다. 내적합 표준화 값의 경우 '+2' 이상을 보이는 경우 유의미한 수준에서 다른 채점자들에 비해 일관성이 부족한 부적합 양상으로 볼 수 있고, '-2' 이하를 보일 때에는 유의미한 수준에서 일관성 정도를 과적합 양상으로 볼 수 있다(신동일 2001:12). 0.75~1.3 범위에 따라 일관성을 판단하면서 0.75나 1.3과 같이 기준점의 경계에 있는 경우 내적합 표준화 값을 함께 적용하고자 한다. 이에 따라 채점 결과에서 평가자 일관성을 살펴보면 적합한 일관성을 보인 평가자는 1번, 2번, 6번, 8번, 9번, 10번, 12번, 16번, 19번, 21번, 24번, 27번, 28번, 29번, 30번 평가자이고, 과적합 양상을 보인 평가자는 3번, 5번, 7번, 13번, 14번, 17번, 23번, 25번 평가자, 부적합 양상을 보인 평가자는 4번, 11번, 15번, 18번, 20번, 22번, 26번 평가자이다.

다음으로 2차 채점 결과에서 평가자의 엄격성을 살펴보면 평가자의 엄격성 분포 범위는 4.02 logit으로, 1차 채점 결과에서 가장 엄격한 평가자로 나타난 12번 평가자가 2차 채점 결과에서도 1.27 logit(SE=0.10)으로 가장 엄격한 것으로 나타났다. 1차 채점 결과에서 가장 관대한 평가자였던 2번 평가자는 2차 채점 결과에서 -2.41 logit(SE=0.12)로 두 번째로 관대한 엄격성을 보였고, 1차 채점 결과에서 두 번째로 관대한 엄격성을 보인 25번 평가자가 2차 채점 결과에서는

-2.75 logit(SE=0.13)로 가장 관대한 평가자로 나타나 큰 차이를 보이지는 않았다. 분리도는 9.11로 채점 엄격성은 1차 채점 결과와 마찬가지로 9개 수준으로 나뉜다는 것을 의미한다. 분리신뢰도는 .99로 나타나 1차 채점 결과와 마찬가지로 2차 채점 결과에서도 채점자들 간의 엄격성 수준의 편차가 컸다. 모든 채점자의 엄격성이 같다는 영가설을 검증한 결과 카이스퀘어 값은 2095.1이며 p값은 .00이기에 영가설을 기각하고, 채점자 집단의 엄격성 차이는 크다는 것을 알 수 있다. 채점자 간 일치도는 실제일치도가 27.7%, 기대일치도가 26.3%로 채점자 간 일치도가 0.019 logit 값으로 나온다. 1차 채점 결과와 마찬가지로 과적합 양상을 약간 보이지만 모형을 통해 예측된 채점자 간 일치도와 실제 채점자 간의 일치도가 유사한 것으로 볼 수 있다.

2차 채점 결과의 평가자의 일관성을 살펴보면 적합한 일관성을 보인 평가자는 1번, 4번, 5번, 6번, 8번, 12번, 13번, 16번, 18번, 21번, 22번, 27번, 28번, 29번, 30번 평가자이고, 과적합 양상을 보인 평가자는 2번, 3번, 7번, 9번, 10번, 14번, 17번, 23번, 24번, 25번 평가자, 부적합 양상을 보인 평가자는 11번, 15번, 19번, 20번, 26번 평가자이다.

다. 일관성 유형에 따른 채점-재채점 신뢰도의 차이

이 연구에서는 McNamare(1996)에 따라 0.75~1.3 범위에서 평가자의 일관성 기준을 정했다. 이에 따라 채점-재채점 일관성에 따라 평가자 유형을 분류한 결과는 <표 Ⅳ-7>과 같다.

<표 Ⅳ-7> 채점-재채점 일관성에 따른 평가자 유형 분류

집단	일관성에 따른 평가자 유형		평가자	인원(%)
	1차 채점	2차 채점		
1	적합	적합	1번, 6번, 8번, 12번, 16번, 21번, 27번, 28번, 29번, 30번	10(33.33)
2	과적합	적합	5번, 13번	6(20.00)
	적합	과적합	2번, 9번, 10번, 24번	
3	부적합	적합	4번, 18번, 22번	4(13.33)
	적합	부적합	19번	
4	과적합	과적합	3번, 7번, 14번, 17번, 23번, 25번	6(20.00)
5	과적합	부적합	·	0(0.00)
	부적합	과적합	·	
6	부적합	부적합	11번, 15번, 20번, 26번	4(13.33)

<표 Ⅳ-7>에 따르면 집단 1은 1차 채점과 2차 채점에서 모두 일관성이 적합한 경우의 평가자로, 10명(33.33%)의 평가자가 해당된다. 집단 2는 1차 채점과 2차 채점 중 한 번은 적합한 수준의 일관성을 보였으나 다른 한 번은 과적합한 양상을 보인 평가자로, 6명(20.00%)의 평가자가 해당된다. 집단 3은 1차 채점과 2차 채점 중 한 번은 적합한 수준의 일관성을 보였으나 다른 한 번은 부적합한 양상을 보인 평가자로, 4명(13.33%)의 평가자가 해당된다. 집단 4는 1차 채점과 2차 채점 결과 모두 과적합한 양상의 일관성 수준을 보인 평가자로, 6명(20.00%)의 평가자가 해당된다. 집단 5는 1차 채점과 2차 채점 중 한 번은 과적합한 양상을 보였으나 다른 한 번은 부적합한 양상을 보인 평가자로, 본 연구에서 해당되는 평가자가 없었다. 집단 6은 1차 채점과 2차 채점 결과 모두 부적합한 양상의 일관성 수준을 보인 평가자로, 4명(13.33%)의 평가자가 해당된다.

일관성 수준이 '적합' 하다는 것은 채점 회기 동안 엄격성을 일관되게 유지한

다는 것으로, '과적합' 하다는 것은 비슷한 점수만 부여해서 세부적인 변별을 하지 못한다는 것으로, '부적합' 하다는 것은 예측할 수 없는 점수를 부여하여 점수에 일관성이 없다는 것을 의미한다(박종임 2013, 최숙기·박영민 2011). 1차 채점과 2차 채점 모두에서 일관성이 적합한 수준을 유지한 평가자가 33.33%로 윤금준(2021)에서 25.00%인 것에 비해서는 다소 높은 비중을 보였다. 하지만 1차 채점과 2차 채점 모두 일관성을 보이지 못하는 부적합 양상의 일관성을 보인 평가자가13.33%로 선행 연구에서 2.78%에 그친 것에 비해 다소 높았다.

일관성 유형에 따라 분류한 집단1~6 중 일관성이 모두 적합한 집단1, 모두 과적합한 집단4, 모두 부적합한 집단6이 각각 일관성 유형을 특징적으로 보여줄 수 있기에 이 집단에 속하는 평가자의 채점-재채점 신뢰도를 분석하였다.

집단1, 4, 6에 해당하는 평가자 20명에 대한 채점-재채점 기술통계와 급내 상관계수(ICC), Pearson 상관계수(r)를 분석하면 <표 Ⅳ-8>과 같다.

<표 Ⅳ-8> 일관성 유형에 따른 채점-재채점 기술통계와 상관계수

집단	평가자	평균		표준편차		ICC	p	r	p
		1차 채점	2차 채점	1차 채점	2차 채점				
1 (적-적)	1	28.30	34.25	7.211	4.799	.221	.221	.192	.417
	6	25.40	22.75	9.388	7.772	.836	< .001	.757	< .001
	8	25.25	25.15	7.482	7.379	.918	< .001	.841	< .001
	12	12.85	16.70	4.760	6.391	.563	.015	.493	.027
	16	24.25	25.50	6.881	7.803	.798	< .001	.668	.001
	21	27.00	26.85	7.167	7.321	.904	< .001	.817	< .001
	27	25.35	23.40	8.892	7.549	.886	< .001	.820	< .001
	28	19.50	17.65	6.747	7.073	.851	< .001	.759	< .001
	29	25.20	26.65	7.097	6.698	.808	< .001	.683	< .001
	30	26.50	29.75	6.492	6.812	.741	< .001	.649	.002

4 (과적-과적)	3	26.20	29.50	5.745	5.453	.787	< .001	.754	< .001
	7	32.70	33.00	3.798	2.973	.862	< .001	.773	< .001
	14	28.65	27.30	6.054	7.413	.851	< .001	.761	< .001
	17	28.10	28.45	6.094	8.120	.862	< .001	.780	< .001
	23	28.70	24.45	6.224	5.335	.732	< .001	.733	< .001
	25	35.20	38.15	3.053	2.300	.566	.001	.647	.002
6 (부적-부적)	11	18.55	22.35	8.870	10.001	.777	< .001	.682	< .001
	15	33.75	32.30	6.060	5.992	.901	< .001	.837	< .001
	20	30.80	30.95	8.062	7.903	.788	< .001	.639	.002
	26	27.85	33.40	7.909	7.653	.770	< .001	.779	< .001
전체		26.50	27.42	6.699	6.637				

<표 Ⅳ-8>을 살펴보면 채점 결과는 평균 26.50, 표준편차 6.699, 재채점 결과는 평균 27.42, 표준편차 6.637로 큰 차이가 없었다. Pearson 상관계수(r)이 0.7 ≤ r < 0.9에 해당되어 높은 상관관계를 보인 평가자는 12명(60%), 0.5 ≤ r < 0.7에 해당되어 중간 정도의 상관관계를 보인 평가자는 6명(30%), 0.3 ≤ r < 0.5에 해당되어 낮은 상관관계를 보인 평가자가 1명(5%)이었다. 또 통계적으로 유의한 상관관계를 보이지 못한 평가자가 1명(5%)로 나타났다. 이러한 결과는 쓰기평가에서 국어교사의 채점-재채점 신뢰도가 평가자에 따라 다소 차이를 보인다는 것을 알게 한다.

통계적으로 유의하지 못한 상관관계를 보인 1번 평가자를 제외하고, 평가자의 일관성 유형에 따른 채점-재채점 신뢰도를 분석하면 <표 Ⅳ-9>와 같다.

<표 Ⅳ-9> 평가자 일관성 유형에 따른 채점-재채점 신뢰도

상관 정도 / 일관성 유형	높은 정도	중간 정도	낮은 정도	계
집단 1 (적-적)	5	3	1	9
집단 4 (과적-과적)	5	1	·	6
집단 6 (부적-부적)	2	2	·	4
계				19

<표 Ⅳ-9>를 살펴보면 먼저 집단1의 경우 높은 정도의 상관관계를 보인 평가자는 5명으로 6번, 8번, 21번, 27번, 28번 평가자가 이에 해당되고, 중간 정도의 상관관계를 보인 평가자는 3명으로 16번, 29번, 30번 평가자가 해당되었다. 낮은 정도의 상관관계를 보인 평가자는 1명으로 12번 평가자였다. 집단4의 경우 높은 정도의 상관관계를 보인 평가자는 5명으로 3번, 7번, 14번, 17번, 23번 평가자가 이에 해당되고, 중간 정도의 상관관계를 보인 평가자 1명은 25번 평가자이다. 집단6의 경우 높은 정도의 상관관계를 보인 평가자는 2명으로 15번 평가자와 26번 평가자였고, 중간 정도의 상관관계를 보인 평가자는 2명으로 11번 평가자와 20번 평가자였다. 집단4와 집단6은 낮은 정도의 상관관계를 보인 평가자는 없었다. 이를 볼 때 평가자의 일관성 유형이 어떠냐에 따라 채점-재채점 신뢰도가 일관된 경향성을 보인다고 보기는 어렵다. 이는 선행 연구에서 평가자의 일관성이 부적합한 경우 채점-재채점 신뢰도가 낮았던 것(윤금준 2021)과 다소 차이를 보이는 결과이다.

상관계수와 채점, 재채점의 평균 점수 차이, 다국면 Rasch 분석 결과, 평가자별 심층 면담 결과를 함께 활용하여, 일관성 유형에 따른 평가자 집단별 채점-재채점 신뢰도를 보다 자세히 분석해보고자 한다.

집단1의 8번 평가자가 상관계수 0.841로 19명의 평가자 중 가장 높은 상관관

계를 보였다. 급내 상관계수도 0.918로 나타나 채점-재채점 신뢰도가 가장 높은 평가자였다. 8번 평가자의 1차 채점, 2차 채점 결과의 기술 통계를 살펴보면 1차 채점 결과의 평균이 25.25, 표준편차는 7.482이고 2차 채점 결과의 평균이 25.15, 표준편차는 7.379로 평균 점수의 차이가 0.1로 매우 작았다. 쓰기평가의 채점-재채점에서 가장 일관된 평가를 보인 평가자라 할 수 있다. 8번 평가자의 평가자 요인 검사지를 살펴보면 30명의 평가자 중 유일하게 쓰기평가 연수 경험이 5회 이상이었고, 쓰기 직접 평가 경험도 '많음'에 해당되었다. 이와 관련하여 결과 분석 이후 이루어진 심층 면담에서 쓰기평가 연수와 쓰기 직접 평가 경험이 쓰기 채점에 미친 영향에 대해 다음과 같은 답변을 얻었다.

> "쓰기평가 연수가 실제적인 평가 연습을 제공하는 것이 아니었기 때문에, 평가 경험이 오히려 채점의 일관성을 유지하는 데 도움이 되었던 것 같습니다. 여러 번의 쓰기평가를 해 보면서 채점 기준의 용어에 익숙해질 수 있었고, 채점 기준을 하위 평가 요소로 분석하는 데 많은 시간을 소요하지 않은 것 같습니다. 채점 기준의 용어와 평가 요소들을 글의 어떤 특징들과 연결해야 하는지 등에 대한 것들이 내면화되어 있어, 채점을 하면서 미리 세워놓은 기준들이 크게 흔들리지 않은 것 같습니다." (F8)

채점 기준을 내면화하고 실제 채점에 적용하기 위해 드는 인지적 부담이 채점 일관성을 유지하기 어렵게 하는 이유가 되기에, 채점자의 인지적 부담을 줄여줄 수 있는 채점자 교육이 필요하다는 의견도 밝혔다.

평가자 요인과 심층 면담을 통해 채점 일관성이 높은 평가자의 경우 실제 채점을 많이 경험한 것이 채점 기준에 제시되는 용어의 추상성을 이해하고 하위 평가 요소들을 학생 글에 나타난 특징과 연결 짓는데 따르는 인지적 부담이 줄이는데 영향을 미침을 알 수 있다.

21번 평가자도 채점-재채점 신뢰도에서 상관계수 0.817과 급내 상관계수 0.904

로 높은 수준의 상관관계를 보였다. 또 1차 채점 결과의 평균이 27.00 표준편차가 7.167이고 2차 채점 결과의 평균이 26.85, 표준편차가 7.321로 1차 채점과 2차 채점 간의 평균 점수의 차이도 0.15로 매우 근소하였다.

6번 평가자는 1차 채점 결과의 평균이 25.40, 표준편차가 9.388이고 2차 채점 결과의 평균이 22.75, 표준편차가 7.772로 그 차이가 2.65로 나타나, 21번, 27번, 28번 평가자가 각각 0.15, 1.95, 1.85인 것에 비해 상대적으로 큰 차이를 보였다. 이는 6번 평가자가 1차 채점보다 2차 채점에서 보다 엄격하게 채점한 것으로 볼 수 있다. 다국면 Rasch 분석 결과를 살펴보면 이 점이 더 잘 드러난다. 채점에서 -0.18 logit(SE=0.09)으로 나타났으나, 2차 채점에서는 0.16(SE=0.09)으로 나타나 2차 채점에서 더 엄격한 채점 경향을 보였다. 이러한 결과는 1차 채점과 2차 채점에서 모두 일관성이 적합한 경우에 해당하는 집단에 속하는 평가자라 하더라도 1차 채점과 2차 채점에서 보인 엄격성의 정도에 차이가 있을 경우 결과에 차이를 가져올 수 있음을 말해준다.

30번 평가자의 경우 상관계수 0.649로 중간 정도의 상관관계를 보인 평가자인데, 상관계수 0.668인 16번 평가자나 상관계수 0.683인 29번 평가자에 비해 1차 채점과 2차 채점 결과의 평균 차이가 컸다. 1차 채점 결과의 평균이 26.50, 표준편차 6.492이고 2차 채점 결과의 평균이 29.75, 표준편차 6.812로, 3.25의 평균차이를 보였는데, 이는 낮은 정도의 상관관계를 보이는 것으로 나타난 12번 평가자 다음으로 높은 차이이다. 30번 평가자의 다국면 Rasch 분석 결과를 살펴보면 1차 채점에서 -0.34 logit(SE=0.09), 2차 채점에서 -0.95 logit(SE=0.09)로 2차 채점에서 다소 관대한 채점 경향을 보여 평균 점수가 올라간 것으로 보인다.

집단 1에 속하는 평가자들 중 1차 채점보다 2차 채점에서 더 엄격하게 채점한 6번 평가자와, 1차 채점보다 2차 채점에서 더 관대하게 채점한 30번 평가자에게 피로도, 집중도, 채점 전략 등에서 보인 변화를 묻고 그에 대한 답변을 다음과 같이 얻었다.

“개인적인 사정으로 2차 채점 시기에 피로도가 조금 높았습니다. 보통 빠르고 변별력 있는 채점이 필요할 때, 고민되는 두 점수 중 낮은 점수를 주는 습관대로 점수를 주었던 것 같아요. 학생 글과 글 사이에 쉬는 시간을 오래 두지 않으려고 했고, (그래서) 고민의 시간이 1차 채점 시기보다 짧았습니다.” (F6)

“1차 채점은 업무가 끝난 늦은 시간에 진행했고, 2차 채점은 주말에 여유를 두고 진행했습니다. 1차 채점 시기에는 글이 잘 읽히지 않으면 낮은 점수를 주고 넘어갔고, 2차 채점은 글이 잘 읽히지 않으면 다시 읽으며 채점 기준 도달 여부를 숙고했던 것 같습니다.” (F30)

2차 채점에서 평가 요소별로 명확하게 점수를 부여하기 어려운 학생 글을 채점할 때, 6번 평가자의 경우 비교적 피로도가 높은 상황에서 고민의 시간을 짧게 두고 빠르게 점수를 부여하여 엄격한 채점 결과를 보였고, 30번 평가자의 경우 비교적 피로도가 적은 상황에서 충분한 시간을 두고 숙고하며 점수를 부여하여 관대한 채점 결과를 보였다. 두 평가자와의 심층 면담을 통해 점수를 부여하는 당시의 피로도, 채점을 위한 숙고의 시간 등이 채점의 엄격성에 영향을 미칠 수 있음을 알 수 있다.

12번 평가자는 상관계수 0.493으로 낮은 상관관계를 보였고 급내 상관계수도 0.563으로 나타났다. 1차 채점 결과의 평균이 12.85 표준편차 4.760이고 2차 채점 결과의 평균이 16.70, 표준편차 6.391로 두 채점 결과 간에 3.85라는 큰 차이를 보였다. 이는 집단 1, 4, 6에 속하는 평가자들의 1차 채점 평균 26.50과 2차 채점 평균 27.42에 비추어 볼 때 현저히 낮은 점수를 부여하고 있다는 점에서도 특징적이다. 다국면 Rasch 분석 결과를 살펴보면 1차 채점에서 2.02 logit(SE=0.12), 2차 채점에서 1.27 logit(SE=0.10)으로 2차 채점에서 다소 관대한 채점 경향을 보이기는 하나 다른 평가자들에 비해 엄격한 채점 경향을 보였다고 할 수 있다. 1차 채점, 2차 채점에서 각각 엄격성 수준을 비교적 일관되게 유지하더라도, 1차

채점에서의 엄격성 수준과 2차 채점에서의 엄격성 수준이 크게 차이가 날 경우에 낮은 상관관계를 보여 채점-재채점 신뢰도가 낮을 수 있음을 보여준다. 12번 평가자의 척도 사용 경향에 대한 심층 면담 응답에 의하면 분석적 채점 기준표에 따라 6점 척도를 고르게 사용하기보다는 총체적 인상에 다소 의존하여 평가 기준 마다 점수 부여를 세밀하게 하지 못했다는 평가자의 성찰이 있었다. 이를 참고할 때 평가자의 척도 사용 경향이나 평가 기준 사용 양상에 따라서 평가자 내 일관성에 영향을 미칠 수 있는 것으로 보인다.

집단 4의 경우 25번 평가자를 제외하면 3번, 7번, 14번, 17번, 23번 평가자가 높은 상관관계를 보였다. 그 중 17번 평가자의 상관계수는 0.780, 급내 상관계수는 0.862로 비교적 높은 수준의 상관관계를 보였다. 또 1차 채점 결과의 평균이 28.10, 표준편차 6.094이고 2차 채점 결과의 평균이 28.45, 표준편차 8.120으로 두 채점 결과 간에 0.35의 근소한 차이만을 보였다. 17번 평가자의 경우 주로 한 편의 완성된 글쓰기 직접 평가를 선호하였고 쓰기평가 연수 경험도 2회 있는 것으로 나타났다. 하지만 심층 면담에서 평소 쓰기 직접 평가에서의 어려움에 대해 '점수 부여에 있어 비슷한 수준의 학생의 경우 세밀하게 점수 차이를 두어 변별하기에 어려움을 느낀다.'는 응답을 통해 과적합 유형 평가자의 특성을 드러냈다.

3번 평가자와 23번 평가자의 경우 각각 0.754와 0.733의 높은 상관관계를 보였음에도 불구하고 1차 채점과 2차 채점의 평균 점수에 큰 차이를 보였다. 먼저 3번 평가자의 경우 1차 채점 결과의 평균이 26.20, 표준편차 5.745이고 2차 채점 결과의 평균이 29.50, 표준편차 5.453으로 두 채점 결과 간에 3.3이라는 점수 차이를 보였다. 다국면 Rasch 분석 결과를 살펴보면 1차 채점에서 -0.30 logit(SE=0.09), 2차 채점에서 -0.91 logit(SE=0.09)으로 2차 채점에서 더 관대한 채점 경향을 보였다.

23번 평가자는 1차 채점 결과의 평균이 28.70, 표준편차 6.224이고 2차 채점 결과의 평균이 24.45, 표준편차 5.335로 두 채점 결과 간에 4.25라는 큰 점수 차

이를 보였다. 다국면 Rasch 분석 결과를 살펴보면 1차 채점에서 -0.67 logit(SE=0.09), 2차 채점에서 -0.11 logit(SE=0.09)으로 3번 평가자와 달리 2차 채점에서 더 엄격한 채점 경향을 보였다.

집단 6의 15번 평가자는 채점-재채점 신뢰도의 상관계수가 0.837로 높게 나타났으나, 1차 채점과 2차 채점의 평균 차이가 1.45로 근소하다고 보기는 어려웠다. 다국면 Rasch 분석 결과를 살펴보면 1차 채점에서 -1.51 logit(SE=0.10), 2차 채점에서 -1.38 logit(SE=0.09)으로 2차 채점에서 약간 엄격한 채점 경향을 보였기 때문으로 보인다.

26번 평가자의 경우에도 상관계수가 0.779로 나타나 높은 상관관계를 보이는 것으로 분류되었으나, 집단 1, 4, 6에 속하는 모든 평가자 중 1차 채점, 2차 채점 결과의 평균 점수 차이가 가장 컸다. 1차 채점 결과의 평균이 27.85, 표준편차 7.909이고 2차 채점 결과의 평균이 33.40, 표준편차 7.653으로 두 채점 결과 간에 5.55의 점수 차이를 보였다. 다국면 Rasch 분석 결과에서도 1차 채점에서 -0.54 logit(SE=0.09), 2차 채점에서 -1.59 logit(SE=0.10)으로 1차 채점보다 2차 채점에서 관대한 채점 경향을 보였고 이로 인해 채점-재채점의 결과에 큰 차이를 가져온 것으로 보인다.

위 내용을 종합할 때 1차 채점, 2차 채점에서 모두 적합한 일관성을 보인 평가자 집단 1에 가장 높은 정도의 채점-재채점 신뢰도를 보인 평가자가 속해 있었고, 통계적으로 유의하지 않은 평가자를 제외하면 대부분 높은 상관관계 혹은 중간 정도의 상관관계를 보인다는 것을 알 수 있었다. 하지만 엄격성 수준의 차이에 따라 1차 채점과 2차 채점 결과에 다소 큰 차이를 보인 경우도 있어서, 각 채점에서 일관된 엄격성 수준을 유지하더라도 채점-재채점 신뢰도에서 모두가 높은 신뢰도 수준을 보이는 것을 아니라는 점을 알 수 있다. 다음으로 1차 채점, 2차 채점에서 모두 과적합한 일관성을 보인 평가자 집단 4의 경우 대체로 채점-재채점 신뢰도는 높은 수준의 상관관계를 보였으나, 1차 채점과 2차 채점의 결과에 큰 점수 차를 보이는 평가자들이 있었고, 1차 채점에서 엄격한 경향을 보

이다가 2차 채점에서 관대한 경향을 보이거나 그 반대의 경향을 보이는 평가자들이 혼재해 있었다. 비슷한 점수를 부여해서 세부적인 변별을 하지 못하는 집단의 경우 평가자 내 신뢰도가 높다고 판단하기에 무리가 따른다는 것을 알 수 있다. 마지막으로 1차 채점, 2차 채점에서 모두 부적합한 양상을 보인 집단6의 경우 채점-재채점 신뢰도가 높게 나타난 평가자들이 있었으나 실제 1차 채점 평균 점수와 2차 채점 평균 점수의 차이가 컸기 때문에, 상관계수가 높으면서 평균 점수의 차이가 근소하다고 볼 만한 평가자는 없었다. 예측할 수 없는 점수를 부여하여 점수에 일관성이 없는 경우 채점-재채점 신뢰도가 높게 나타날 수는 있으나 이를 일관된 경향으로 분류하기는 어려우며, 동일한 학생의 글을 반복하여 채점할 때 큰 차이를 보일 수 있기에 평가자 내 일관성을 확보하기 위한 노력이 필요하다는 점을 시사한다.

5. 쓰기평가 효능감에 따른 채점-재채점 신뢰도의 차이

가. 기술통계

이 연구에서는 채점-재채점 신뢰도에 영향을 미치는 요인으로 먼저 평가자의 쓰기평가 효능감을 설정하여, 평가자의 쓰기평가 효능감 수준을 먼저 분류하고 효능감 수준에 따른 채점-재채점 신뢰도를 분석하였다. 먼저 평가자별 쓰기평가 효능감 검사 문항의 기술통계는 <표 Ⅳ-10>과 같다.

<표 Ⅳ-10> 평가자별 쓰기평가 효능감 검사 문항의 기술통계

평가자	일반적 평가 효능감	실행적 평가 효능감	계	평가자	일반적 평가 효능감	실행적 평가 효능감	계
4	25	65	90	30	23	55	78
20	24	65	89	13	21	56	77
24	25	64	89	18	21	56	77
3	24	64	88	10	21	53	74
11	25	63	88	14	17	57	74
15	22	65	87	26	19	54	73
1	21	64	85	17	20	52	72
5	24	61	85	22	20	52	72
8	22	60	82	29	21	49	70
23	22	60	82	12	18	50	68
9	21	60	81	28	17	51	68
16	22	58	80	7	18	49	67
27	22	58	80	19	18	49	67
6	21	57	78	25	18	45	63
21	20	58	78	2	15	45	60

<표 Ⅳ-10>은 채점에 참여한 평가자 30명의 쓰기평가 효능감 수준을 내림차순으로 정리한 것이다. ‘일반적 평가 효능감’ 5개(1번~5번)와 ‘실행적 평가 효능감’ 13개(6번~18번)로 이루어진 총 18개의 문항에 대한 평가자 전체의 평균 점수는 77.4점이다. 일반적 평가 효능감 배점이 30점, 실행적 평가 효능감 배점이 78점으로 총점 108점인 것을 고려할 때 채점에 참여한 국어교사의 쓰기평가 효능감 수준은 높은 편이라 볼 수 있다. 점수는 60점에서 90점까지 분포되어 평가자에 따라 그 격차가 컸다. 요인별로 살펴보면 ‘일반적 평가 효능감’은 15점에서 25점, ‘실행적 평가 효능감’은 45점에서 65점까지로 나타났다.

나. 쓰기평가 효능감에 따른 채점-재채점 신뢰도

평가자 30명의 쓰기평가 효능감을 변인으로 하여 채점-재채점 신뢰도를 분석하고자 한다. 쓰기평가 효능감 수준에 따른 평가자의 Pearson 상관계수(r)를 Mukaka(2012)의 기준에 따라 분류하여 채점-재채점 신뢰도를 분석하면 <표 Ⅳ-11>과 같다.

<표 Ⅳ-11> 쓰기평가 효능감 수준에 따른 채점-재채점 신뢰도

상관 정도 / 효능감 수준	높은 정도	중간 정도	낮은 정도	계
70점 미만	2	3	1	6
70점 이상 80점 미만	8	2	1	11
80점 이상	8	4	·	12
계				29

<표 Ⅳ-11>은 채점-재채점에 참여한 평가자 중 통계적으로 유의한 상관관계를 보이지 못한 1번 평가자를 제외하고 쓰기평가 효능감 수준을 70점 미만, 70점 이상 80점 미만, 80점 이상의 3개 집단으로 분류했을 때의 채점-재채점 신뢰도 정도를 보여준다. 백유진(2018)에서 쓰기평가 효능감 수준의 총점에 따라 집단별 채점 엄격성과 일관성을 정리할 때 사용한 구간을 참고하였다. 선행 연구에서는 90점 이상부터 108점에 이르는 집단도 분류하였으나 이 연구에서는 해당 구간에 속하는 평가자가 1명으로 매우 적어 총 세 구간으로만 분류하였다.

쓰기평가 효능감 수준이 70점 미만인 평가자 중 높은 정도의 상관관계를 보인 평가자는 2명으로 28번, 7번 평가자가 해당되고, 중간 정도의 상관관계를 보인 평가자는 3명으로 19번, 25번, 2번 평가자가 해당된다. 낮은 정도의 상관관계를 보인 평가자는 12번 평가자이다. 쓰기평가 효능감 수준이 70점 이상 80점 미만

인 평가자 중 높은 정도의 상관관계를 보인 평가자는 8명으로 6번, 21번, 18번, 10번, 14번, 26번, 17번, 22번 평가자가 해당되고, 중간 정도의 상관관계를 보인 평가자는 2명으로 30번, 29번 평가자가 해당된다. 낮은 정도의 상관관계를 보인 평가자는 1명으로 13번 평가자이다. 쓰기평가 효능감 수준이 80점 이상인 평가자 중 높은 정도의 상관관계를 보인 평가자는 8명으로 24번, 3번, 15번, 8번, 23번, 9번, 27번, 4번 평가자가 해당되고, 중간 정도의 상관관계를 보인 평가자는 4명으로 20번, 11번, 5번, 16번 평가자가 해당된다. 낮은 정도의 상관관계를 보인 평가자는 없었다.

쓰기평가 효능감 수준이 70점 미만으로 비교적 낮은 평가자들 중 높은 정도의 상관관계를 보인 평가자인 28번 평가자의 경우 쓰기 직접 평가의 경험이 '많음'에 해당하지만 쓰기평가와 관련한 연수 경험이 없어서 자신의 쓰기평가를 성찰할 만한 객관적 준거가 부족한 것이 쓰기평가 효능감 수준이 낮은 원인 중 하나로 보인다. 반면 쓰기평가 효능감 수준은 70점 이상 80점 미만에 해당하지만 낮은 정도의 상관관계를 보인 평가자인 13번 평가자의 경우 쓰기 직접 평가의 경험이 1~2회로 매우 적고, 쓰기평가 연수의 경험도 없어서 효능감 수준에 비해 실제 채점 경험이 부족한 것으로 나타났다.

또한 쓰기평가 효능감 수준이 80점 이상으로 높은 평가자 중 중간 정도의 상관관계를 보인 평가자가 4명의 상관관계(r)을 살펴보면 20번 평가자는 .639, 11번 평가자는 .682, 5번 평가자는 .698, 16번 평가자는 .668로 $0.5 \leq r < 0.7$에 해당하기는 하나 0.7에 가까운 수준을 보였다. 쓰기평가 효능감 수준에 따른 채점-재채점 상관계수(r)의 평균을 비교하면 70점 미만인 평가자가 .658, 70점 이상 80점 미만인 평가자가 .734, 80점 이상인 평가자가 .760으로, 쓰기평가 효능감 수준이 높은 평가자 집단일수록 상관계수(r)가 높게 나타났다.

이를 종합적으로 고려할 때 평가자의 쓰기평가 효능감 수준에 따라 채점-재채점 신뢰도가 일관된 경향성을 뚜렷하게 보인다고 할 수는 없지만 대체로 쓰기평가 효능감 수준이 높은 평가자의 경우 채점-재채점 신뢰도의 수준도 높은 경우

가 많고, 쓰기 직접 평가의 경험 정도에 따라 효능감 수준과 다른 상관관계를 보이기도 한다는 것을 알 수 있다.

6. 경력 및 성별에 따른 채점-재채점 신뢰도의 차이

가. 경력에 따른 채점-재채점 신뢰도

평가자 30명의 다양한 경력을 변인으로 하여 채점-재채점 신뢰도를 분석하고자 한다. 평가자의 Pearson 상관계수(r)를 Mukaka(2012)의 기준에 따라 분류하여 채점-재채점 신뢰도를 분석하면 <표 Ⅳ-12>와 같다.

<표 Ⅳ-12> 경력에 따른 채점-재채점 신뢰도

상관 정도 / 경력	높은 정도	중간 정도	낮은 정도	계
5년 미만	1	1	1	3
5년 이상~10년 미만	11	3	·	14
10년 이상~15년 미만	5	3	1	9
15년 이상	1	2	·	3
계				29

<표 Ⅳ-12>는 채점-재채점에 참여한 평가자 중 통계적으로 유의한 상관관계를 보이지 못한 1번 평가자를 제외하고 경력에 따라 분류했을 때의 채점-재채점 신뢰도 정도를 보여준다.

경력이 5년 미만인 평가자 중 높은 정도의 상관관계를 보인 평가자는 18번, 중간 정도의 상관관계를 보인 평가자는 2번, 낮은 정도의 상관관계를 보인 평가자는 13번 평가자이다. 경력이 5년 이상~10년 미만인 평가자 중 높은 정도의 상

관관계를 보인 평가자는 11명으로 4번, 6번, 7번, 9번, 14번, 15번, 21번, 22번, 23번, 24번, 26번 평가자가 해당되고, 중간 정도의 상관관계를 보인 평가자는 3명으로 5번, 19번, 20번 평가자가 해당된다. 낮은 정도의 상관관계를 보인 평가자는 없었다. 경력이 10년 이상~15년 미만인 평가자 중 높은 정도의 상관관계를 보인 평가자는 5명으로 3번, 8번, 10번, 17번, 27번 평가자가 해당되고, 중간 정도의 상관관계를 보인 평가자는 3명으로 16번, 25번, 30번 평가자가 해당된다. 낮은 정도의 상관관계를 보인 평가자는 12번 평가자 1명이다. 경력이 15년 이상인 평가자 중 높은 정도의 상관관계를 보인 평가자는 28번, 중간 정도의 상관관계를 보인 평가자는 11번, 29번 평가자이다. 낮은 정도의 상관관계를 보인 평가자는 없었다. 또 경력에 따른 채점-재채점 상관계수(r)의 평균을 비교하면 5년 미만인 평가자가 .628, 5년 이상~10년 미만인 평가자가 .750, 10년 이상~15년 미만인 평가자가 .718, 15년 이상인 평가자가 .708로 나타났다.

이를 살펴 볼 때, 경력이 높거나 낮음에 따라 나타나는 경향은 발견할 수 없었다. 또 채점, 재채점에 참여한 평가자의 수가 충분하지 않고 네 집단으로 분류한 경력에 해당하는 평가자의 수에 차이가 커서 경력에 따른 일관된 경향을 파악하기에 무리가 있으나 5년 이상~10년 미만에 속하는 평가자의 상관계수(r)가 가장 높고, 높은 정도의 상관관계를 보인 평가자의 비율도 가장 많이 나타났다.

나. 성별에 따른 채점-재채점 신뢰도

평가자의 성별을 변인으로 하여 채점-재채점 신뢰도를 분석하고자 한다. 성별에 따른 평가자의 Pearson 상관계수(r)를 Mukaka(2012)의 기준에 따라 분류하여 채점-재채점 신뢰도를 분석하면 <표 Ⅳ-13>과 같다.

<표 Ⅳ-13> 성별에 따른 채점-재채점 신뢰도

성별 \ 상관 정도	높은 정도	중간 정도	낮은 정도	계
남	6	4	2	12
여	12	5	·	17
계				29

<표 Ⅳ-13>은 채점-재채점에 참여한 평가자 중 통계적으로 유의한 상관관계를 보이지 못한 1번 평가자를 제외하고 성별에 따라 분류했을 때의 채점-재채점 신뢰도 정도를 보여준다.

남자 평가자 중 높은 정도의 상관관계를 보인 평가자는 6명으로 3번, 4번, 7번, 14번, 17번, 18번 평가자이고, 중간 정도의 상관관계를 보인 평가자는 4명으로 2번, 5번, 19번, 25번 평가자이다. 낮은 정도의 상관관계를 보인 평가자는 2명으로 12번, 13번 평가자가 해당된다. 여자 평가자 중 높은 정도의 상관관계를 보인 평가자는 12명으로 6번, 8번, 9번, 10번, 15번, 21번, 22번, 23번, 24번, 26번, 27번, 28번 평가자이고, 중간 정도의 상관관계를 보인 평가자는 5명으로 11번, 16번, 20번, 29번, 30번 평가자이다. 낮은 정도의 상관관계를 보인 평가자는 없었다. 또 성별에 따른 채점-재채점 상관계수(r)의 평균을 비교하면 남자 평가자가 .679, 여자 평가자가 .723으로 나타났다.

낮은 정도의 상관관계를 보인 2명의 평가자가 남자 평가자에 해당하고, 상관계수(r)의 평균이 여자 평가자에 비해 다소 낮게 나타났다. 하지만 성별에 따른 채점-재채점 신뢰도의 특성을 보여주기에 평가자의 수가 충분하지 않아 일반화할 수 있는 결론으로 볼 수는 없다.

Ⅴ. 결론

학생의 쓰기 능력 진단과 발달을 위해 타당하고 신뢰할 수 있는 쓰기 직접 평가를 수행하는 능력은 국어교사가 갖추어야 할 주요한 쓰기평가 전문성에 해당한다. 채점의 엄격성과 일관성 양상을 분석하고 채점자 내 일관성을 신장시키거나 채점자 간 일치도를 확보하기 위한 연구가 많이 있어온 것도 이러한 이유 때문이다. 하지만 쓰기 평가자가 동일한 학생의 글을 반복적으로 채점했을 때 일관된 채점을 하는지에 대한 실증적 연구는 부족했다. 따라서 쓰기 평가자의 채점-재채점 신뢰도를 확인하고 채점 일관성을 신장시킬 수 있는 방안을 모색하는 일은 국어교사의 쓰기평가 전문성을 향상시키기 위한 방안 마련에 유의미한 정보를 제공할 수 있다.

이 연구에서는 국어교사인 쓰기 평가자들이 고등학생 논설문을 채점한 후 시간 간격을 두고 동일 학생 글을 재채점 했을 때, 채점과 재채점 결과의 일치도를 확인하기 위해 채점-재채점 신뢰도를 분석하였다. 이를 위해 30명의 평가자를 대상으로 분석 대상이 될 학생 글 20편을 포함하여 35편의 학생 글을 두 달 이상의 간격을 두고 채점, 재채점한 후 Pearson 상관분석을 실시하였다. 쓰기 평가자의 여러 변인에 따라 채점-재채점 신뢰도를 분석하기 위해서, 우선 다국면 Rasch 모형에 따라 채점, 재채점 결과로 알 수 있는 평가자의 엄격성과 일관성 수준을 분석하고, 쓰기평가 효능감과 성별, 경력 등의 배경요인에 따른 평가자 특성도 함께 분석하였다. 나아가 평가자의 쓰기평가 경험이나 쓰기평가 연수 경험, 심층 면담 내용 등을 고려하여 쓰기 평가자의 채점 일관성 향상을 위한 방안을 모색하였다.

이 연구에서 얻은 주요 결론은 다음과 같다.

첫째, 평가자별로 상관분석을 통해 채점-재채점 신뢰도를 분석한 결과 평가자들의 채점-재채점 신뢰도가 대체로 확보된 것으로 나타났다. 국어교사 30명 중 통계적으로 유의한 상관관계를 보이지 못한 평가자 1명을 제외하면, 상관계수는

0.563에서 0.918까지 폭넓게 분포된 양상을 보여 정도의 차이는 있었으나 중간 정도의 상관관계를 보인 평가자가 9명, 높은 상관관계를 보인 평가자가 18명으로 나타났다.

둘째, 엄격성 logit 값의 차이, 분리신뢰도, 카이스퀘어 값 등을 분석한 결과, 평가자 개인마다 엄격성에 차이가 있으나, 우수한 글과 그렇지 못한 글에 대한 판단, 가장 엄격하거나 관대하게 평가하는 기준 등에서는 일관성을 보이는 것으로 나타났다. 1차 채점과 2차 채점 모두 엄격한 평가자보다는 관대한 평가자가 많았고 평가자의 엄격성 수준에 편차가 존재했다. 또 평가자마다 일부 차이를 보였으나 1차 채점에서 엄격성 수준이 높았던 평가자가 2차 채점에서도 엄격성이 높은 편으로 나타났다. 이러한 결과는 쓰기평가에서 평가자의 엄격성 차이에 따라 나타나는 상이한 채점 결과로 인해 쓰기평가의 신뢰도에 문제가 있을 수 있음을 의미한다.

셋째, 내적합 지수와 내적합 표준화값을 통해 평가자를 일관성 유형에 따라 분류한 결과, 1차 채점과 2차 채점에서 모두 적합한 수준의 일관성을 보인 평가자는 10명(33.33%), 모두 과적합한 수준의 일관성을 보인 평가자는 6명(20.00%), 모두 부적합한 수준의 일관성을 보인 평가자는 4명(13.33%)으로 나타났다. 전체 평가자 중 1/3의 비율에 해당하는 평가자가 채점 일관성을 적절히 유지하는 편이지만, 1차 채점과 2차 채점에서 모두 일관되게 과적합하거나 부적합한 양상을 보인 평가자도 1/3의 비율에 해당한다는 점에서 평가자의 채점 일관성 신장이 요구된다고 볼 수 있다.

넷째, 평가자의 일관성 유형에 따라 집단을 분류하고 채점-재채점 신뢰도를 분석한 결과, 1차 채점과 2차 채점에서 모두 적합한 일관성을 보인 집단1의 경우 가장 높은 정도의 채점-재채점 신뢰도를 보인 평가자를 포함하여 대부분의 평가자들이 높은 상관관계 또는 중간 정도의 상관관계를 보였다. 하지만 엄격성 수준의 차이에 따라 일치도가 떨어지기도 했다. 1차 채점과 2차 채점에서 모두 과적합한 일관성을 보인 집단4의 경우 대체로 채점-재채점 신뢰도는 높은 수준

의 상관관계를 보였지만 1차 채점과 2차 채점에서 서로 다른 엄격성을 보이는 평가자들이 혼재되어 있었다. 1차 채점과 2차 채점에서 모두 부적합한 일관성을 보인 집단 6의 경우 일부 채점-재채점 신뢰도가 높은 평가자도 있었으나 평균 점수의 폭은 컸기 때문에 신뢰도가 높다고 판단하기 어려웠다. 평가자의 일관성 유형에 따라 채점-재채점 신뢰도의 일관된 경향성을 판단하기에 무리가 따르기에, 해석에 있어 평가자의 쓰기 직접 평가 경험이나 쓰기평가 연수 등 평가자 요인과 심층 면담 결과를 고려하였다. 쓰기 평가자가 채점을 할 때 동일한 엄격성 수준을 유지하는 전문성을 갖춘 경우라 하더라도 채점 기준을 일관되게 적용하기 위한 충분한 직접 쓰기평가 경험, 쓰기평가 용어에 대한 이해, 채점 당시의 피로도의 영향 최소화 등에 따라 채점의 일관성은 달라질 수 있기에 적절한 채점자 훈련이 필요하다는 시사점을 얻을 수 있다.

다섯째, 평가자의 쓰기평가 효능감에 따른 채점-재채점 신뢰도의 차이를 분석한 결과, 효능감 수준이 높은 평가자가 채점-재채점 신뢰도의 수준도 높은 경우가 많았으며 상관계수도 높게 나타났다. 하지만 효능감 수준에 따라 채점-재채점 신뢰도가 높아지는 경향이 일관되게 나타나지는 않았고, 효능감 수준이 유사하더라도 쓰기 직접 평가의 경험 정도에 따라 서로 다른 결과를 보이기도 했다. 따라서 쓰기평가 효능감에 따른 채점-재채점 신뢰도의 차이를 해석할 때에는 평가자의 다른 변인을 함께 고려할 필요가 있다.

여섯째, 배경요인 중 평가자의 경력과 성별에 따른 채점-재채점 신뢰도의 차이를 분석한 결과, 평가자의 수가 충분치 않아 일반화에 무리가 따르기는 하나 5년 이상~10년 미만의 경력에 속하는 평가자의 경우 높은 정도의 상관관계를 보이는 비율이 높았고, 여자 평가자에 비해 남자 평가자의 경우 낮은 정도의 상관관계를 보이는 정도가 다소 높았다. 경력과 성별이 채점 일관성에 미치는 영향에 대해 일관된 결과를 도출할 수는 없었지만 경력은 실제 쓰기평가의 경험과 무관할 수 없고, 성별에 따른 엄격성의 차이에 대한 선행 연구가 다수 있기에 보다 많은 수의 평가자를 대상으로 한 후속 연구가 이루어질 필요가 있다.

일곱째, 쓰기 평가자의 채점 일관성을 신장시키기 위해서는 쓰기평가 지식을 습득하고 실제 채점 연습이 이루어지는 채점자 훈련, 평자가의 채점 일관성에 대한 피드백을 통한 자기 성찰 기회 부여 등이 요구됨을 알 수 있다. 심층 면담 결과 평가자들은 채점 기준을 하위 평가 요소로 분석하는데 사용되는 용어나 전략에 대한 내면화 여부가 채점 시 빠르고 정확한 판단을 내리는데 기여한다고 보았다. 채점 기준에 사용된 용어의 추상성을 이해하고 적용하기 위한 쓰기평가 지식이 부족하면 일관성 있는 평가를 지속하기 어렵기 때문이다. 또 하위 평가 요소를 실제 학생 글에 나타난 특징과 연결 짓는 능력은 평가에 관한 지식만으로 숙달하기는 어렵기에 실제 쓰기 직접 평가를 수행한 경험이 필요하다. 실제로 채점 기준을 적용하여 채점하고 그 결과에 대해 분석하는 연수를 통해 반복된 채점에서도 같은 글에 대해 동일하게 평가 기준을 적용할 수 있는 능력이 함양될 것이다. 나아가 채점이 이루어진 후 평가자의 채점 일관성 수준에 대한 상세한 정보 제공을 통해 채점 기준을 해석하고 적용하는 데 성찰의 기회를 제공한다면, 자신의 채점 과정에서의 문제점을 인식하고 개선하여 채점 일관성을 확보하는데 기여할 것이다.

이 연구에서 실시한 쓰기평가에서의 채점-재채점 신뢰도 분석은 쓰기 평가자로서 국어교사의 채점 일관성을 실증적으로 확인하고 평가자의 여러 변인에 따른 특성을 분석한 것으로, 앞으로 이어질 후속 연구에서 채점 일관성 신장 방안을 모색하는 데 유의미한 자료를 제공할 수 있기를 기대한다.

<참고 문헌>

1. 국내 참고 자료

가은아(2008), “국어교사의 쓰기 효능감 및 쓰기 신념이 학생 쓰기평가에 미치는 영향”, 석사학위 논문, 충북: 한국교원대학교.

가은아(2018), “예비 국어교사의 쓰기평가 지식과 쓰기평가 효능감 분석-쓰기평가수업 경험을 중심으로”, 『리터러시연구』 제9권 제4호, 경북: 한국리터러시학회.

강승호·김양분(2004), 『신뢰도』, 서울: 교육과학사.

권태현(2012), “쓰기 채점 방식에 따른 국어교사의 채점 신뢰도 비교 연구”, 『교원교육』 제28권 제3호, 충북: 한국교원대학교 교육연구원.

권태현(2014), “쓰기 성취기준에 따른 학생 예시문 선정에 관한 연구”, 박사학위 논문, 충북: 한국교원대학교 대학원.

나은진·송창순(2018), “만성뇌졸증 환자를 위한 신체인식척도: 검사-재검사 신뢰도”, 『한국신경인지재활치료학회지』 제10권 제1호, 경기: 한국인지운동치료협회.

김경희·송미영(2001), “채점척도에 따른 채점자의 일관성과 피험자능력추정의 정확성 비교”, 『교육평가연구』 제14권 제1호, 서울: 한국교육평가학회.

김성숙(2001), “채점의 변동요인 분석방법에 대한 고찰: 일반화가능도 이론과 다국면 라쉬모형의 적용과 재해석”, 『교육평가연구』 제14권 제1호, 서울: 한국교육평가학회.

남명호·김성숙·지은림(2000). 『수행평가-이해와 적용-』, 서울: 문음사.

박영목(2008), “쓰기평가연구의 주요 과제”, 『작문연구』 제6집, 서울: 한국작문학회.

박영민(2010), “예비국어교사의 쓰기평가 효능감 분석”, 『청람어문연구』 제42집,

충북: 청람어문교육학회.
박영민(2011), “국어교사의 쓰기평가 효능감 분석”, 『청람어문교육』 제44집, 충북: 청람어문교육학회.
박영민(2012), “예비국어교사의 중학생 논설문 평가에서 발견되는 엄격성 및 일관성의 특성”,『국어교육학연구』 제43집, 서울: 국어교육학회.
박영민·최숙기(2009), “현직 국어교사와 예비 국어교사의 쓰기평가비교 연구”, 『교육과정평가연구』 제12권 제1호, 서울: 교육과정평가원.
박영민·최숙기(2010), “Rasch 모형을 활용한 국어교사의 쓰기평가 특성 분석”, 『국어교육학연구』 제37집, 서울: 국어교육학회.
박영민·최숙기(2011), “논설문 평가에 나타난 국어교사의 평가 특성 및 편향 분석”, 『교육과정평가연구』 제14권 제1호, 충북: 한국교육과정평가원.
박영민 외 (2016), 『작문교육론』, 서울: 역락.
박종임(2013), “국어교사의 쓰기평가 특성 연구”, 박사학위논문, 충북: 한국교원대학교 대학원.
박종임·박영민(2011), “Rasch 모형을 활용한 국어교사의 채점 일관성 변화 양상 및 원인 분석”, 『우리어문연구』 제39집, 서울: 우리어문학회.
박종임·박영민(2012), “평가자 일관성에 따른 설명문 평가 예시문 선정의 차이 연구”, 『작문연구』 제14집, 서울: 한국작문학회.
박종임·박영민(2013), “국어교사 쓰기 지도 효능감의 구성 요인과 경력 및 성별에 따른 수준 차이 분석”, 『새국어교육』 제94호, 충북: 한국국어교육학회.
박찬홍(2019), “예비 국어교사의 쓰기 평가 효능감과 쓰기 평가 수행에 대한 연구”, 『국어문학』 제72집, 전북: 국어문학회.
백유진(2018), “국어교사의 쓰기평가 지식과 효능감이 논설문 평가에 미치는 영향”, 석사학위논문, 충북: 한국교원대학교 대학원.
백유진·박영민(2021), “중학생 논설문 평가에 나타난 예비국어교사의 평가 특성

분석", 『학습자중심교과교육연구』 제21권 제1호, 충북: 학습자중심교과교육학회.

신동일(2001), "채점 경향 분석을 위한 Rasch 측정모형 적용 연구", 『Foreign Languages Education』 제8권 제1호, 서울: 한국외국어교육학회.

신동일·설현수(2005), "NEW FACETS을 활용한 채점자료 분석방법", 『Foreign Languages Education』 제12권 제2호, 서울: 한국외국어교육학회.

신문자·이희란(2017), "학령기 아동 낱말 의미검사의 표준화 연구", 『학습자중심교과교육연구』 제17권 제6호, 충북: 학습자중심교과교육학회.

오세영(2017), "작문 평가자의 학생글 읽기 과정 연구", 『우리말글』 제72집, 서울: 우리말글학회.

윤금준(2021), "국어교사의 쓰기평가 일관성 유형에 따른 채점-재채점 신뢰도 분석", 『국어교육학연구』 제56집 제1호, 서울: 국어교육학회.

이성영(2005), "국어과 교사의 쓰기 영역 평가 전문성 기준과 모형", 『국어교육』 제117호, 서울: 한국어교육학회.

이인혜(2014), "한국어교사의 쓰기평가 효능감과 평가 특성 연구", 『이중언어학』 제56호, 서울: 이중언어학회.

이현숙(2008), "다국면 라쉬모형을 적용한 논술 채점 상황에서 채점 설계 및 채점자 특성이 채점의 정확성에 미치는 효과", 『교육평가연구』 제21권 제4호, 서울: 한국교육평가학회.

이혜원·이경원(2014), "학령전기용 어음청각검사 어표의 검사-재검사 신뢰도", 『Audiology and Speech Research』 제10집 제1호, 강원: 한국청각언어재활학회.

이재창 외(2017), "조현병 환자가 시행한 주의력 네트워크 검사 점수의 검사-재검사 신뢰도", 『정신신체의학』 제25집 제2호, 한국정신신체의학회.

장소영·신동일(2009), 『언어교육평가 연구를 위한 FACETS 프로그램』, 서울: 글로벌콘텐츠.

장미(2020), “논설문 채점 진행에 따른 국어교사의 채점 전략 변화 분석”, 박사학위논문, 충북: 한국교원대학교 대학원.

장은주(2015), “채점의 일관성 유형에 따른 국어교사의 쓰기평가 특성 분석”, 박사학위논문, 충북: 한국교원대학교 대학원.

정미경(2011), “국어교사의 성별에 따른 쓰기평가 특성 분석”, 『교원교육』 제27권 제4호, 충북: 한국교원대학교 교육연구원.

정분의(2019), “학생 글 채점 누적에 따른 국어교사의 인지 부담 변화”, 『작문연구』 제42집, 서울: 한국작문학회.

정수정·최나야(2018), “초등학생 읽기동기 척도의 타당화 및 규준 연구”, 『아동교육』 제27집 제1호, 대구: 한국아동교육학회.

정희모(2009), “대학글쓰기평가의 신뢰도와 타당도 향상을 위한 한 방안”, 『작문연구』 제9집, 서울: 한국작문학회.

조윤정·양명희(2018), “한국어 말하기 평가에서 나타난 채점자 신뢰도 및 일관성 연구”, 『화법연구』 제40호, 서울: 한국화법학회

지은림(2008), “논술고사의 신뢰성에 영향을 미치는 채점자 특성 분석”, 『교육평가연구』 제21권 제2호, 서울: 한국교육평가학회.

지은림·채선희(2000), 『Rasch모형의 이론과 실제』, 서울: 교육과학사.

최숙기(2012), “국어과 수행 평가의 평가자 신뢰도 보고 방안 탐색”, 『작문연구』 제14집, 서울: 한국작문학회.

최숙기·박영민(2011), “논설문 평가에 나타난 국어교사의 평가 특성 및 편향 분석”, 『교육과정평가연구』 제14권 제1호, 서울: 교육과정평가원.

최영미·김수미·이소현·박영민(2019), “Python 기반의 쓰기평가연습 프로그램 개발”, 『학습자중심교과교육연구』 제19권 제12호, 충북: 학습자중심교과교육학회.

채선희(1996), “논술시험 채점의 공정성과 효율성 확보 방안 - 채점과정의 엄격성과 FACETS 모형에 의한 채점결과 분석”, 『교육평가연구』 제9집

제1호, 서울: 한국교육평가학회.
허소희·진인기(2019), “국어 이명주요기능설문지의 검사-재검사 신뢰도 검증 및 간소화 버전 제안”, 『Audiology and Speech Research』 제15집 제4호, 강원: 한국청각언어재활학회.

2. 국외 참고 자료

Brooks, G. W.(2007). Teachers as Readers and Writers and as Teachers of Reading and Writing. *Journal Of Educational Research,* 100(3), 177-191.

Congdon, P. J. & McQueen, J.(2000), The stability of rater severity in large-scale assessment programs, *Journal of educational measurement,* 37(2), pp.163-178.

Eckes, T.(2008), Rater types in writing performance assessment: A classification approach to rater variability, *Language Testing*, 25(2), 155-185.

Eckes, T.(2012), Operational Rater Types in Writing Assessment: Linking Rater Cognition to Rater Behavior, *Language Assessment Quarterly,* 9, 270-292.

Engelhard, G. (1996), Evaluating rater accuracy in performance assessments. *Journal of Educational Measurement*, 33(1), 56-70.

Gary A. Troia(2009), *Instruction and Assessment for Struggling Writers*, The Guilford Press, New York: Guilford. 박영민 역(2012), 『쓰기 지도 및 쓰기평가의 방법』, 서울: 시그마프레스.

Huot, B. A.(1993), The influence of holistic scoring procedures on reading and rating student essays, In M. M. Williamson & B. A. Huot (Eds.), *Validating holistic scoring for writing assessment: Theoretical and empirical foundations*, pp.206-236, Cresskill, NJ: Hampton Press.

Ken Hyland(2015), *Teaching and Researching Writing(Second edition)*, New York: Routledge. 박영민·장은주 역(2017), 『쓰기 지도와 쓰기 연구

의 방법』, 서울: 글로벌콘텐츠.

Linacre, J. M.(1989, 1994), *Many-Facet Rasch Measurement*, MESA Press.

Lunz, M, E. & Stahl, J.(1990), Judge consistency and severity across grading periods, *Evaluation and Health Professions*, 13(4), pp.425-444.

Lunz, M. E., Wright, B. D., & Linacre, J. M. (1990), Measuring the impact of judge severity on examination scores, *Applied Measurement in Education*, 3, 331-345.

Lumley, T., & McNamara, T. F. (1995), Rater characteristics and rater bias: Implications for training. *Language Testing*, 12(1), 54-71.

McNamara, T. F.(1996), *Measuring Second Language Performance*, New York: Longman. 채선희·지은림·백순근·설현수 역(2003), 『문항반응이론의 이론과 실제: 외국어 수행평가를 중심으로』, 서울: 서현사.

Mukaka, M. M. (2012), "A guide to appropriate use of correlation coefficient in medical research", *Malawi Medical Journal* 24(3), 69-71.

Myford, C. M. & Wolfe, E. W. (2003), Detecting and Measuring Rater Effects Using Many-Facet Rasch Measurement: Part Ⅰ, *Journal of Applied Measurement* 4(4), 386-422

Weigle, S. C.(1998), Using FACETS to model rater training effects. *Language Testing*, 15(2), 268-287.

ABSTRACT

The Reliability Analysis of Scoring-Rescoring Depending on the Raters Variables.

Choi, Mi yeong

Major in Korean Language Education
Graduate School of Korea National University of Education
Chung-Buk, KOREA

Supervised by Professor Park, Young min, Ph. D.

In Korean language education, direct writing assessment has an important meaning for the diagnosis and development of students' writing skills. Therefore, Korean language teachers are required to have knowledge and efficacy in writing assessment and expertise in valid and reliable writing assessment for direct writing assessment. However, it is difficult for the scorer to overcome the subjectivity intervention problem and maintain a constant tendency to score on the text due to decreased concentration or fatigue, and differences in scoring scale and standard utilization. Therefore, it is important to determine the degree of scoring consistency and to find a way to improve it.

Based on this awareness of the problem, this study attempts to empirically confirm the consistency within the scorer in writing assessment

through scoring-rescoring reliability analysis. The scoring-rescoring reliability was analyzed using rater consistency type, write assessment efficacy level, and career and gender corresponding to background factors as variables, and a plan to improve scoring consistency was sought through the assessment characteristics of write raters.

In this study, writing scoring was conducted twice in total for 30 raters. Based on gender, 12 male teachers (40.00%), 18 female teachers (60.00%), 4 (13.33%) under 5 years (13.33%) based on experience, 14 students (46.67%) under 5 years to 10 years, 9 students (30.00%) over 10 years to 15 years, and 3 Korean teachers over 15 years (10.00%). The raters scored the writings of a second-year high school student who performed the thesis writing task according to the scoring standard table on a six-point scale consisting of seven assessment elements. Thirty-five student articles were scored respectively during the first and second scoring periods, and 20 of them were given the same during the first and second scoring periods, making them the subject of future scoring-rescoring reliability analysis. In addition, raters factor test papers and write assessment efficacy test papers were put in, and in-depth interviews were conducted with some raters.

Through descriptive statistics analysis, the first and second scoring results were summarized, and among them, descriptive statistics for 20 student articles subject to scoring-rescoring reliability analysis were analyzed separately. In order to analyze the scoring-rescoring reliability according to the rater consistency type, the characteristics of scoring consistency and rigor analyzed through the multi-phase Rasch model after the model suitability test for scoring results were described. Groups were classified into

1 to 6 according to the scoring consistency type, and the scoring-rescoring reliability of raters corresponding to 1, 4, and 6, which are groups showing characteristic consistency types, was analyzed. In addition, after describing the level of writing assessment efficacy, the difference in scoring-rescoring reliability according to the level of efficacy was analyzed, and differences according to career and gender were also analyzed. In the description process, in-depth interviews with raters were cited, and measures were sought to improve scoring consistency by utilizing the contents of writing assessment training experience and writing direct assessment experience shown in the rater factor test paper. The conclusions obtained through this process are as follows.

First, as a result of analyzing the scoring consistency for each rater, it was found that the scoring-rescoring reliability was generally secured. Although the correlation coefficients obtained through correlation analysis are widely distributed, there are 9 raters with moderate correlation and 18 raters with high correlation, which means that there are many raters who maintain an appropriate level of scoring consistency.

Second, as a result of analyzing the rigor and consistency of raters, it was found that there was a variation in the level of rigor for each raters. Overall, there were more generous raters than strict raters, and some raters showed different levels of strictness in scoring and sneezing. This difference in rigor means that it can cause problems in the reliability of writing assessment.

Third, as a result of classifying raters according to the type of consistency, one-third of all raters tended to maintain scoring consistency in both scoring and sneezing, but likewise, one-third of raters showed overfitting or

inadequate patterns in scoring and sneezing. This suggests that it is necessary to increase the consistency of raters in writing assessment.

Fourth, as a result of analyzing the scoring-rescoring reliability according to the rater's consistency type, most of the groups that showed suitable consistency in both scoring and sneezing showed high or moderate correlation. However, it was not seen that the scoring-rescoring reliability tended to be consistent depending on the type of consistency, and it was found through in-depth interviews that there were aspects that changed depending on the experience or training of writing assessment. This means that scorer training on writing assessment is required.

Fifth, as a result of analyzing the scoring-rescoring reliability according to the rater's writing assessment efficacy, the consistent tendency according to the level of efficacy was not clear, but raters with high efficacy often had a high level of scoring-rescoring reliability.

Sixth, as a result of analyzing the scoring-rescoring reliability according to the rater's career and gender, there was no tendency to generalize, but the percentage of raters who belonged to more than 5 to 10 years of experience was high. In addition, in the case of male teachers, the degree of low correlation was high.

Seventh, it was found that in order to improve the consistency of writing raters' scoring, it was necessary to acquire writing assessment knowledge, train scorers who actually score, and give them opportunities for self-reflection through feedback.

This study analyzed the scoring-rescoring reliability twice for Korean language teachers, empirically confirmed the scoring consistency, and based

on the scoring results, the rater's scoring consistency type, writing assessment efficacy, career and gender to analyze rater characteristics, and seek ways to improve scoring consistency through in-depth interviews.

Key words : writing assessment, scoring-rescoring reliability, rater consistency, writing assessment efficacy, many-facet Rasch model.

※ A thesis submitted to the Committee of the Graduate School of Korea National University of Education in partial fulfillment of the requirements for the degree of Master of Education in February, 2022.

부 록

부 록 차 례

<부록 1> 평가자 요인 검사지……87

<부록 2> 쓰기평가 자료……95

<부록 1> 평가자 요인 검사지

1. 배경요인 검사지

1. 인적 사항

설명(선택사항)

1-1. 선생님의 성별 *

- 남
- 여

1-2. 선생님의 교직 경력 (기간제 경력 포함, 현재 5년차면 '5년 이상'에 체크) *

- 5년 미만
- 5년 이상~10년 미만
- 10년 이상~15년 미만
- 15년 이상

1-3. 현재 근무지의 학교급 *

- 중학교
- 고등학교

2. 쓰기평가 및 연수 경험

설명(선택사항)

2-1. 선생님의 쓰기 직접 평가 경험 (쓰기 수행평가 등을 일반적으로 행하는 정도) *

- ◯ 매우 적음(주로 하지 않음)
- ◯ 적음(일 년에 1회)
- ◯ 보통(학기 당 1회)
- ◯ 많음(학기 당 2회)
- ◯ 매우 많음(수시로 실시)

2-2. 주로 경험한 쓰기평가의 방식 (예: 한 편의 완성된 글쓰기 직접 평가, 선다형 문항을 통한 간접 평가 등) *

장문형 텍스트

2-3. 쓰기평가에 관한 연수 경험 (종류, 기간 무관) *

- ◯ 없음
- ◯ 1~2회
- ◯ 3~4회
- ◯ 5회 이상

2-4. 주로 경험한 쓰기평가 연수의 방식(예: 자격, 직무, 집합, 원격 등)

단답형 텍스트

2. 쓰기평가 효능감 검사지

쓰기 평가 효능감 검사지(박영민,2010)

'쓰기 평가 효능감'은 1차 채점 시기에만 수집하며, 2차 채점 시기에는 바로 본 채점에 들어가게 됩니다. 질문은 총 18개입니다.

1. 나는 학생 글을 잘 평가(채점)할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

2. 나는 학생들의 쓰기 능력을 정확하게 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

3. 나는 높은 신뢰도 수준을 유지하면서 학생 글을 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

4. 나는 학생 글을 '잘 쓴 글'과 '잘 못 쓴 글'로 잘 변별하며 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

5. 나는 학생 글을 평가할 때 평가 기준을 일관성 있게 적용할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

6. 나는 채점의 엄격성(점수를 잘 주는지 아닌지)을 일관성 있게 유지하며 학생 글을 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

7. 나는 학생 글에서 '내용'과 관련된 요소(명료성, 통일성, 창의성, 풍부성 등)을 잘 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

8. 나는 학생 글에서 '조직'이나 '구성'이 적절한지를 잘 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

9. 나는 학생 글에서 '표현'이 적절한지를 잘 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

10. 나는 학생 글에서 '단어 선택'이 적절한지를 잘 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

11. 나는 학생 글에서 어법(구두점, 띄어쓰기, 정서법 등)이 정확한지를 잘 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

12. 나는 쓰기 평가와 관련하여 어떤 문제나 갈등이 발생했을 때 이를 적절하게 해결할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

13. 나는 학생 글을 평가할 때 쓰기 윤리를 위반했는지(예, 표절)를 가려낼 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

14. 나는 다른 동료 평가자와 협의하며 학생 글을 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

15. 나는 쓰기 평가의 상황을 고려하여 평가 과정과 평가 결과를 조절할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

16. 나는 평가 영향 요인(예, 글씨 모양, 학생 성별 등)을 적절히 통제하며 학생 글을 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

17. 나는 마음이 편안한 상태에서 학생 글을 읽고 평가할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

18. 나는 쓰기 평가와 관련하여 어떤 문제가 발생했을 때 문제의 원인이 어디에 있는지 파악할 수 있다. *

- 전혀 그렇지 않다
- 그렇지 않다
- 별로 그렇지 않다
- 조금 그렇다
- 그렇다
- 매우 그렇다

<부록 2> 쓰기평가 자료

1. 쓰기 과제 및 자료

【쓰기 과제】

다음 <자료>를 읽고 '과학 연구를 위해 동물 실험을 해야 한다'에 대한 자신의 의견을 써 봅시다.

국내 연구진이 포유동물 실험을 하지 않고 예쁜 꼬마선충을 대상으로 항암제 독성을 실험하는 기술을 개발했다는 뉴스다. 아직 사용할 수 없는 분야가 더 많겠지만 적어도 항암제 독성 실험에 사용됐던 포유동물의 수를 줄일 수 있을 것으로 기대된다. 지난 2015년 한 해 동안 실험에 사용된 동물은 2013년에 비해 37% 증가한 250만 마리에 달했다. 동물실험은 국내뿐만 아니라 세계적으로 증가하는 추세다. 동물실험의 횟수가 늘수록 동물애호가를 포함한 많은 사람들이 더 격렬하게 실험에 반대하고 있다. 실제로 동물실험에 대한 찬반 토론은 국내의 많은 학교들이 토론 대회 문제로 선호하는 항목 가운데 하나다. 이번에는 동물실험에 대해 알아보도록 하자.

동물실험의 역사는 고대 그리스 시대까지 거슬러 올라간다. 히포크라테스는 동물 해부를 통해 생식과 유전을 설명했고, 아리스토텔레스는 해부학과 발생학을 발전시켰다. 16세기에는 베살리우스가 인체 해부학을 발전시켰는데 그 이전까지 동물 해부는 의학 분야에서 가장 중요한 과목으로 자리 잡았다. 19세기 이후 동물실험은 독성학과 생리학에서 사용되기 시작했다. 우리가 알고 있는 파스퇴르나 파블로프의 실험으로 의학과 생물학은 진일보한다. 이와 함께 반대하는 사람들도 늘기 시작했다.

동물실험을 반대하는 입장에서는 늘 효율에 대한 주장을 펼친다. 독일의 입덧 방지약에 들어있던 탈리도마이드라는 물질은 쥐나 개, 고양이에 대한 동물실험에서 아무런 부작용을 일으키지 않았지만 정작 원숭이와 사람에게는 팔이나 다리뼈가 발달하지 않거나 극단적으로 짧은 기형아를 발생시켰다. 백혈병 치료제였던 글리백은 쥐에서는 독성을 보였지만 원숭이와 사람에게는 효과가 있는 걸로 나타났다. 실제로 아스피린과 페니실린 등 많은 의약품이 동물과 인간에게 나타나는 효과가 다르다. 동물실험을 통해 모든 부작용을 정확하게 예측할 수 없기에 실험이 과연 의미가 있는지에 대한 의심이 제기되는 것이다. 여기에 동물과 사람이 공유하는 병이 약 1% 정도로 극히 드물다는 것도 동물실험을 반대하는 중요한 근거다.

동물실험을 찬성하는 측은 완벽하게 대체가 불가능한 기술이라는 점을 꼽는다. 인간이 사용할 약을 실험하려면 인간에게 투약하는 것이 가장 정확하고 명확한 결과를 얻을 수 있지만 그럴 수 없다는 것이다. 물론 목적으로 인간을 대하는 것 자체가 올바른 행위는 아니겠지만 만약 사용하더라도 실험 결과를 얻기까지 너무 많은 시간이 걸리는 것도 동물실험이 불가피하다는 논거가 된다. 컴퓨터를 활용해 시뮬레이션을 해도 수많은 변수를

전부 데이터화할 수 없고, 이로 인해 부작용을 정확하게 예측하기 어렵다. 동물을 사용함으로써 빠른 결과를 얻고, 부작용을 살펴볼 수 있기에 대체 기술이 발명되기 전에는 어쩔 수 없는 실험이라는 주장이다.

이처럼 과학의 발전은 때로는 사회적인 혼란을 불러온다. 올바른 답이 있는 경우도 있지만 대부분은 그렇지 않은 경우가 많다. 어디에 방점을 찍느냐는 언제나 우리의 선택이다. 동물실험에 대해 다시 생각해보고, 과학과 윤리와의 관계를 생각해보는 시간을 갖도록 하자.

(출처 : 대전일보, 2017-06-19기사 편집 2017-06-19 19:36:25)
http://www.daejonilbo.com/news/newsitem.asp?pk_no=1268776

2. 평가 기준표

평가 요소	평가 기준	평가 척도					
내용	1. 주장이 명료한가?	1	2	3	4	5	6
	2. 근거가 주장을 뒷받침하기에 타당한가?	1	2	3	4	5	6
	3. 근거가 주장을 뒷받침하기에 구체적이고 풍부한가?	1	2	3	4	5	6
조직	1. 서론-본론-결론의 체계적인 구조를 갖추었는가?	1	2	3	4	5	6
	2. 문장 또는 문단이 유기적으로 연결되었는가?	1	2	3	4	5	6
표현	1. 단어 사용이 적절하고 문장을 명료하게 진술하였는가?	1	2	3	4	5	6
	2. 어문규범(맞춤법, 문장 부호 등)에 맞게 표현되었는가?	1	2	3	4	5	6
	* 띄어쓰기는 평가하지 않습니다.						

3. 학생 글

1

나는 과학 연구를 위한 동물 실험의 이행에 반대하는 입장이다. 우리는 누구나 자연의 힘에 기대어 살아왔으며, 자연을 지배하기 위함이 아닌 자연과 공존하기 위해 태어났음을 알아야 한다. 교육용 목적으로 이용되는 영상 중 유명한 영상이 있다. 1분 남짓한 애니메이션으로, 지구에 태어난 하나의 인간이 자신의 사리사욕을 채우기 위해 그 짧은 시간 내에 수많은 생명체들을 죽이고 쓰레기가 가득한 행성의 왕이 되지만 결국 외계 생명에 의해 몰락하게 된다는 영상이다. 우리는 이러한 영상을 보고 무엇을 느껴야 하는가? 뱀의 입을 벌려 종아리를 집어넣고 손짓 한 번에 나무 백 그루를 종이 천 장으로 만들어 버리는 장면이 우리와 아주 동떨어져 있다고 생각되는가? 그리고 이러한 지구의 파괴에 동물 실험이 결코 영향을 미치지 않을 수 있을까? 그렇지 않다. 현대 인간의 최대 수명이 지나치게 증가하고 있는 가운데, 행성은 아직 한정되어 있는데도 우리의 욕구는 무한해져만 한다. 우리는 인간이 살아갈 수 있는 시간을 늘리고 공간을 넓히기 위해 새로운 산을 파헤쳐 악을 만들고 가장 작은 생명체들을 죽여 땅을 개척했다. 말인즉슨 우리는 지구를 인간의 행성으로 만들고 있다. 그 사업 중 일부가 동물 실험이다. 인간들은 희박한 가능성에 목숨을 기대했고, 동물들은 희박한 가능성에 목숨이 걸린다. 동물 실험을 볼 수 있는 영상 중에는 토끼가 눈과 코, 입과 귀에서 피를 흘리며 죽어가는 실험이 존재한다. 그리고 이는 인간들의 사욕과 우월 의식이 없었다면 자행할 수 없는 종류의 시행이다. 우리가 고등 지성체라는 이유를 들어 지구를 인간의 행성으로 만들려 했던 우월 의식은 인간이 점점 하등 생물에게 관심을 갖지 않도록 만든다. 허나 생물학적 먹이 사슬이라는 것이 존재함을 고려하면, 인간은 오히려 이러한 의식을 갖지 말아야 했다. 생태계가 건강하게 유지되는 이유는 포식자가 잡을 수 있는 피식자의 종족이 다양하기 때문인데 인간들은 점점 동물 실험이라는, 포식과 관련이 없는 부가적 이유로 개체 수를 감소시키고 있다. 우리가 지금까지 종족을 유지할 수 있었던 이유가 이 거대한 생태계 먹이그물의 안에서 보호 받고 있었기 때문인데 스스로 그 그물을 망가뜨리고 있다는 것이다. 우리는 늘 포식자로서 습성을 바라기에 대체 식품 또한 생산해내겠지만 그것이 과연 과거 인류가 포식하고 영양분을 찾았을 법한 것과 동일하리라 예측할 수 있는가? 설혹 그렇다한들, 언제나 실수할 수 있는 인간이 관여하는 생명 활동 유지 체계가 과연 단 한 번의 문제도 없이 모두를 부양할 수 있을까? 우리는 인간으로서 편리하게 누릴 수 있는 모든 것에게서 삶의 안락함을 추구하고 있다. 이 안락함에 슬슬 만족했다면 우리는 인간의 무한한 희망이라는 것을 핑계 삼아 다른 자연을 이용해서는 안 된다. 우리가 과거부터 함께 공존해 왔던 생명체들이 사라지고 나면 사슬의 여파에 따라 그 피해는 반드시 인간에게로 돌아온다. 이 점을 깨닫게 될 때 우리는 더 이

상 새로운 것을 탐하지 않을 때가 되었다. 정 인간의 가능성을 논하고 싶다면, 하이 리스크 하이 리턴으로 동물들을 해치며 인간 또한 해치는 방향이 아닌 점진적 발전과 인류의 안정된 미래를 도모하며 비생물 실험을 시도하는 방식으로 의학계는 노선을 틀어야 할 것이다.

2

동물 실험에 대한 찬반은 오랜 시간 동안 토론의 주제로 자리잡아왔으며, 현재에도 의견 충돌이 계속해서 일어나고 있다. 동물 실험의 효과는 완벽하지 않으며, 동물들에 대한 실험 윤리도 제대로 지켜지지 않아 많은 이들이 이에 반대한다. 이런 와중에 꼬마선충을 이용하는 실험 기술이 개발되었다는 것은 아주 기쁜 소식이라고 할 수 있다. 하지만 대체 기술의 등장으로 동물 실험을 완전히 멈추는 것이 가능할까?

자료에 쓰여 있는 것과 같이, 동물 실험은 고대 그리스 시대로 거슬러 올라갈 정도의 오래된 역사를 지녔으며, 지난 시간 동안 많은 과학 분야의 발전을 불러왔다. 이는 지금까지도 쓰이는 기술로, 현재 우리가 쓰는 의약품, 화장품 등의 대부분이 여기서 개발됐다. 비록 동물과 인간의 몸에 나타나는 효과가 다른 경우도 있다. 그러나, 그런 실패만 존재하는 것이라면 지금까지의 발전은 있을 수 없었을 것이다. 본문에 나온 약품인 아스피린과 페니실린 등의 의약품은 동물실험 과정에서의 오류가 밝혀졌고, 현재 많은 사람들이 잘 사용하고 있다. 한 번에 완벽한 결과가 나오는 실험은 없다. 어느 실험이든지 시행착오가 존재하는 법이며, 이는 과학의 발전을 불러온다. 단지 오류가 알려진 일부의 실험만으로 동물 실험이 잘못 됐다고 판단할 수는 없다.

현재로선 이를 대체할 수 있는 기술이 마땅히 존재하지 않는다. 꼬마선충 실험 기술과 같이 새로 개발되고 있는 기술은 소수이며, 이 마저도 사용할 수 없는 분야가 더 많다. 이는 보편적으로 이용할 수 있는 동물 실험이 격렬한 반대에도 아직까지 진행될 수밖에 없는 이유이다. 같은 인간을 대상으로 하면 실험의 오류가 줄어들 수 있고, 불쌍한 동물들을 이용하지 않아도 된다. 하지만 선뜻 실험 대상이 되겠다고 하는 사람이 얼마나 되겠는가? 결국 단시간에 많은 실험체를 확보하여 실험을 진행할 수 있는 동물 실험이 아직은 더 효율적이라는 결론이 나온다.

인간이 필요에 의해 마구잡이로 이용되는 동물들이 안쓰러운 것도 사실이다. 하루빨리 대체 기술이 개발되어 동물 실험이 필요 없어질 날이 오기를 바래본다.

3

저는 동물실험을 찬성합니다. 저는 동물을 많이 좋아하는 동물 애호가 중에 한 명입니다. 저도 동물이 실험에 이용되며 그로 인해 고통도 받고 심지어 죽기까지 하는 것을 잘 알고 있습니다. 그래서 예전에는 동물실험에 반대하는 입장이었습니다. 하지만 요즘 들어 느꼈습니다. 이런 코로나 시국에 저는 많은 사람들이 코로나에 걸려 고생하고 있다는 뉴스를 자주 봤고 심지어 사촌누나의 친구, 부모님의 지인 등 제가 아는 사람들도 감염이 됐다는 소식을 듣고 큰 충격을 받으면서 동시에 현실을 직시했습니다. 지금이야 백신이라는 것이 나온 상태라 안심을 할 수 있지만 전 앞으로 더 전염성이 높고 사람에게 더 치명적인 것들이 나올 것이라고 생각을 하고 무엇이든지 백신을 만들기 위해 어쩔 수 없이 동물실험을 해야만 하는 상황을 직시할 것입니다. 물론 성공률은 낮고, 많은 동물들이 희생되며 심지어 포유류와 사람이 공유하는 병이 적을지 몰라도 전 어쩔 수 없다고 생각합니다. 무책임한 말처럼 느껴질 수도 있지만 제가 동물을 많이 좋아하고 아낀다 해도 사람이 우선이라고 생각합니다. 사람이 고통 받고 힘들어 할 때 동물실험으로 그에 대한 해답이 나올 가능성이 단 1%라도 있다면 전 시도해야 된다고 생각합니다. 물론 다른 좋은 방안이 있다면 당연히 안 하는 것이 맞습니다. 근데 다른 방법은 없습니다. 많은 변수들이 존재하며 우리는 가장 최선의 방법으로 동물실험을 선택했습니다. 그런데 이런 활동을 중지하라면서 아무 대안도 내놓지 않는 사람들을 보면 무책임하다고 생각합니다. 단지 성공률이 낮다는 이유로 동물이 불쌍하다는 이유로, 물론 그 누구도 동물실험을 좋아하는 사람은 없습니다. 하지만 사람을 위해서 어쩔 수 없는 상황이니 막 반대하는 것이 아니라 현실을 직시하고 어떤 방법이 최선인지 곰곰이 생각해 보면 좋겠습니다.

4

저는 “과학연구를 위해 동물실험을 해야 한다”라는 주제에 찬성하는 입장입니다. 현재까지의 의학이 발생할 수 있었던 가장 큰 요인은 동물실험이었습니다. 물론 동물도 하나의 생명체이고 권리가 있음을 알고 있습니다. 그렇다면 돼지고기나 소고기도 먹으면

안 되는 것일까요? 우리가 이 문제에 대한 답을 찾기 위해서는 무엇이 더 중요한지 우선순위를 두어야 합니다. 누구나 만족하는 사회는 만들 수 없고 우리는 인간이기 때문입니다. 반대하는 입장에서는 대체 방안이 있음에도 왜 비윤리적인 동물 실험을 하냐고 묻습니다. 하지만 그러한 대체 방안들은 시간이 너무 많이 걸린다는 점과 부작용이 많다는 점에서 비효율적입니다. 화장품 같은 필수적이지 않은 곳에 사용되어지는 동물 실험은 저도 반대하지만 오늘날의 코로나 백신 같은 필수적이고 인류에게 중요한 의약개발에는 동물실험은 어쩔 수 없다고 생각됩니다. 앞으로 많은 기술들이 발달하여 완벽히 동물 실험을 하지 않고도 과학 연구가 진행되기 전까지는 동물의 희생이 필요합니다. 안타깝지만 좀 더 현실적인 측면에서 바라볼 수밖에 없는 것 같습니다. 수많은 전염병으로 많은 사람들이 고통 받고 죽어가는 상황에서 동물이 불쌍하다는 이유만으로 동물실험을 반대하는 것을 그저 무책임하다는 생각밖에 들지 않습니다. 동물실험을 찬성한다고 해서 동물을 싫어하는 것도 아니고 동물의 생명을 중요하지 않게 생각하는 것도 아닙니다. 동물의 희생에 감사해하며 살아가면 됩니다. 과학적인 발전과 윤리적 사상의 충동은 오늘날 우리 인류가 풀어야 할 가장 어려운 과제가 아닐까 생각합니다.

5

과학연구를 위해 동물 실험을 해야 한다는 의견에 반대하겠습니다. 첫 번째 이유는 생명은 소중하기 때문입니다. 동물 실험은 말 그대로 살아있는 생명체에게 비윤리적인 일을 하는 것입니다. 인간들처럼 생각을 할 수 있고 자신만의 언어로 말을 할 수 있으며 기쁨, 슬픔 등 많은 감정을 느낄 수 있는 동물들에게 알 수 없는 약을 먹이고 칼로 살을 잘라 고통을 느끼게 하는 것은 해서는 안 될 행동이라고 생각합니다. 두 번째 이유는 동물과 사람이 공유하는 병이 약 1%정도로 극히 드물기 때문입니다. 이 말은 동물에게 실험을 해도 그 결과가 정확하지 않으며 혹여 인간이 그 약을 먹었을 경우 몸에 이상이 생길 확률이 높다는 것이다. 실제로 독일의 입덧 방지약에 들어 있던 탈리도마이드라는 물질은 동물 실험에서는 아무런 부작용을 일으키지 않았지만 인간은 부작용을 겪었던 사례가 있습니다. 이처럼 이런 결과를 통해 동물 실험에서 실험용으로 살다가 죽은 동물의 수에 비해 모든 결과를 알 수 없이 이 실험은 의미가 없는 실험이라고 생각합니다. 마지막 이유로는 너무 많은 생명의 목숨을 희생해야 합니다. 동물실험은 매년 계속해서 증가하고 있으며 그에 따라 죽음을 당하는 동물 또한 증가하고 있습니다. 이렇게 동물 실험을 위해 너무 많은 생명체를 사용하고 있는데 이런 동물들 또한 강아지 공장과 같은 비윤리적인 곳에서 태어나는 경우가 많다고 합니다. 이처럼 동물 실험 때

문에 몇 백 마리의 동물들이 죽는 것은 더 이상 무시해서는 안 될 문제이며 쉽게 여겨서도 안 될 문제입니다. 이처럼 저는 이 3가지 이유에 따라 동물실험은 해서는 안 될 실험이라고 생각합니다. 누군가의 가족이 될 수 있고 한 생명체로서 살아있는 생명을 해치는 비윤리적인 실험은 이제 멈춰야 한다고 생각합니다. 지금이라도 동물이 아닌 다른 무언가로 대체할 수 있는 것을 찾고 개발해야하며 오히려 동물보다 훨씬 더 정확한 결과가 나올 수 있도록 많은 사람들이 서로 생각하고 방법을 찾아야한다고 생각합니다. 사람들이 이 문제에 대해 무관심하지 않고 조금만 관심을 가지고 귀 기울인다면 동물실험을 하지 않고 더 정확한 결과를 얻을 수 있는 실험을 분명히 찾을 수 있을 것이다.

6

나는 동물실험에 대해서 찬성하기도 하고 반대하기도 한다. 왜냐하면 동물들은 원하지 않는 실험으로 인해 죽거나 신체의 일부를 못 쓰기 된다거나 등의 부작용이 생기는데, 이렇게 강제적으로 원하지 않는 실험에 쓰이는 것을 사람들도 싫어하듯이 동물들도 힘들도 싫을 것이다. 그리고 동물들도 감각을 느끼고 존중을 받아야 할 권리가 있다. 또 동물실험에서 부작용이 일어나지 않는다고 해서 사람에게도 부작용이 일어나지 않는다는 법은 없고 동물실험에서 부작용이 일어나도 사람에게는 효과를 보일 수도 있다. 그래서, 동물실험을 통해 모든 부작용을 예측할 수도 없고, 동물과 사람이 공유하는 질병은 1% 정도로 극히 드물다고 하여 동물실험이 필요 없다고 생각이 된다. 동물실험이 약을 실험하기 위해서는 가장 빠른 결과를 얻고 부작용도 살펴볼 수 있고 인간에게 투약할 수 없는 것을 대신하는 거라 하지만, 위에 있는 이유로 동물실험을 반대하기도 하지만 동물실험을 대체할 기술이 없고, 인간에게 약을 실험하는 것이 가장 정확하고 명확한 결과를 얻을 수도 있지만 그럴 수 없기도 하다. 그리고 인간을 목적으로 대하는 것 자체가 올바른 행동이 아니지만 만약 사용하더라도 실험결과를 얻기까지 너무 낳은 시간이 걸리기도 한다. 컴퓨터를 이용하여 시뮬레이션을 돌려본다고 해도 그 수많은 변수를 전부 다 데이터화할 수도 없고, 이로 인해 부작용과 효과들을 전부 예측할 순 없다. 하지만 동물을 사용함으로써 빠르게 결과를 얻고, 부작용과 효과들을 살펴볼 수 있기 때문에 대체 할 만한 기술이 나오지 않는 이상은 필요할 거라고 생각한다. 하지만 동물실험도 윤리적인 문제가 있고, 동물들도 존중받아야 할 권리가 있지만 그렇다고 동물실험을 안하기에는 동물실험이 너무 불가피해서 나는 동물실험에 대해서 찬성하기도 하며 반대하기도 하는 중립이다.

7

나는 '동물 실험을 해야 한다'라는 의견에 찬성한다. 이 의견에 찬성하는 근거로 가장 먼저 제시할 것은 바로 완벽한 대체 수단이 없는 기술이라는 점이다. 동물 실험의 목적 자체는 인류에게 필요한 약이나 병, 유해한 것들이 인류에게 얼마나 도움이 되거나 얼마나 해로운지를 동물에게 실험을 하여 밝히는 것이라 생각하는데 이러한 실험을 동물에게 하는 이유는 인간에겐 이러한 실험을 윤리적(?) 문제로 할 수 없기 때문이라 생각한다. 즉 인류에게 필요한 결과를 알아내기 위해선 어쩔 수 없이 동물 실험을 완전히 포기할 수는 없다고 생각한다. 이곳에서 컴퓨터를 활용해서 시뮬레이션을 돌려서 결과를 도출한다고 해도 실험에서 생기는 수많은 변수들을 전부 데이터화하기엔 무리가 있고 부작용 또한 동물 실험을 하는 것보단 정확하지 않게 나올 가능성이 높다. 이러한 이유들로 대체 수단이 나오기 이전엔 동물 실험을 완벽하게 포기하기엔 어렵다고 생각하기에 나는 동물 실험에 대해 찬성한다. 그렇다고 무분별하게 하는 것을 찬성하는 것은 아니다. 필요에 따라 어느 정도 조절을 하거나 유해동물(?)들을 대상으로 실험을 하는 것도 방법이다. 물론 이런 식으로 조절 하다 보면 결과가 더욱 불투명하게 나오거나 아예 원하지 않는 결과가 나올 수도 있지만 무분별하게 실험을 하여 수많은 생명을 해치는 것보단 필요에 따라 조금씩 발전해 나가는 것이 조금 더 효율적이라 생각한다. 최근 국내 연구진의 포유동물 실험을 하지 않고 꼬마선충을 대상으로 항암제 독성을 실험하는 것과 같이 이와 같은 방법으로 천천히 기술을 발전시켜 나간다면 포유동물을 대상으로 한 실험과 무분별한 실험을 조금이나마 줄일 수 있다고 생각한다. 과학 발전은 때로 윤리적 문제와 부딪친다. 이것에 대해 가장 효율적으로 발전시켜 나가는 것이 가장 바람직하고 현재 가장 옳은 방법이라 생각한다.

8

인간을 위해 죄 없는 동물들이 희생당하는 것이 과연 옳은 일일까? 의학 기술이 발전하고, 새로운 약들이 많이 발명되면서 실험에 쓰이는 동물들은 더 증가하고 있다. 2015년 한 해 동안 실험에 사용된 동물이 무려 250만 마리에 달한다. 인간의 편의를 위해

말을 하지 못한다는 이유만으로 동물들은 태어나면서부터 좁은 실험실에 갇혀 실험 용도로 사용되다가 생을 마감하게 된다. 어떠한 이유로 죄 없는 동물들이 인간을 위해 희생해야 하는 것일까? 동물 실험을 찬성하는 사람들은 인간에게 투약할 수는 없으니까, 많은 시간이 걸리니까 동물을 사용해 실험한다고 말한다. 동물들과 인간들의 차이점은 무엇일까. 똑같이 살아 숨 쉬고 고통을 느끼는 존재인데 인간이 동물보다 우월하다고 생각하고 동물들을 함부로 대한다. 하지만 아스피린과 페니실린 등의 많은 의약품들이 동물과 인간에게 나타나는 효과가 다르다. 실제로 동물과 인간이 공유하는 병은 약 1% 밖에 되지 않는다는 것이다. 따라서 동물 실험이 성공했어도 인간에게 투약했을 때는 결과가 달라질 수 있다는 뜻이다. 매년 몇 백만 마리의 동물들이 고작 1%의 확률을 위해서 희생되는 것이다. 성공한 1%를 제외한 99%는 무의미한 희생을 당하게 되는 것이라고 생각한다. 포유동물을 대체하여 꼬마 선충을 사용한 실험과 같은 사례들을 보면, 기술들이 점점 발달하여 대체 대상들이 점점 늘어날 것이고, 컴퓨터 시뮬레이션을 활용하는 것 등의 기술이 발달하면 동물의 희생도 줄일 수 있을 것이라고 생각한다. 그 전까지는 동물 실험이 불가피하게 일어나겠지만, 적어도 인간들이 동물의 희생을 당연하게 생각하지 않고 적어도 동물들의 희생을 고맙게 생각해주면 어떨까. 마지막으로 몇 백만 마리의 죄 없는 동물들의 희생들을 안타깝게 생각해야겠다. 내가 먹는 모든 약들이 동물들이 희생으로 만들어진 약이라고 생각하니 마음이 아프다. 앞으로는 모든 약을 먹을 때 많은 동물들의 희생을 미안하게 생각하고 고마운 마음으로 살아가야겠다.

9

고대 그리스 시대의 히포크라테스와 아리스토텔레스부터 16세기 베살리우스, 19세기를 거쳐 현재까지 동물실험을 통해 의학과 생물학이 발전해왔다. 이와 함께 동물 실험을 반대하는 사람들도 늘어났다.

동물실험을 반대하는 사람들은 동물에게는 어떤 부작용도 일으키지 않지만 사람에게는 부작용이 일어나는 경우와 그 반대의 경우를 예를 든다. 또한 동물과 인간이 공유하는 병이 전체의 1%정도밖에 안 되고 이에 따라 동물실험으로 모든 효과와 부작용을 정확하게 예상할 수 없다. 이것을 근거로 효율이 떨어진다는 주장을 내세운다. 이렇게 동물실험을 반대하는 사람들도 있다.

하지만 내 생각은 좀 다르다. 우선 나는 동물 실험에 찬성하는 입장이다. 물론 인간과 동물이 공유하는 질병들의 수가 매우 적고 정확한 예측이 불가능하다고 해서 인간을 실험에 사용할 수는 없다. 인간에게 사용되는 약인만큼 인간에게 사용하는 것이 가장 정

확하긴 하겠지만 부작용도 모르는 약을 실험해보는 것은 윤리에 어긋난다고 생각한다. 또한 인간에게 실험을 한다고 해도 실험의 결과가 도출되기까지 너무 많은 시간이 걸리게 된다. 아직은 동물 실험을 완벽히 대체할 기술도 없고 컴퓨터를 사용해도 모든 변수를 데이터화해 시뮬레이션을 할 수 없다는 점도 근거로 말할 수 있다.

동물실험을 하지 않고 완벽하게 대체할 기술이 생기면 그때는 당연히 동물실험에 반대할 것이다. 무엇이 정답인지는 알 수 없지만 최대한 윤리적으로 과학이 발전할 수 있는 방법을 사용하면 좋겠다.

10

나는 개인적으로 동물실험에 찬성한다. 고대 그리스에 동물실험을 통해 과학과 의학 등을 발전시켰다. 만약에 동물실험이 아니였으면 우리의 과학이 이렇게 발전할 수 있었을까? 물론 동물실험이 좋다고는 생각 안 한다. 당연히 동물도 하나의 생명이고 소중한 존재이다. 하지만 나는 이 글에도 나와 있듯이 대체 기술이 발명되기 전에는 어쩔 수 없다고 생각한다. 그렇다고 인간에게 약을 투여하여 부작용을 살펴볼 수도 없기 때문에 아직은 어쩔 수 없는 것 같다. 그런데 결국 이 동물실험을 반대하는 사람들도 동물실험을 통해 만들어진 화장품, 약 등을 쓰고 있지 아니한가? 이거에 대해서 동물실험을 반대하는 사람들에 이야기를 들어보고 싶다.

동물실험에 대한 문제를 해결하기 위한 방법은 나는 이렇게 생각한다. 실험을 당하는 동물을 당연하듯이 다루지 말고 감사하고 미안한 마음으로 다루는 것이 진짜 최소한의 방법인거 같다. 아니면 동물실험을 조금이라도 줄여서 동물실험에 반대하는 사람들과 같이 맞춰나가면서 한시라고 빨리 부작용을 확인할 수 있는 기술이 나오기를 기다리는 것이 최선이다.

하지만 내 마음에 30%정도 반대하는 마음이 있다. 동물을 좋아하고 키웠던 입장으로서 귀엽고 사랑스러운 동물에게 약을 투여해서 부작용을 확인한다는 것이 정말 마음 아프고 슬프다. 그리고 이 글에 나와 있듯이 동물과 사람이 공유하는 병이 약 1% 정도로 극히 드물다면 굳이 동물실험을 해서 동물을 죽일 필요가 있을까 생각이 든다. 그리고 동물과 인간에게 나타나는 효과도 다르고 동물실험을 통해 모든 부작용을 정확하게 예측할 수 없으면 진짜 이 동물실험을 왜하는지 잘 모르겠다. 또 실험을 한 후 실험 결과를 얻기까지 많은 시간이 걸리고, 컴퓨터를 활용해 시뮬레이션을 해도 수많은 변수를 전부 데이터화할 수 없다면 진짜 동물실험을 안 해도 될 것 같다. 처음엔 찬성하는 입장이 컸으나 지금은 살짝 반대하는 입장이 커진 것 같다.

11

국내 연구진이 포유동물 실험을 하지 않고 예쁜 꼬마 선충을 대상으로 항암제 독성을 실험하는 기술을 개발했다고 한다. 분명히 이는 의료계에 한 획을 그을 기술일 수도 있고, 항암제 독성 실험에 사용되는 포유동물의 수를 줄일 수 있다는 기대를 받고 있는 것도 사실이다. 이 기술은 포유동물을 독성 실험의 피실험체로 사용하는 것에 대해 반대하는 사람들이 생각보다 정말 많기 때문에 라는 이유로 개발된 것도 없지 않을 것이다. 포유동물 실험에 반대하는 사람들의 주된 입장은 '동물을 존중하자'와 '인간과 포유동물이 공유하는 질병이 1%정도밖에 되지 않는다.'이다. 실제로 맞는 말이긴 하지만 나는 이 사람들의 주장은 모순된다는 생각이 든다. 따라서 나는 동물실험이 필요하다고 생각한다.

첫 번째 이유로는 사람과 가장 비슷한 동물 종은 포유류이기 때문이다. 동물실험에 반대하는 사람들의 주장처럼 포유류와 사람이 공유하는 질병이 1% 남짓이라면 사람과는 비슷한 부분이 거의 없는 예를 들어 예쁜 꼬마 선충은 사람과 공유하는 질병이 얼마나 될까? 그리고 동물실험 반대자들은 동물과 사람의 독성 반응이 다르다고도 말한다. 하지만 반응이 같은 항암제(항생제)의 수가 더 많을뿐더러 인간과 가장 비슷한 포유류의 실험 결과도 믿지 않는 사람들이 어떻게 곤충의 항암제(항생제) 실험 결과를 믿을 수 있을까 하는 의문이 들었다. 두 번째 이유는 동물 실험을 통해 현대 의학이 비약적으로 발전을 한 것은 사실이라는 것이다. 자료에 나와 있듯이 고대 그리스 시대부터 동물실험이 시작되어 현대에 오기까지 지금의 수술에서 빠질 수 없는 의학의 기초 학문인 해부학을 엄청나게 발전시켰고, 발생학, 독성학, 생리학 등 여러 학문을 발전시켜왔다. 동물실험이 없었다면 아마 우리는 지금쯤 제대로 된 수술을 받지도 못하고, 우리 몸의 어떤 부분에 어떤 장기가 있는지도 알지 못했을 것이다. 지금도 의학이 완전한 발전을 이룬 것은 아니고 아직 임상 실험, 동물실험을 확실히 대체할 만한 대안도 발견되지 않았고 여전히 의학은 발전 중이다. 따라서 지금 이 시점에서 동물실험을 멈춘다면 고대 그리스 시대 이전의 발전 속도보다는 빠르겠지만 그와 비슷한 속도로 발전할 것이다. 만약 동물실험을 100% 대체할 만한 기술이 나온다면 동물 실험에 찬성하지 않겠지만, 현재로서는 동물실험이 불가피하다고 생각한다.

세 번째 이유는 동물실험으로 다른 어떠한 방법보다 확실한 해답을 얻을 수 있다는 것이다. 실제로 생명체 내에서는 수 만 가지의 변이와 변수가 존재한다. 포유류는 인간만큼은 아니지만 몸 구조가 아주 복잡하다. 그리고 반응도 비교적 빨리 나타나기 때문에

우리 인간의 목적인 '의료용 약품 개발'의 취지와 완전히 부합한다. 솔직히 동물실험이 금지된다면 사람들도 앞으로 맞을 백신, 치료제에 대한 불신이 커질 것이다. 그래서 최악의 경우 백신을 맞지 않는다는 사람이 나오고, 지금처럼(코로나 19 바이러스처럼) 전염성이 큰 바이러스가 아니라도 별거 아닌 바이러스가 유행한다 해도 지금과 같은 상황이 연출될 수 있다.

이러한 이유로 나는 동물실험에 찬성한다. 하지만 윤리 문제도 있기 때문에 동물실험을 대체할 기술이 빨리 개발되어야 한다고 생각한다. 어쩔 수 없는 실험이지만, 동물실험을 통해 그 희생만큼 좋은 결과가 나오고, 의학이 발전했으면 좋겠다.

12

나는 '과학 연구를 위해 동물 실험을 해야 한다'라는 논제에 대해 반대의 입장이다. 이러한 입장에 대해서 세 가지의 근거를 들 수 있다.

첫째, 동물은 인간과 다르지 않다. 사람은 고통은 피하고 쾌락을 추구하는 경향이 있다. 또한 인간의 행복추구권은 헌법에도 명시되어 있기 때문에 인간을 대상으로 하는 실험은 아마 모든 사람이 반대 할 것이다. 그러나 인간에 대한 실험은 반대하면서 동물을 대상으로 하는 실험은 찬성하는 사람들이 있는데, 이는 동물이 인간과 다르지 않다는 것을 간과한 것이다. 포유동물들은 신경계가 있고, 그것을 느낄 수 있는 뇌가 있기 때문에 인간과 똑같이 고통을 느낀다. 또한 인간의 '감정'과 마찬가지로 동물의 '감정'을 조절하는 호르몬이 분비된다. 따라서 동물도 쾌락을 추구한다. 그렇기 때문에 인간을 대상으로 하는 실험에는 반대를, 동물실험은 찬성하는 것은 논리적으로 모순이 존재하며, 이기주의적 태도이다.

둘째, 경제성만을 추구하는 것은 근대의 방식이다. 예를 들어, 다수의 생쥐나 토끼 등을 우리에 가두고 다양한 약물을 투여하여 실험의 결과를 얻는 것은, 인간의 장기와 비슷한 기관을 인공으로 제작하여 실험하는 것보다 효율적이고 경제적이다. 하지만, 오늘날의 국가들이 국가의 발전만을 추구하지 않고, 국민의 복지증진과 삶의 질에 기여하는 것에 노력하듯, 과학계에서도 효율성과 경제성만을 추구하면 안 된다. 과학계에서도 윤리적 측면이 효율성 못지않게 중요한 요소로 고려되어야 한다.

셋째, 과학기술의 진보로 동물실험을 대체할 수 있다. 예를 들어 생물의 해부나 신체구조와 같은 측면의 실험은 과학기술이 발달하기 전 물리적 해부를 통해 직접 기관을 관찰하는 방법이 유일했다. 하지만, 과학기술이 진보한 시대에 우리는 해부를 직접 수행하지 않고도 X선 촬영과 같은 기술을 통해 특정대상의 내부를 연구할 수 있다. 또한

3D프린터의 사용으로 동물의 장기와 비슷한 기능을 하는 회로를 가진 인공장기 등을 제작 할 수 있다. 이는 특정 자극에 대해 인공장기가 인간과 유사하지 않은 반응을 보일 수 있다는 비판을 직면할 가능성이 있지만, 유사성의 측면에서는 동물과 인간이 공유하는 병이 약 1%정도로 극히 드물기 때문에 동물실험이 인공장기보다 정확한지에 대해서는 미지수이다.

오늘날 의료 또는 피부미용 등의 다양한 분야에서 동물 실험이 이루어지고 있다. 기술발전의 관점에서, 동물 실험이 인간의 문명발전에 중요한 역할을 했다는 것은 사실이다. 그러나 인간에 대한 인권뿐만 아니라 인간의 생명권도 존중해 줄 만큼 시민의식이 성장한 현대 사회에서의 동물 실험은 윤리적 측면에서 비판을 피해 갈수 없다. 또한 동물의 입장에서는 동물실험을 인간이라는 생물중의 이기적이고 무자비한 학살이라고 표현 될 수 있다.

인간과 동물의 생명의 가치는 다르지 않으며 인간은 동물을 가두고 실험할 수 있는 권리도 없다. 따라서 나는 동물실험에 반대한다.

13

국내에서 포유동물 실험을 하지 않고 예쁜 꼬마선충을 대상으로 항암제 독성을 실험하는 기술이 개발되었다는 소식을 시작으로 과학의 발전을 위해 동물실험에 대한 생명윤리에 대한 이야기를 전달하고 있다. 우선 개인적인 입장을 밝히자면 동물 실험자체가 크게 나쁘다고 보진 않는다. 과학 그중에서도 의료, 생명 등의 분야로 쓰인 동물 실험 덕분에 지금까지 최단시간으로 과학이 많이 발전했다. 하지만 이를 악용하고 동물을 조심히 다루어 주지 않는다면 문제가 될 수 있다. 실험목적 자체가 나쁘고 동물들도 소중히, 조심히 다뤄주는 것이 아니라면 윤리적 기반에 있어 이를 철저히 막아야 한다고 본다. 그러나 동물들을 소중히 대한다면 당연히 실험으로 인해 죽은 생명들도 줄어 들 테고, 실험체를 무작위로 남용하는 일들도 없을 것이다.

그렇다고 해서 동물들을 일방적으로 실험체로 사용하자는 것은 아니다.

한 사례를 예로 들자면 독일의 입덧 방지약에 들어 있던 탈리도마이드라는 물질은 쥐나 개, 고양이에 대한 동물실험에서 아무런 부작용을 일으키지 않았지만 정작 원숭이와 사람에게는 부작용이 일어났다. 이처럼 약에 들어있는 성분이 각각 동물들 체내 속에서 어떠한 일들을 벌이는지 동물들 몸속에 들어있는 기관, 체액, 장기 등이 이 약과 만나면 어떻게 되는지를 먼저 실험하기 전에 충분한 가설 또는 입증을 해야 한다고 본다. 물론 실험자체가 정확한 확인결과를 도출하는 데에 목적을 두는 것이지만 생명을 다루

는 일인 만큼 실험 전에도 충분한 이론 습득과 실험체에 대한 완벽한 이해를 하고 실험을 진행해야한다고 생각한다. 그렇지만 이렇게 시행을 했는데도 죽으면 괜찮다는 얘기는 아니다.

그 전에 미리 치료 가능한 환경을 만들고 실험동물 역시 엄중히 골라 실험을 실패해도 회복 가능한 요건을 미리 만들어 두어야 하는 것 역시 당연하다.

이처럼 동물실험이 사회적 혼란을 불러일으키는 이유는 아무래도 실험 자체가 안전하지 않고 생사를 결정하기 때문이다. 하지만 이러한 실험이 있었기에 우리는 현재 많은 발전을 이루어 냈다. 이러한 실험이 없었더라면 우리 인간의 생존율이 낮아졌을 것이다. 때문에 동물실험자체가 나쁘다고 보지는 않지만 이를 악용하고, 생명을 존중하는 기본적인 윤리적 자세가 되어있지 않다면 충분히 이를 막아야 한다고 보는 사람들에게 공감을 느낄 것이다. 반대로 이러한 자세가 되어있다면 계속 지켜보고 믿어보는 것도 나쁘지는 않은 것 같다.

14

저는 과학연구를 위해 동물 실험을 해야 한다에 찬성합니다.

제가 찬성하는 이유는 인간에게는 곡 필요한 것이기 때문입니다. 과학실험이라고 했었는데 의료목적의 한해서만 찬성합니다. 동물 실험이 우리가 현재 누리는 건강에 많은 부분을 가지고 있을 겁니다. 많은 바이러스를 극복하기 위해서는 짧은 기간에 약효가 확실해야 하며 신뢰 가능해야 합니다. 동물은 이를 위해 실험에 쓰였습니다. 물론 동물에게는 이롭고 사람에게는 해로울 수 있지만 하지만 하지 않았더라면 사람에게는 큰 재앙이 될 수밖에 없습니다. 인체에 실험 또한 방법이지만 실험에 필요한 인간수를 정해놓고 실험을 한다면 약효 발현이나 부작용이 늦게 일어나며 실험체의 수의 한계가 너무 낮을 수밖에 없습니다. 이렇게 된다면 정확도에 대한 신뢰는 낮아지며 바이러스에 피해가 늘어날 것입니다. 하지만 이에 윤리적 문제로 본다면 생명을 해하는 것은 윤리에 어긋납니다. 그런데 인간과 자연은 유기적 관계에 있으며 인간이 고기를 먹는 것은 자연의 먹이사슬의 가장 위에 있으며 그 그물 안에는 고기와 채소 등이 있었던 것이죠. 그렇다면 인간이 동물에게 인간을 위한 실험을 하는 것은 정말 잘못된 것일까? 자연적으로 인간이 누릴 수 있는 권한이라고 생각한다. 하지만 그들도 생명이기에 우리는 생명의 소비에 대한 것을 줄여야만 한다.

가장 효율적인 방법으로 실험해서 줄여야만 한다. 우리의 무차별적인 소비로 생태계와 윤리의식에서 어긋나지 않게 그리고 그 생명을 생명체로서 끝까지 존중해야하며 실험후

의 처리를 실험체로서가 아닌 생명으로서 생을 이거가거나 생을 마감할 수 있도록 해줘야 한다고 생각합니다. 앞으로도 동물 실험은 계속 될 것이다. 하지만 그 과정에서 부끄럼이 없어야 할 것이고 가장 효율적이며 소비를 최소한으로 할 수 있는 방법에 대해 우리 인류는 고민하며 생각해야만 한다.

15

나는 과학 연구를 위해 동물 실험을 해야 한다고 생각한다. 동물 실험은 많은 이로운 의약품을 발명할 수 있었고, 해부학, 발생학, 의학, 생물학 등 많은 학문에서도 발전을 시킬 수 있었다. 사람과 동물 간 공유하는 병이 적고, 동물 실험이 실패한 사례들이 있기도 하다. 하지만 나는 이것은 소수 사례일 뿐이라고 생각한다. 만약 처음부터 동물 실험을 하지 않았더라면, 이들과는 비교도 안 될 정도로 많은 부작용들과 치명적인 위험 사례들이 있었을 것이라 생각한다. 동물 실험은 동물에겐 매우 미안하지만, 인간들이 살기 위해서는 어느 정도 희생 할 수 있다 생각한다. 나도 동물들을 매우 아끼고 사랑하지만 그저 불쌍하다고 감정적으로만 접근 할 일이 아니라 생각한다. 이성적으로 판단을 내렸을 때, 인간에게 사용될 화장품, 의약품뿐만 아니라 동물들의 의약품을 개발하고 부작용을 낮추기 위하여 실험을 할 수 있는 방법은 동물 실험을 제외하고는 거의 없다. 인간을 실험하여 생체 실험을 하겠다고 했을 땐, 더 큰 윤리적 갈등이 일어나게 될 것이다. 그나마 같은 포유류이기도 하니 동물들이 실험의 대체물둘이 되는 것 같다. 죄 없이 실험용 동물로 태어나고 자라 실험을 기다리는 동물들에게는 정말 미안함을 가지고 엄숙하게 실험을 해야 한다 생각한다. 그리고 동물 실험이 없었더라면 현대 의학까지 발전하는 것은 꿈도 못 꾸었을 것이다. 동물 실험으로 동물들의 내장의 위치 등을 파악하여 생물학과 해부학에 큰 발전이 가능했으며, 현대 의학 수준까지도 크게 성장하게 되었다. 동물 실험이 없었더라면 의학이 발전하지 못 해 평균 수명 또한 크게 감소하였을 것이라 생각한다. 물론 나도 동물 실험의 단점을 알고 있다. 그러므로 앞으로는 동물들을 대체하여 실험이 가능한 대상을 찾고 개발하여 널리 쓰이게 될 것을 기대한다. 과학과 윤리의 갈등, 대립이 갈수록 커지는 것 같다. 이 둘의 중간 지점을 찾아 둘 중 한 가지로 치우치지 않고 균형을 잘 맞추어 빠른 시간 내에 사람들과 동물이 조화로운 삶을 살도록 기대한다.

16

저는 동물실험을 해야 한다고 생각합니다. 왜냐하면 인류에 발전에 있어서는 희생이 따라야만 한다고 생각하기 때문입니다. 여지껏 동물실험을 하면서 인류는 많은 발전과 진화를 했습니다. 우주선에 강아지를 태워 보내기도 했습니다. 결국 그 강아지는 죽었지만 그 강아지 덕분에 인류는 우주에 대해 더욱 심도 있게 연구하고 알아낼 수 있는 기반을 만들었다고 생각합니다. 강아지 한 마리의 희생으로 인간은 우주에 대해 더 많은 자료를 수집할 수 있었습니다. 그리고 여러 실험에 사용하는 하얀 쥐도 마찬가지입니다. 그 쥐들이 자신의 몸을 내주어서 여러 가지 실험을 하고 병을 찾아내고 치료제를 찾아내고 그러는 것입니다. 만약 동물실험을 하지 않았다면 인류는 어떻게 될까요. 과학 기술이 엄청 많이 뒤쳐져있는 삶을 살았을 것입니다. 우주에 인공위성도 없고 달 표면에 꽂혀있는 미국 국기도 아직 꽂혀있지 않을 것입니다. 의료 시스템이나 산업, 마케팅적으로도 발달이 덜 이루어져있을 겁니다. 그럼 국가 경제도 좋을 수 없겠죠. 치료제 개발도 늦어져서 전염병이 확산될 때 우리는 이미 감염되어 치료제가 완성되길 손가락 물고 지켜봐야 할 것입니다. 동물 실험을 할 수 없으니 사람에게 밖에 실험할 수 없는데 부작용이라도 일어나면 실험에 참여했던 사람들이 많이 희생당할 것입니다. 저는 위와 같은 이유로 동물실험을 어쩔 수 없이 해야 한다고 생각합니다. 우리는 동물실험에 실험대상이 된 동물들의 희생에 감사하고 또 다른 희생될 동물들이 최대한 없게 빨리 정확하고 효과가 있는 그럼 제품, 치료제, 연구를 진행해야 한다고 생각합니다. 저도 동물을 정말 좋아하고 아낍니다. 동물들이 실험 대상 연구 대상으로 활용되고 희생당하는 게 정말 안타깝고 슬프지만 전 인류의 생존과 후대 사람들에게 더 편리한 건강한 삶을 주기 위해 동물실험을 해야 한다고 생각합니다. 실험 당하고 연구 대상이 되는 동물들에게 고맙고 감사하게 생각하지만 앞으로도 계속 실험 당해주면 고마울 것입니다.

17

나는 동물실험을 하는 것에 찬성한다. 모든 생물의 목숨은 소중하지만 인간에게 어떤 바이러스나 질병이 나타날지는 아무도 모르고 그에 대한 대처 또는 예방을 위해 동물실

험을 하는 것은 당연한 일이다. 그 실험은 위험할 수 있고 시간도 오래 걸려 결과가 더디기 때문에 실험용 동물이 생긴 것이다. 비록 그 동물들이 불쌍하지만 그런 것을 생각하였다면 인간은 여기까지 발전해오지 못했을 것이다. 아주 오래전부터 인간에게 해로운 질병이 존재하였고 그 질병을 치료하는 법을 찾기 위해 동물들이 실험 대상이 되었다. 특히 동물들은 우리와 인체 구조가 거의 비슷하기 때문에 인간에게 투여하였을 때의 반응과 비슷하게 나타날 것이다. 인간과 비슷한 반응을 얻는 것이 실험의 목적이고 그게 성공한다면 인간의 그 의약품을 사용할 수 있다. 만약 동물실험이 허용되지 않으면 우리는 약 하나를 맞더라도 불안할 것이며 부작용의 피해도 클 것이다. 또한 과학연구에서 동물실험을 하지 않았더라면 인간은 진화를 멈췄거나 아주 느렸을 것이고 어떤 것이 인체에 해로운 것이고 해롭지 않은 것인지에 대한 정보도 없었을 것이다. 동물실험은 인간이 지금까지 발전하게 한 주 원인이다. 그러한 동물들의 희생으로 우리가 건강하게 살 수 있었던 것이기 때문이다. 물론 동물들이 인간을 위해서 사용되는 수단으로 생각하여 동물실험을 당연시하는 태도는 올바르지 못하다. 그러나 아직 동물실험을 대체할 어떠한 수단이나 기술이 존재하지 않는다. 이러한 기술들이 발달하기 전까지 나는 동물실험을 찬성한다.

18

나는 이 글을 읽기 전까지는 동물실험을 통과하면 사람에게도 잘 맞으니 동물실험은 불가피하다고 생각했다. 하지만 많은 의약품들이 동물과 인간에게 나타나는 효과가 달라 부작용을 정확하게 예측하기 어렵다는 것을 알게 되었다. 그렇다면 동물실험을 왜 하는 것일까 인간의 발전을 위해 우리는 그동안 수많은 생명들을 죽여 왔다. 생존을 위한 먹이사슬은 생태계의 자연스러운 일이지만 우리는 생존이 아닌 우리 만족을 위해 털을 산 채로 뽑고, 가죽을 벗기고 태우는 등 비윤리적인 행동을 행해왔다. 최근 나는 한 영상을 보게 되었다. 인간의 발전과 망가져가는 환경들에 대한 영상이었다. 그 중 뇌리에 꽂혔던 것은 인간을 제외한 많은 생물들이 인간을 위해 만들어지고 인간들을 위해 죽는다고 한다. 해서 이러한 인간의 만행과 동물들의 죽음은 나를 혼란스럽게 한다. 동물실험은 인간의 '생존'과 관련되있기 때문이다. 아무리 사람에게 실험하는 것이 정확하다고 한들, 행해질 수 없기에 그나마 인간과 유사한 동물에게 실험을 한다는 것이 어쩔 수 없다고 생각이 든다.

따라서 '나는 동물실험을 하지 말아야 한다.'까지는 못 말하겠지만 최대한 그들을 윤리적으로 하나의 생명으로서 보고 필요한 경우에만 실험이 행해져야 한다고 생각한다. 인

간과 동물이 공유하는 병은 약 1%라고 한다. 따라서 그 병에 대해서만 실험을 하고, 인간에게 치명적인지 정도만 파악해야한다고 생각한다. 생명은 무게가 없기 때문이다. 또한 나는 이러한 인간의 '생존'과 관련되어 불가피하게 동물들의 희생이 강요되는 '동물실험'보다는 인간의 '만족'과 관련되어 무자비하고 비윤리적으로 동물들이 희생되는 동물 가죽 가방, 옷, 신발, 무자비한 포획 등이 사라져야 한다고 생각한다. 당연하게 동물실험에 대해 금지하란 말이 나온다면 그런 것들도 금지해야 하는 게 우선시 되야 하는 것이 당연하다. 인간들이 더 이상 자신들의 이익과 만족으로 다른 생물 등을 해치지 않았으면 좋겠으며, 환경 보호에도 힘을 썼으면 좋겠다.

19

나는 과학 연구를 위해 동물실험을 해야 한다고 생각한다. 인간에게 사용되는 의약품의 효과, 부작용을 검증해보기 위해서는 실제 투여 대상인 인간에게 투여하기 전, 실험해 보아야 할 대상이 필요한데, 현재 우리의 기술 발달 상황을 보았을 때에는, 약품 독성을 실험하기 위해 동물실험을 하는 것이 불가피하다.

아직까지는 동물실험을 대체할 기술이 크게 개발되지 않았다. <자료>에 나와 있듯이, 항암제 독성 실험에 꼬마 선충을 사용함으로써 동물실험으로 사용되는 포유동물의 수를 줄일 수 있고, 컴퓨터를 활용해 시뮬레이션을 해 보는 방법도 있다. 동물실험을 대체하려면 이러한 기술들의 발달이 더 이루어져야 하고, 이것에 대해 더 많은 지원이 필요하다. 많은 약들이 개발되고 있고, 현재도 독성 검증을 기다리고 있는 약들이 계속 생기는 사회에서, 동물실험은 피할 수 없는 영역이다.

또, 동물실험을 하지 않고 인간을 대상으로 약 독성 검증 실험을 해서는 안 된다. 아스피린, 페니실린 등은 인간에게 좋은 영향을 끼치기도 하지만 환자의 상태에 따라 오히려 독이 될 수도 있다. 예를 들어 아스피린은 진통제로서 알려져 있지만, 다른 역할도 한다. 환자가 다른 기저 질환을 앓고 있는 상태일 경우, 오히려 아스피린이 독이 되는 경우가 있어 복용 시 주의해야 한다. 부작용도 사람마다 다르므로 복용에 있어서 신중해야 한다. 이러한 약을 동물실험 없이 인간에게 먼저 투여하게 된다면, 그 애상이 된 인간은 아주 위험한 상황에 처할 수도 있고, 환각 등의 부작용으로 인해 타인과 사회에 피해를 줄지도 모른다. 검증되지 않은 약을 인간에게 먼저 투여하는 것은 인간의 존엄성을 침해하는 행위로 윤리에도 어긋나고, 너무나도 위험한 행위이다. 독성이 검증되기까지의 시간, 인간의 희생이 더해져 오히려 신약이 판매되는 속도가 더디게 되어, 오히려 사회에 악영향을 줄 것이다.

인간들은 여태까지 질병에 대한 약의 독성을 검증하는 데에 동물실험을 대부분 사용해왔기에, 동물실험을 윤리적인 방향으로 개선하고, 신약을 개발할 때 사람과 동물에게 큰 부작용을 끼치지 않도록 개발하도록 노력해야 한다. 또는 동물실험을 대체할 방법을 연구하는 것도 대안이 될 것이다. 나 또한 동물실험의 동물에 대한 윤리적 측면에 대해서는 부정적이지만, 동물실험이 불가피한 지금, 동물실험은 이루어져야 하고 동시에 환경과 생물을 생각하는 신약 개발 기술, 실험 기술이 같이 발전되어야 한다고 생각한다.

20

나는 "과학 연구를 위해 동물실험을 해야 한다"는 의견에 반대한다. 본문에서는 고대 그리스부터 동물실험이 이루어졌고 동물실험을 찬성하는 입장을 보면 이 실험이 완벽하게 대체가 불가능하다고 말하며 인간에게 실험하는 건 불가능하니 동물에게 실험을 진행한다고 하는데, 내가 동물실험을 반대하는 첫 번째 이유는 생명윤리이다. 동물들도 인간과 같이 살아있는 생명체이고 소중한 존재인데 과연 인간이 그러한 생명윤리를 어기고 동물실험을 계속 진행하는 거는 옳지 않다고 생각한다. 두 번째 이유로는 동물도 감정을 가지고 있고 고통을 느낀다는 점이다. 인간은 주사 한 방만 맞아도 따끔하면서 아픈 느낌이 들 것이다. 동물도 자신의 고통을 몸짓과 소리로 표현하는데, 그런 점을 생각하지 않고 고통스럽고 힘든 실험을 동물에게 계속 한다는 것은 입장을 바꿔 생각해본다면 얼마나 끔찍한 행위인지 알 수 있다. 세 번째로 무분별한 실험이다. 인간과 동물이 같을 수 없기 때문에 동물한테 부작용이 안 생겨도 인간한테는 생길 수 있고 동물한테 부작용이 생겨도 인간한테는 안 생길 수도 있다. 물론 동물실험을 통해 많은 정보와 도움을 받을 수 있다는 것은 부정할 수 없지만 정확하지도 않은 정보를 위해 동물을 끝없이 죽이고 2015년에 250만 마리에 동물을 죽일 정도로 의미 있는 실험이 맞을까 생각이 드는 것이다. 그래서 나는 동물실험은 불가피한 최후의 수단으로 두고 꼬마 선충 같은 대체물을 찾는 것이 맞다고 생각한다. 아무리 많은 반대가 있어도 회사와 생산자, 과학자 등은 끊임없이 동물실험을 지속할 것이다. 하지만 이러한 사람들이 동물실험에 대해 진지하게 고민해 보고 대안책을 찾아보면서 동물실험을 조금이라도 줄인다면 좋겠다고 생각했다. 동물들도 지구에서 우리와 함께 사는 소중한 생명체이고 존재이다. 동물을 실험의 대상으로만 보지 않고 우리와 동일한 생명체로 한 번쯤은 고민해보고, 봤으면 좋겠다. 앞으로는 무분별한 동물실험이 조금은 줄어들기를 기대해보고 소망한다.